UỶ BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN

BÁO CÁO CUỐI KÌ MÔN
DỮ LIỆU LỚN

CHUYÊN ĐỀ:

XỬ LÝ VÀ PHÂN TÍCH DỮ LIỆU COVID-19 KHU VỰC ĐÔNG NAM Á

Sinh viên thực hiện

Lớp

Giảng viên hướng dẫn

Học phần

BẢNG ĐÁNH GIÁ THÁI ĐỘ THAM GIA CỦA CÁC THÀNH VIÊN NHÓM

Thành viên	MSSV	Họ và tên	Tỷ lệ đóng góp	Ký tên
1			50%	
2			50%	

MỤC LỤC

PHẦN MỞ ĐẦU 8
1. Lý do chọn đề tài 8
2. Mục tiêu và ý nghĩa thực tiễn của Đồ án 9
I. TỔNG QUAN VỀ ĐỀ TÀI VÀ DỮ LIỆU 10
1.1. Giới thiệu bài toán 10
1.2. Mục tiêu đồ án 10
1.3. Khám phá tập dữ liệu (EDA) 10
1.3.1. Nguồn gốc dữ liệu 10
1.3.2. Từ điển dữ liệu 11
1.3.3. Đánh giá sơ bộ chất lượng dữ liệu 11
II. CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ 13
2.1. Nền tảng Docker — Container hóa 13
2.1.1. Khái niệm Containerization 13
2.1.2. Docker Compose — Quản lý đa container 13
2.1.3. Tại sao dùng Docker trong Big Data? 14
2.2. Hệ sinh thái Hadoop — Kiến trúc HDFS 15
2.2.1. Kiến trúc tổng thể 15
2.2.2. HDFS — Kiến trúc Master-Worker 15
2.2.3. Cơ chế lưu trữ và tính chịu lỗi 16
2.3. Apache Spark — Động cơ xử lý dữ liệu 16
2.3.1. Kiến trúc Spark Cluster 16
2.3.2. RDD và DataFrame API 17
2.3.3. Lazy Evaluation — Cơ chế thực thi thông minh 17
2.3.4. Ưu điểm của In-Memory Processing 17
2.4. Kỹ thuật lập trình PySpark quan trọng 18
2.4.1. groupBy và agg — Tổng hợp dữ liệu 18
2.4.2. Window Functions — LAG, RANK, ROW_NUMBER 18
III. THIẾT KẾ KIẾN TRÚC HỆ THỐNG 20
3.1. Mô hình kiến trúc tổng thể 20
3.2. Luồng dữ liệu — Medallion Architecture 21

3.3. Thiết kế lưu trữ — Parquet vs CSV 21
IV. TRIỂN KHAI CHI TIẾT VÀ KẾT QUẢ 23
4.1. Cấu hình môi trường — docker-compose.yml 23
4.1.1. Mục tiêu 23
4.1.2. Nội dung file docker-compose.yml và giải thích kỹ thuật 23
4.1.3. Quy trình khởi động và kiểm tra trạng thái 24
4.1.4. Quy trình đẩy dữ liệu lên hệ thống phân tán HDFS 24
4.2. Giai đoạn làm sạch (Tiền xử lý) 26
4.2.1. Khám phá dữ liệu thô (Data Exploration) 26
4.2.2. Kiểm tra chất lượng dữ liệu (Data Quality Assessment) 29
4.2.3. Làm sạch và lưu dữ liệu (Data Cleaning & Transformation) 32
4.3. Giai đoạn tổng hợp (Aggregation) 35
4.3.1. Tổng hợp dữ liệu theo chu kỳ Tháng (Monthly Aggregation) 35
4.3.2. Tổng hợp theo quý (Quarterly Aggregation) 39
4.3.3. Tổng hợp theo năm (Yearly Aggregation) 41
4.4. Giai đoạn phân tích chuyên sâu — 5 Data Marts (Lớp Gold) 45
4.4.1. Phân loại Đánh giá rủi ro (Risk Assessment Data Mart) 45
4.4.2. Phân tích tăng trưởng MoM (Month-over-Month Growth) 48
4.4.3. Hệ thống Xếp hạng và Truy tìm Đỉnh dịch 51
V. TỔNG KẾT VÀ ĐÁNH GIÁ 61
5.1. Kết quả đạt được 61
5.1.1. Kết quả kỹ thuật 61
5.1.2. Kết quả phân tích 62
5.2. Hướng phát triển và Mở rộng hệ thống 62
5.2.1. Tích hợp Kafka — Streaming Pipeline 63
5.2.2. Machine Learning — Dự báo ca mắc 63
5.2.3. Các hướng phát triển khác 63
PHÂN CÔNG CÔNG VIỆC 64
TÀI LIỆU THAM KHẢO 65

DANH MỤC HÌNH ẢNH

Hình 4.1. Terminal hiển thị kết quả lệnh docker ps 24
Hình 4.2. Giao diện HDFS Web UI (localhost:9870) — Tổng quan dung lượng Cụm 25
Hình 4.3. Giao diện HDFS duyệt file thành công tại đường dẫn /data/raw/asean_data.csv 26
Hình 4.4. Terminal thông tin data 27
Hình 4.5. Ảnh Terminal Schema hiển thị 10 cột dữ liệu 27
Hình 4.6. Terminal hiển thị 10 dòng đầu data 27
Hình 4.7. Thống kê mô tả 28
Hình 4.8. Kết quả đếm số lượng bản ghi theo từng nhóm depth (Bảng phân cấp địa lý 3 cấp) 30
Hình 4.9. Kết quả đếm số lượng giá trị NULL của 10 cột 30
Hình 4.10. Kết quả 7 bước làm sạch 33
Hình 4.11. Kết quả Schema sau làm sạch (12 cột) 34
Hình 4.12. Thông tin 12 cột mới và thông báo lưu thành công 34
Hình 4.13. Bảng tổng hợp tháng với 363 nhóm mẫu 36
Hình 4.14. Diễn biến dịch theo tháng ở Việt Nam 37
Hình 4.15. Biểu đồ tương quan giữa số ca mắc mới và số ca tử vong 39
Hình 4.16. Tổng hợp dữ liệu toàn khu vực Đông Nam Á 39
Hình 4.17. Bảng tổng hợp năm đầy đủ 33 nhóm dữ liệu (quốc gia × năm =33) 42
Hình 4.18. Biểu đồ thể hiện số ca mắc mới qua từng năm (2020, 2021 và 2022) của các nước Đông Nam Á 43
Hình 4.19. Biểu đồ thể hiện số ca mắc cả kỳ của các nước Đông Nam Á 43
Hình 4.20. Biểu đồ thể hiện tỷ lệ tử vong trung bình (CFR TB %) của các nước Đông Nam Á 44
Hình 4.21. Kết quả phân phối mức độ nguy hiểm trên 363 nhóm 46
Hình 4.22. Những tháng có ca mắc cao nhất và tỉ lệ tử vong trung bình của từng nước (CFR) 46
Hình 4.23. Biểu đồ th hiện tháng nguy hiểm nhất từng nước ở Đông Nam Á 47
Hình 4.24. Phân phối 6 mức độ xu hướng 49
Hình 4.25. Biểu đồ diễn biến dịch bệnh tăng trưởng theo tháng (%) của Việt Nam từ tháng 01/2020 đến tháng 09/2022 50
Hình 4.26. Bảng xếp hạng số tháng đứng hạng 1 tâm dịch từng nước 52
Hình 4.27. Biểu đồ thể hiện Top 3 tâm dịch các nước Đông Nam Á (theo tháng) năm 2020 53
Hình 4.28. Biểu đồ thể hiện Top 3 tâm dịch các nước Đông Nam Á (theo tháng) năm 2021 53
Hình 4.29. Biểu đồ thể hiện Top 3 tâm dịch các nước Đông Nam Á (theo tháng) năm 2022 54
Hình 4.30. Bảng tổng kết toàn bộ khu vực Đông Nam Á theo năm 55
Hình 4.31. Biểu đồ thể hiện Quy mô lây nhiễm và Số ca tử vong trên toàn khu vực Đông Nam Á 56

Hình 4.32. Biểu đồ thể hiện Tỉ lệ tử vong toàn kỳ (CFR) trên toàn khu vực Đông Nam Á 56
Hình 4.33. Bảng đỉnh dịch của 11 quốc gia 57
Hình 4.34. Bảng so sánh đỉnh dịch giữa các nước 59
Hình 4.35. Biểu đồ thể hiện số ca mắc trung bình mỗi ngày (phân loại theo làn sóng dịch) của các nước Đông Nam Á 59
Hình 4.36. Biểu đồ thể hiện tổng ca mắc mới trong tháng so với tỉ lệ tử vong (CFR %) 60

DANH MỤC BẢNG BIỂU

Bảng 1.1. Từ điển dữ liệu — 10 cột asean_data.csv 11
Bảng 1.2. Đánh giá chất lượng dữ liệu theo nhóm cột 12

Bảng 3.1. Chi tiết cấu hình và vai trò của 3 container Docker 21
Bảng 3.2. So sánh chiến lược lưu trữ Parquet và CSV 22

Bảng 4.1. Tổng hợp chỉ số thống kê mô tả trên các trường dữ liệu quan trọng 28
Bảng 4.2. Phân cấp địa lý và quyết định xử lý 31
Bảng 4.3. Kết quả chi tiết 7 bước làm sạch 35
Bảng 4.4. Diễn biến tháng đầy đủ của Việt Nam 38
Bảng 4.5. Tổng hợp quý — toàn khu vực Đông Nam Á 40
Bảng 4.6. Tổng hợp diễn biến dịch tễ theo năm — 11 quốc gia ASEAN 42
Bảng 4.7. Phân phối mức độ nguy hiểm theo lượng ca mắc (DM1) 47
Bảng 4.8. Phân phối xu hướng dịch bệnh theo tháng trên toàn khu vực Đông Nam Á 49
Bảng 4.9. Dịch chuyển tâm dịch theo giai đoạn (DM3) 53
Bảng 4.10. Tháng đỉnh dịch của 11 quốc gia Đông Nam Á 58

Bảng 5.1. Đánh giá tổng hợp kết quả kỹ thuật 61
Bảng 5.2. Các phát hiện chính từ phân tích dữ liệu 62

PHẦN MỞ ĐẦU

1. Lý do chọn đề tài

Bối cảnh đại dịch và sự bùng nổ của dữ liệu y tế Đại dịch COVID-19 không chỉ là sự kiện y tế công cộng có quy mô và tác động tàn khốc nhất trong hơn một thế kỷ qua, mà còn là chất xúc tác tạo ra một cuộc cách mạng về thu thập dữ liệu số. Từ tháng 1/2020 đến nay, đại dịch đã tạo ra một lượng dữ liệu dịch tễ học khổng lồ được cập nhật liên tục từng giờ, từng ngày từ hàng trăm quốc gia và vùng lãnh thổ. Các chỉ số như số ca mắc mới, số ca tử vong, năng lực xét nghiệm, tỉ lệ bao phủ vaccine hay sự xuất hiện của các biến thể mới đã hình thành nên một trong những bộ dữ liệu thời gian thực lớn nhất trong lịch sử y học nhân loại.
Sự kiện này đặt ra một bài toán điển hình mang đầy đủ các đặc trưng của Big Data (Dữ liệu lớn): Khối lượng dữ liệu khổng lồ (Volume), tốc độ phát sinh liên tục (Velocity) và độ phức tạp cao (Variety). Dữ liệu này quá lớn để xử lý bằng các công cụ truyền thống, nhưng lại chứa đựng nguồn thông tin/tri thức có giá trị to lớn vô giá, là chìa khóa then chốt để hỗ trợ chính phủ và các tổ chức y tế đưa ra quyết định kịp thời (Data-driven decision making).

Đông Nam Á – Bức tranh dịch tễ học đa chiều và phức tạp Khi thu hẹp lăng kính nghiên cứu, khu vực Đông Nam Á với 11 quốc gia thành viên ASEAN cùng quy mô dân số hơn 680 triệu người nổi lên như một mô hình thu nhỏ của thế giới. Đây là một trong những khu vực đa dạng nhất toàn cầu về điều kiện kinh tế - xã hội, hạ tầng hệ thống y tế, mật độ dân số cũng như chiến lược ứng phó với khủng hoảng.
Chính sự đa dạng và độ trễ về thời gian bùng phát dịch đã tạo ra những câu chuyện dịch tễ học vô cùng phong phú: Việt Nam với chiến lược Zero-COVID nghiêm ngặt và hiệu quả trong giai đoạn đầu; Singapore với chiến dịch thần tốc đạt tỉ lệ tiêm chủng cao nhất khu vực; Indonesia phải đối mặt với làn sóng lây lan nghiêm trọng do quy mô dân số khổng lồ và địa hình quần đảo phức tạp; hay Myanmar với hệ thống y tế bị đình trệ do ảnh hưởng bởi những bất ổn chính trị. Việc phân tích dữ liệu COVID-19 trong bối cảnh Đông Nam Á vì thế không chỉ dừng lại ở một bài tập kỹ thuật đơn thuần, mà còn là cơ hội để trích xuất những quy luật lây lan, đánh giá hiệu quả của các chính sách và rút ra những bài học thực tiễn, định hình kịch bản ứng phó cho các cuộc khủng hoảng y tế công cộng trong tương lai.

Sự dịch chuyển công nghệ: Giới hạn của công cụ truyền thống và Sức mạnh của Big Data Để giải quyết bài toán trên, các hệ thống xử lý dữ liệu truyền thống đang bộc lộ những giới hạn rõ rệt. Các công cụ như Microsoft Excel hay SQL Server cấu trúc đơn lẻ (Single-node) không thể tải và xử lý hiệu quả bộ dữ liệu thô lên tới gần 400.000 bản ghi với hàng chục trường thông tin. Nút thắt cổ chai (Bottleneck) càng hiện rõ khi hệ thống phải thực thi các phép tính phân tích chuỗi thời gian phức tạp như Window Functions (so sánh tốc độ tăng trưởng tháng này với tháng trước, hay xếp hạng động để tìm ra đỉnh dịch theo từng quốc gia). Các truy vấn này trên hệ cơ sở dữ liệu quan hệ thường tốn rất nhiều thời gian hoặc gây quá tải hệ thống.

Trong khi đó, với kiến trúc xử lý phân tán và tính toán trực tiếp trên bộ nhớ (In-Memory Processing), nền tảng Apache Spark có thể đọc, làm sạch và phân tích khối dữ liệu tương tự chỉ trong vài giây. Hơn thế nữa, Spark cung cấp khả năng mở rộng linh hoạt (Scalability), cho phép hệ thống dễ dàng mở rộng khả năng xử lý lên tới hàng Terabyte dữ liệu chỉ bằng cách bổ sung thêm các máy tính trạm (Worker Node) vào cụm (Cluster) mà không cần phải viết lại hay thay đổi mã nguồn. Đây chính là giá trị cốt lõi và sức mạnh không thể thay thế của Big Data: Xử lý khối lượng công việc vượt ngoài tầm với của các hệ thống cũ với một mức chi phí và thời gian tối ưu nhất.

2. Mục tiêu và ý nghĩa thực tiễn của Đồ án

Đồ án này được nhóm chúng em thực hiện trong khuôn khổ học phần Dữ Liệu Lớn, tập trung chuyên sâu vào Giai đoạn 4 — **Xử lý, Chuyển đổi và Phân tích Dữ liệu (Data Processing & Analytics)** trong một Pipeline Big Data hoàn chỉnh. Thông qua việc ứng dụng hệ sinh thái Hadoop và PySpark trên nền tảng Docker, nhóm không chỉ đặt mục tiêu xây dựng thành công một hệ thống kỹ thuật vận hành trơn tru, mà quan trọng hơn là ứng dụng nó để đánh giá/theo dõi sát sao diễn biến đại dịch tại Đông Nam Á. Những phát hiện có giá trị được trích xuất từ dữ liệu thô trong đồ án này chính là minh chứng rõ nét nhất cho sức mạnh thực tiễn của lĩnh vực Phân tích Dữ liệu Lớn (Big Data Analytics) trong kỷ nguyên số hiện nay.

I. TỔNG QUAN VỀ ĐỀ TÀI VÀ DỮ LIỆU

1.1. Giới thiệu bài toán

Bài toán được đặt ra là: Với bộ dữ liệu dịch tễ học COVID-19 thực tế từ Google bao phủ 11 quốc gia Đông Nam Á trong gần 3 năm (394.165 bản ghi), làm thế nào để xây dựng một pipeline xử lý dữ liệu tự động, có thể làm sạch dữ liệu thô, tổng hợp theo nhiều chiều thời gian, và thực hiện phân tích đa chiều để rút ra các insight có giá trị về diễn biến đại dịch?

Bài toán này thể hiện đầy đủ thách thức của Big Data: dữ liệu có 3 cấp độ địa lý (quốc gia, tỉnh, huyện) dễ gây tính trùng nếu không xử lý cẩn thận; có nhiều giá trị NULL (>60% ở một số cột) cần chiến lược xử lý phù hợp; cần các phép tính phức tạp như so sánh tháng-qua-tháng hay xếp hạng động không thể làm trực tiếp bằng GROUP BY thông thường.

1.2. Mục tiêu đồ án

Mục tiêu kỹ thuật: Triển khai thành công Giai đoạn 4 – Xử lý Dữ liệu trong Big Data Pipeline với Apache Spark 3.5.0 và Hadoop HDFS, chạy trong môi trường Docker. Xây dựng pipeline ETL (Extract-Transform-Load) hoàn chỉnh với 12 file PySpark tuần tự, xử lý từ dữ liệu thô đến 5 Data Marts phân tích đa chiều. Áp dụng các kỹ thuật nâng cao bao gồm Window Functions (LAG, RANK, ROW_NUMBER) và lưu trữ theo chuẩn Data Lake với định dạng Parquet.

Mục tiêu phân tích: Khám phá và định lượng các xu hướng dịch tễ học tại Đông Nam Á bao gồm: sự tiến hóa của dịch bệnh qua 3 giai đoạn (2020/2021/2022), sự khác biệt giữa biến thể Delta và Omicron, hiệu quả của chương trình tiêm chủng thông qua sự thay đổi của CFR, và sự dịch chuyển vai trò tâm dịch giữa các quốc gia.

1.3. Khám phá tập dữ liệu (EDA)

1.3.1. Nguồn gốc dữ liệu

Dữ liệu được lấy từ Google COVID-19 Open Data, một dự án của Google LLC được ra mắt vào tháng 4/2020 nhằm tổng hợp và chuẩn hóa dữ liệu dịch tễ học từ các nguồn chính thức trên toàn thế giới bao gồm WHO, CDC, các bộ y tế quốc gia và nhiều tổ chức nghiên cứu uy tín. Đây là một trong những bộ dữ liệu COVID-19 đầy đủ và đáng tin cậy nhất hiện nay.

File gốc epidemiology.csv có dung lượng hơn 7GB với hàng chục triệu bản ghi toàn cầu. Script Python get_asean_data.py được viết để tải file này theo từng chunk 100.000 dòng và lọc ra chỉ các bản ghi thuộc 11 quốc gia Đông Nam Á, tạo ra file asean_data.csv với 394.165 bản ghi, kích thước khoảng 25MB.

1.3.2. Từ điển dữ liệu

Tên cột	Kiểu dữ liệu	Mô tả chi tiết	Ví dụ	Đặc điểm
date	String → Date	Ngày ghi nhận số liệu, định dạng YYYY-MM-DD	2021-07-15	Không có NULL
location_key	String	Mã địa lý theo chuẩn ISO. 2 ký tự = quốc gia; thêm '_XX' = tỉnh/huyện	VN, VN_44, VN_44_704	Không có NULL
new_confirmed	Integer	Số ca mắc mới được xác nhận trong ngày. Đây là chỉ số quan trọng nhất.	139.780	Không có NULL, có thể = 0
new_deceased	Integer	Số ca tử vong mới trong ngày. Dùng tính CFR.	1.219	Không có NULL
new_recovered	Integer	Số ca hồi phục mới trong ngày. Nhiều nước dừng báo cáo sau 2021.	50.000	NULL 68,4%
new_tested	Integer	Số xét nghiệm COVID mới thực hiện trong ngày.	1.200.000	NULL 62,5%
cumulative_confirmed	Integer	Tổng số ca mắc tích lũy từ đầu dịch đến ngày đó.	11.448.034	Không có NULL
cumulative_deceased	Integer	Tổng số ca tử vong tích lũy từ đầu dịch.	157.849	Không có NULL
cumulative_recovered	Integer	Tổng số ca hồi phục tích lũy.	N/A	NULL 68,4%
cumulative_tested	Integer	Tổng số xét nghiệm tích lũy.	N/A	NULL 62,3%

Bảng 1.1. Từ điển dữ liệu — 10 cột asean_data.csv

1.3.3. Đánh giá sơ bộ chất lượng dữ liệu

Sau khi lọc cấp quốc gia (10.864 bản ghi), đánh giá chất lượng dữ liệu cho thấy hai nhóm cột rõ ràng. Nhóm 1 — chất lượng tốt: date, location_key, new_confirmed, new_deceased, cumulative_confirmed, cumulative_deceased đều có NULL = 0, đây chính là các cột quan trọng nhất cho phân tích dịch tễ học. Nhóm 2 — nhiều NULL: new_recovered (68,4%), new_tested (62,5%), cumulative_recovered (68,4%), cumulative_tested (62,3%). Tỉ lệ NULL cao này không phải lỗi kỹ thuật mà phản ánh thực tế: WHO và nhiều cơ quan y tế quốc gia đã ngừng yêu cầu báo cáo các chỉ số hồi phục và xét nghiệm chi tiết khi số ca tăng đột biến vào 2021–2022.

Nhóm cột	Cột	NULL (%)	Đánh giá chất lượng
Nhóm 1: Tốt	date, location_key	0%	Tốt — đây là backbone của dataset
Nhóm 1: Tốt	new_confirmed, new_deceased	0%	Hai chỉ số cốt lõi, đầy đủ 100%
Nhóm 1: Tốt	cumulative_confirmed, cumulative_deceased	0%	Lũy kế đầy đủ
Nhóm 2: NULL	new_recovered, cumulative_recovered	68,4%	Nhiều NULL — xử lý bằng fillna(0)
Nhóm 2: NULL	new_tested, cumulative_tested	~62,5%	Nhiều NULL — xử lý bằng fillna(0)

Bảng 1.2. Đánh giá chất lượng dữ liệu theo nhóm cột

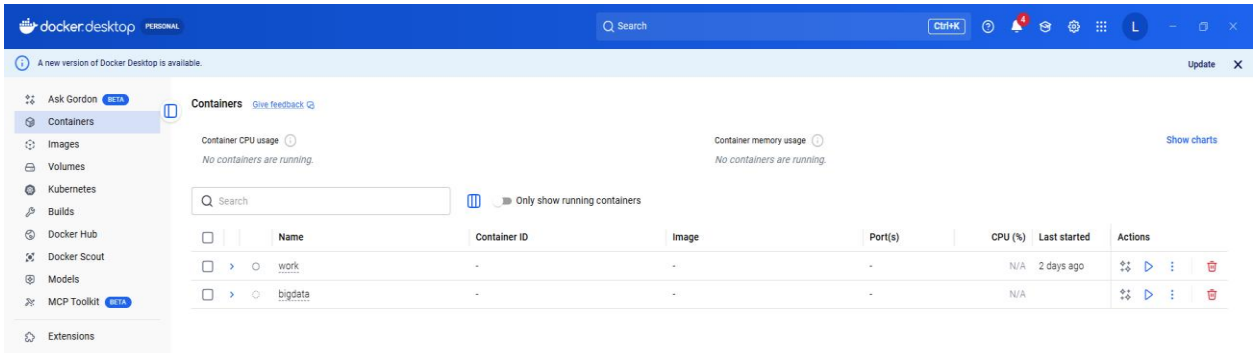
II. CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ

2.1. Nền tảng Docker — Container hóa

2.1.1. Khái niệm Containerization

Container là một đơn vị phần mềm tiêu chuẩn hóa, đóng gói mã nguồn ứng dụng cùng toàn bộ các thành phần phụ thuộc (runtime, system tools, thư viện, cấu hình) vào một môi trường cô lập, nhẹ và có tính di động cao. Khác với kiến trúc máy ảo truyền thống (Virtual Machine - VM) đòi hỏi phải mô phỏng toàn bộ phần cứng và chạy một hệ điều hành khách (Guest OS) cồng kềnh, container hoạt động dựa trên cơ chế ảo hóa cấp hệ điều hành (OS-level virtualization). Các container chia sẻ chung kernel của hệ điều hành máy chủ (Host OS), nhờ đó chúng có dung lượng rất nhẹ (thường chỉ vài chục MB) và tốc độ khởi động tính bằng giây thay vì vài phút như máy ảo.

Docker hiện là nền tảng containerization phổ biến nhất thế giới. Trong hệ sinh thái này, **Image Docker** đóng vai trò như một bản thiết kế (template) bất biến, chứa ứng dụng và môi trường cấu hình sẵn. **Container** chính là một thực thể (instance) đang chạy của image đó. Để quản lý các bản thiết kế này, hệ thống sử dụng **Registry** (như Docker Hub) — một kho lưu trữ image công khai, nơi nhóm đã tải xuống các image lõi của Hadoop và Spark để phục vụ cho đồ án.



Hình 2.1. Ảnh minh họa Docker và Container

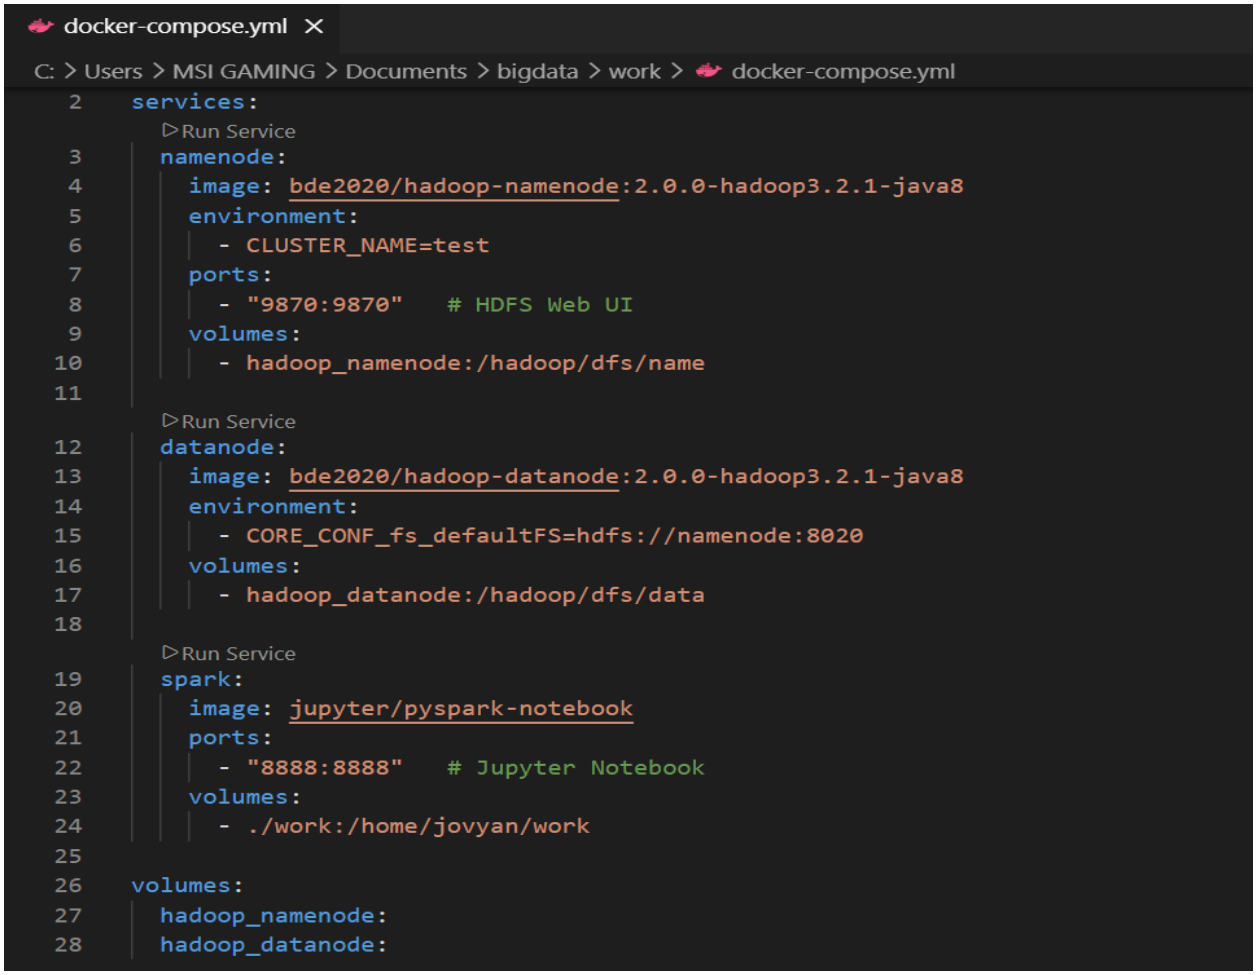
2.1.2. Docker Compose — Quản lý đa container

Khi triển khai các hệ thống phân tán như Big Data, việc quản lý thủ công từng container là không khả thi. Docker Compose ra đời như một công cụ điều phối (orchestration) cục bộ, cho phép định nghĩa và quản lý các ứng dụng đa container thông qua một file duy nhất có định dạng YAML (docker-compose.yml).

Các thành phần cốt lõi trong file cấu hình bao gồm:

- services: Định nghĩa các node trong hệ thống (ví dụ: namenode, datanode, spark-master).
- image: Chỉ định Docker image được sử dụng làm nền tảng.

- ports: Thiết lập quy tắc ánh xạ cổng (port mapping) để máy chủ thật có thể giao tiếp với các dịch vụ bên trong mạng ảo.
- environment: Cấu hình các biến môi trường động cho hệ thống.
- volumes: Cơ chế chia sẻ ổ đĩa cứng, giúp đồng bộ mã nguồn PySpark và tập dữ liệu từ máy thật vào bên trong container mà không cần sao chép thủ công.



Hình 2.2. Cấu hình các dịch vụ Big Data trong file docker-compose.yml

2.1.3. Tại sao dùng Docker trong Big Data?

Việc cài đặt thủ công một cụm Hadoop và Spark kết hợp với môi trường Java trên hệ điều hành Windows thường mất từ 4–6 giờ, đòi hỏi phải thiết lập các biến môi trường (PATH) phức tạp và rất dễ đối mặt với lỗi xung đột phiên bản (version conflict). Docker giải quyết triệt để bài toán này bằng cách đóng gói toàn bộ hệ sinh thái Big Data vào các image chuẩn hóa. Bằng một lệnh docker-compose up duy nhất, một cụm Hadoop và Spark hoàn chỉnh có thể được khởi tạo chỉ trong chưa đầy 10 phút.

Hơn thế nữa, Docker đảm bảo tính nhất quán tuyệt đối về môi trường: mã nguồn chạy thành công trên máy tính của sinh viên A chắc chắn sẽ hoạt động với kết

quả tương tự trên máy tính của sinh viên B, loại bỏ hoàn toàn vấn đề "works on my machine" kinh điển trong phát triển phần mềm.

2.2. Hệ sinh thái Hadoop — Kiến trúc HDFS

2.2.1. Kiến trúc tổng thể

Hadoop là một framework mã nguồn mở do quỹ Apache phát triển, thiết kế chuyên biệt cho việc lưu trữ và xử lý phân tán các tập dữ liệu khổng lồ. Kiến trúc cốt lõi của Hadoop hoạt động dựa trên hai trụ cột chính: **HDFS** (Hadoop Distributed File System) đảm nhận vai trò lưu trữ phân tán, và **YARN** (Yet Another Resource Negotiator) làm nhiệm vụ quản lý tài nguyên và lên lịch trình (scheduling) cho các tác vụ. Triết lý thiết kế đột phá của Hadoop nằm ở việc tận dụng phần cứng phổ thông (commodity hardware) — thay vì đầu tư vào các siêu máy tính đắt đỏ, hệ thống sẽ phân tán khối lượng công việc ra hàng loạt máy tính thông thường để tối ưu hóa chi phí và hiệu suất.

2.2.2. HDFS — Kiến trúc Master-Worker

HDFS hoạt động theo mô hình Master-Worker chuẩn mực, bao gồm:

- **NameNode (Master):** Đóng vai trò là trung tâm điều khiển của hệ thống, chịu trách nhiệm lưu trữ toàn bộ siêu dữ liệu (metadata) trên RAM, bao gồm cây thư mục, tên file, quyền truy cập và vị trí của các khối dữ liệu (block) trên toàn mạng lưới. NameNode tuyệt đối không lưu trữ dữ liệu thực tế, mà chỉ giữ chức năng như một "bản đồ" chỉ dẫn. Mặc dù là điểm chạm quan trọng nhất, thiết kế này cũng biến NameNode thành rủi ro điểm lỗi duy nhất (Single Point of Failure) trong các kiến trúc cơ bản.
- **DataNode (Worker):** Là các nút xử lý/thực thực thi nhiệm vụ lưu trữ dữ liệu vật lý dưới dạng các block (kích thước mặc định thường là 128MB). Kích thước block lớn nhằm giảm thiểu tối đa thời gian tìm kiếm trên ổ cứng (seek time) và giảm tải lượng metadata cho NameNode. Theo chu kỳ 3 giây, các DataNode sẽ gửi tín hiệu nhịp tim (heartbeat) về NameNode để báo cáo tình trạng "còn sống". Nếu NameNode không nhận được tín hiệu từ một DataNode sau 10 phút, node đó sẽ bị đánh dấu là đã chết.



Hình 2.3. Giao diện quản lý NameNode và trạng thái các DataNode của hệ thống HDFS

2.2.3. Cơ chế lưu trữ và tính chịu lỗi

HDFS được thiết kế với cơ chế sao chép (Replication) nghiêm ngặt để đảm bảo an toàn dữ liệu. Khi người dùng tải một file lên HDFS, hệ thống sẽ băm file đó thành các block 128MB. Client sẽ liên hệ NameNode để lấy danh sách các DataNode khả dụng. Hệ thống thường áp dụng mức độ nhân bản (Replication Factor) là 3. Client sẽ tiến hành ghi block đầu tiên vào DataNode 1; tiếp đó DataNode 1 sẽ đóng vai trò trạm trung chuyển để chép sang DataNode 2; và DataNode 2 tiếp tục chép sang DataNode 3. Dòng chảy dữ liệu (pipeline replication) này đảm bảo mỗi block luôn có 3 bản sao dự phòng nằm rải rác trên các rack máy chủ khác nhau.

Nhờ cơ chế này, HDFS đạt được tính chịu lỗi (Fault Tolerance) cực kỳ mạnh mẽ. Khi một DataNode bị sập do hỏng hóc phần cứng, NameNode ngay lập tức phát hiện thông qua sự cố gián đoạn heartbeat và tự động ra lệnh tạo bản sao mới cho các block bị mất từ 2 bản sao còn lại. Quá trình tự phục hồi này diễn ra trong suốt, đảm bảo dữ liệu luôn toàn vẹn mà không làm gián đoạn trải nghiệm của người dùng.

2.3. Apache Spark — Động cơ xử lý dữ liệu

2.3.1. Kiến trúc Spark Cluster

Apache Spark vận hành dựa trên kiến trúc phân tán Driver-Executor.

- **Driver Program:** Là tiến trình chỉ huy trung tâm. Khi người dùng gửi mã lệnh PySpark, Driver sẽ biên dịch chúng thành một Đồ thị có hướng không chu trình (Directed Acyclic Graph - DAG) đại diện cho kế hoạch tính toán logic. Sau đó, nó chia nhỏ DAG thành các Stage và Task.

- **Cluster Manager:** (Có thể là YARN, Mesos, hoặc Standalone) hoạt động như một nhà đàm phán tài nguyên, cấp phát CPU và RAM trên cụm máy chủ cho ứng dụng Spark.
- **Executor:** Là các tiến trình công nhân nằm trên Worker Node. Chúng thực thi các Task được Driver phân công. Mỗi Executor sở hữu một bộ nhớ đệm (Cache Memory) riêng và nhiều luồng (CPU Threads) để xử lý song song. Trong phạm vi đồ án, nhóm sử dụng cấu hình local[*], nghĩa là cả Driver và Executor đều khởi chạy trên cùng một tiến trình JVM, tận dụng tối đa toàn bộ số lõi CPU của máy tính cá nhân.

2.3.2. RDD và DataFrame API

- **RDD (Resilient Distributed Dataset):** Là cấu trúc dữ liệu nguyên thủy của Spark. Nó là một tập hợp các đối tượng được phân tán trên nhiều node, có tính chất bất biến (immutable). Dù mang lại khả năng can thiệp sâu ở tầng thấp, RDD đòi hỏi mã lệnh phức tạp và không hỗ trợ các cơ chế tối ưu hóa tự động từ lõi hệ thống.
- **DataFrame API:** Ra mắt từ Spark 1.3, DataFrame cung cấp một lớp trừu tượng bậc cao hơn, tổ chức dữ liệu theo các cột có định danh (schema) tương tự như bảng trong cơ sở dữ liệu quan hệ (SQL) hay thư viện Pandas. Lợi điểm lớn nhất của DataFrame là được hỗ trợ bởi động cơ **Catalyst Optimizer**. Nhờ đó, Spark có thể tự động phân tích truy vấn của lập trình viên và tìm ra con đường thực thi tối ưu nhất. Vì những ưu điểm vượt trội về hiệu năng và cú pháp trực quan, nhóm quyết định sử dụng hoàn toàn DataFrame API cho việc xử lý dữ liệu COVID-19.

2.3.3. Lazy Evaluation — Cơ chế thực thi thông minh

Thay vì tính toán ngay lập tức mỗi khi nhận một câu lệnh, Spark áp dụng chiến lược tính toán lười biếng (Lazy Evaluation). Khi lập trình viên gọi các phép biến đổi (Transformation) như filter, select hay groupBy, Spark chỉ ghi nhận lại các bước này vào đồ thị DAG chứ chưa thực sự đọc dữ liệu.

Chỉ khi mã nguồn gọi một hành động (Action) yêu cầu trả về kết quả — ví dụ như show(), count() hay write() — Spark mới chính thức được kích hoạt. Lúc này, Catalyst Optimizer sẽ rà soát toàn bộ DAG để gom nhóm các thao tác, cắt bỏ các bước dư thừa (ví dụ: đẩy việc lọc dữ liệu lên đầu chu trình để giảm tải dung lượng bộ nhớ). Cơ chế lười biếng này là chìa khóa giúp Spark tránh được những bài toán thắt cổ chai về mặt I/O.

2.3.4. Ưu điểm của In-Memory Processing

Mô hình Hadoop MapReduce thế hệ cũ mắc phải một nhược điểm chí mạng: nó phải đọc input từ HDFS, tính toán Map, ghi kết quả trung gian ra đĩa cứng, sau đó lại đọc từ đĩa cứng lên để tính Reduce, và ghi kết quả cuối cùng trở lại HDFS. Mỗi lần

ghi/đọc đĩa cứng (Disk I/O) đều tiêu tốn hàng trăm mili-giây, khiến các thuật toán phân tích lặp đi lặp lại trở nên vô cùng chậm chạp.

Ngược lại, Spark giữ lại và xử lý các bản ghi trung gian (DataFrames) hoàn toàn trong bộ nhớ RAM (In-Memory Processing). Dữ liệu chỉ bị ép phải ghi ra đĩa khi bộ nhớ RAM quá tải hoặc ở bước xuất kết quả cuối cùng. Nhờ kiến trúc này, Spark đạt tốc độ xử lý nhanh hơn MapReduce từ 10 đến 100 lần đối với các tác vụ truy vấn dữ liệu lớn. Trong đồ án này, nhờ cơ chế In-Memory, hàng chục nghìn bản ghi dữ liệu dịch tễ được chuyển đổi và tổng hợp trong thời gian tính bằng giây.

2.4. Kỹ thuật lập trình PySpark quan trọng

2.4.1. groupBy và agg — Tổng hợp dữ liệu

Hàm groupBy() thực hiện thao tác phân vùng DataFrame thành các tập con dựa trên các giá trị khóa (tương tự như mệnh đề GROUP BY trong SQL chuẩn). Khi kết hợp với phương thức agg(), hệ thống sẽ áp dụng các phép toán vô hướng lên từng tập con này (như F.sum() tính tổng ca mắc, F.max() tìm đỉnh điểm, hay F.avg() tính trung bình ca tử vong).

Trong hệ thống phân tán, các phép gom nhóm này thuộc nhóm Wide Transformation, yêu cầu các máy tính phải tráo đổi dữ liệu cho nhau qua mạng (quá trình Shuffle). Do đó, nhóm đã phải thiết kế chiến lược lưu trữ định dạng Parquet trước khi thực hiện groupBy để tối ưu hóa hiệu suất của toàn bộ quá trình tổng hợp dữ liệu theo tháng, quý và năm tại các file xử lý 2a, 2b và 2c.

2.4.2. Window Functions — LAG, RANK, ROW_NUMBER

Window Functions là nhóm hàm phân tích mạnh mẽ nhất trong Big Data, cho phép tính toán trên một "cửa sổ" (window) dữ liệu trượt mà không làm mất đi số lượng hàng ban đầu của bảng. Khung cửa sổ này được cấu trúc bởi hai thông số: partitionBy (xác định ranh giới nhóm, ví dụ: nhóm theo quốc gia) và orderBy (trình tự các bản ghi trong nhóm, ví dụ: xếp theo trục thời gian).

- **Hàm LAG(col, n):** Có khả năng trích xuất giá trị của một bản ghi nằm trước nó n bước trong cùng một phân vùng. Hàm này là lời giải duy nhất để thực hiện phép tính Tốc độ Tăng trưởng so với tháng trước (Month-over-Month Growth Rate) dựa trên công thức toán học:

$$MoM = \frac{Current - Previous}{Previous} \times 100\%$$

Đây là phép toán mà các hàm GROUP BY thông thường không thể giải quyết được do đặc tính gộp hàng và phá vỡ chuỗi thời gian.

- **Hàm RANK():** Thực hiện việc xếp hạng vị trí của từng bản ghi. Điểm đặc biệt của RANK là nếu hai tháng có số ca mắc bằng nhau, chúng sẽ nhận cùng một thứ hạng, và thứ hạng liền sau sẽ bị nhảy bậc (ví dụ: 1, 1, 3). Nhóm sử dụng kỹ

thuật này để đánh giá và xếp hạng độ nguy hiểm của các quốc gia ASEAN theo từng chu kỳ.

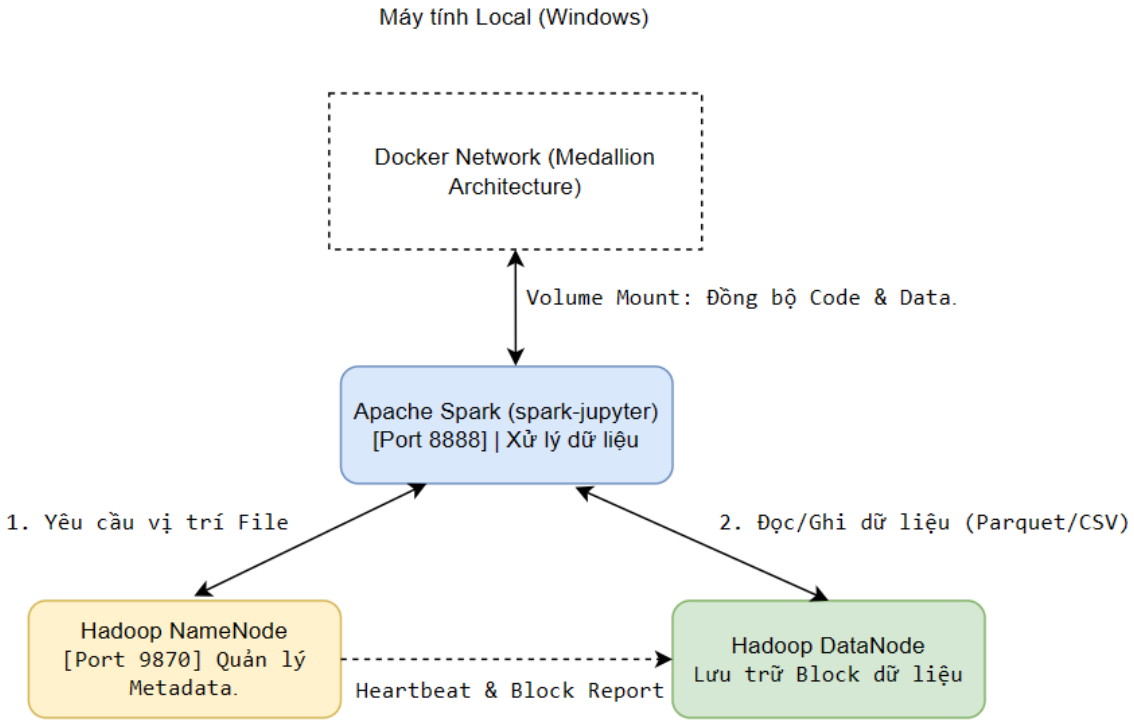
- **Hàm ROW_NUMBER():** Đánh số thứ tự duy nhất tịnh tiến (1, 2, 3...) cho từng dòng trong một cửa sổ. Ứng dụng quan trọng nhất của hàm này trong đồ án là thuật toán tìm Đỉnh Dịch. Bằng cách sắp xếp số ca mắc theo chiều giảm dần và sử dụng bộ lọc filter(ROW_NUMBER() == 1), hệ thống có thể trích xuất chính xác đúng một tháng tồi tệ nhất của mỗi quốc gia từ hàng nghìn bản ghi ban đầu.

III. THIẾT KẾ KIẾN TRÚC HỆ THỐNG

3.1. Mô hình kiến trúc tổng thể

Hệ thống được thiết kế và xây dựng theo mô hình **Medallion Architecture** (còn gọi là Multi-hop Architecture) — một tiêu chuẩn kiến trúc Data Lake/Data Lakehouse vô cùng phổ biến trong ngành kỹ thuật dữ liệu hiện nay. Kiến trúc này phân chia luồng dữ liệu thành 3 tầng với chất lượng và mức độ tinh chỉnh tăng dần: Bronze (thô), Silver (sạch) và Gold (phân tích).

Để đảm bảo tính độc lập và khả năng triển khai linh hoạt, toàn bộ kiến trúc lõi được ảo hóa và vận hành trong 3 Docker container, cấu hình tập trung qua tệp docker-compose.yml. Việc ảo hóa này không chỉ giúp khởi tạo môi trường nhanh chóng mà còn mô phỏng chính xác nguyên lý phân tách giữa tầng tính toán (Compute - Spark) và tầng lưu trữ (Storage - HDFS) thường thấy trong các hệ thống Big Data của doanh nghiệp.



Hình 3.1. Sơ đồ kiến trúc tổng thể — Tương tác giữa 3 container Docker và luồng dữ liệu HDFS

Container	Image Docker	Cổng (Port)	Vai trò trong kiến trúc
namenode	bde2020/hadoop-namenode:2.0.0-hadoop3.2.1-java8	9870 (Web UI)	NameNode — não của HDFS, quản lý metadata và cây thư mục. Giao diện web cho phép duyệt file system.
datanode	bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8	—	DataNode — kho chứa thực sự, lưu block dữ liệu vật lý. Giao tiếp nội bộ với namenode.
spark-jupyter	jupyter/pyspark-notebook:latest	8888 (Jupyter)	Spark Driver + Executor — chạy code PySpark. Volume mount ./work để đồng bộ file với máy host.

Bảng 3.1. Chi tiết cấu hình và vai trò của 3 container Docker

3.2. Luồng dữ liệu — Medallion Architecture

Giai đoạn Bronze — Raw Data (/data/raw/) Đây là tầng tiếp nhận dữ liệu thô nguyên bản từ nguồn cấp. Nguyên tắc tối thượng tại tầng Bronze là "Dữ liệu thô bất biến" (Immutable raw data). File asean_data.csv sau khi được tải lên HDFS sẽ được giữ nguyên trạng thái gốc, tuyệt đối không bị ghi đè hay chỉnh sửa. Thiết kế này tạo ra một "Nguồn sự thật duy nhất" (Single Source of Truth), đảm bảo khả năng truy vết dữ liệu (Data Lineage) và cho phép hệ thống dễ dàng xử lý lại (reprocess) từ đầu nếu có lỗi xảy ra ở các khâu sau.

Giai đoạn Silver — Cleaned & Aggregated Data (/data/processed/) Tầng Silver chứa các tập dữ liệu đã trải qua quá trình tiền xử lý, làm sạch và tổng hợp bằng sức mạnh của Apache Spark. Tại đây, dữ liệu được chia thành các thư mục: 1_cleaned_data (dữ liệu sạch, đã loại bỏ nhiễu và điền giá trị khuyết), 2_aggregated (dữ liệu gom nhóm theo trục thời gian Tháng/Quý/Năm) và các Data Mart phục vụ phân tích chuyên sâu. Tầng này đóng vai trò như một bộ lọc lõi, chuẩn hóa kiểu dữ liệu và tạo tiền đề vững chắc cho các truy vấn phân tích (OLAP). Toàn bộ dữ liệu tại đây được ép kiểu sang định dạng Parquet để tối ưu hóa hiệu năng.

Giai đoạn Gold — Export Data (/data/export/) Tầng Gold là điểm chạm cuối cùng của đường ống dữ liệu (Data Pipeline). Dữ liệu ở tầng này mang tính nghiệp vụ cao (Business-ready), dung lượng cực kỳ nhỏ gọn vì đã được đúc kết thành các tri thức cốt lõi (ví dụ: bảng xếp hạng, đỉnh dịch). Dữ liệu được chuyển đổi ngược lại thành định dạng CSV để xuất ra ngoài, phục vụ trực tiếp cho người dùng cuối, các phần mềm vẽ biểu đồ BI (Tableau, Power BI, Excel) hoặc làm đầu vào cho hệ thống truy vấn của nhóm khác.

3.3. Thiết kế lưu trữ — Parquet vs CSV

Quyết định thiết kế mang tính chiến lược nhất trong đồ án là việc sử dụng Apache Parquet làm định dạng lưu trữ nội bộ (cho tầng Silver) thay vì dùng CSV từ đầu đến cuối.

Parquet là định dạng lưu trữ theo cột (Columnar Format). Khi Spark thực thi một lệnh GROUP BY chỉ yêu cầu 2 cột dữ liệu, nó sẽ quét và trích xuất đúng 2 cột đó từ ổ cứng, hoàn toàn phớt lờ các cột còn lại. Đặc biệt, Parquet hỗ trợ cơ chế **Predicate Pushdown**, cho phép Spark đẩy các điều kiện lọc (filter) xuống tận lớp lưu trữ, ngăn chặn việc tải dữ liệu thừa vào RAM. Ngược lại, với kiến trúc lưu trữ theo hàng (Row-based) của CSV, hệ thống bắt buộc phải đọc toàn bộ mọi dòng dữ liệu từ đầu đến cuối dù chỉ cần phân tích một thông số duy nhất.

Tiêu chí	Parquet (Áp dụng cho Silver Layer)	CSV (Áp dụng cho Gold/Export Layer)
Mục đích	Lưu trữ trung gian, phân tích nặng	Chia sẻ, báo cáo, BI tools
Kích thước	~1–2MB cho 10.864 bản ghi	~5–8MB tương đương
Tốc độ đọc	Nhanh 3–5 lần — chỉ đọc cột cần	Chậm hơn — đọc toàn bộ dòng
Schema	Nhúng trong file — không cần khai báo	Không có — phải inferSchema
Nén	Tự động Snappy/Gzip	Không nén (text thuần)
Tương thích	Spark, Hive, Python(pyarrow), Presto	Mọi ứng dụng đọc text

Bảng 3.2. So sánh chiến lược lưu trữ Parquet và CSV

Bên cạnh đó, do bản chất phân tán của Spark, mỗi lần ghi dữ liệu dạng Parquet, hệ thống sẽ sinh ra rất nhiều file vật lý nhỏ (part-00000, part-00001...) tương ứng với số phân vùng (partition) trên RAM. Đây là thiết kế xuất sắc để các Executor đọc dữ liệu song song tốc độ cao. Tuy nhiên, nó lại gây khó khăn cho người dùng cuối. Do đó, kỹ thuật ép phân vùng coalesce(1) đã được áp dụng ở cuối tầng Gold để hợp nhất toàn bộ dữ liệu thành một file CSV duy nhất, đảm bảo tính gọn gàng và thân thiện khi trích xuất ra môi trường máy tính cá nhân.

IV. TRIỂN KHAI CHI TIẾT VÀ KẾT QUẢ

4.1. Cấu hình môi trường — docker-compose.yml

4.1.1. Mục tiêu

Bước này nhằm mục đích thiết lập toàn bộ hạ tầng Big Data cơ sở: bao gồm 3 container Docker được kết nối nội bộ với nhau, hệ thống lưu trữ phân tán HDFS sẵn sàng tiếp nhận dữ liệu, và môi trường ảo hóa PySpark có thể thực thi mã nguồn. Quá trình này mô phỏng lại chính xác quy trình khởi tạo một cụm máy chủ (Cluster) thực tế trong môi trường doanh nghiệp, đảm bảo tính tái sử dụng (reproducibility) và cô lập hoàn toàn khỏi hệ điều hành máy tính cá nhân.

4.1.2. Nội dung file docker-compose.yml và giải thích kỹ thuật

```
version: "3"
services:
  namenode:
    image: bde2020/hadoop-namenode:2.0.0-hadoop3.2.1-java8
    container_name: namenode
    environment:
      - CLUSTER_NAME=bigdata          # Tên cluster HDFS
      - CORE_CONF_fs_defaultFS=hdfs://namenode:8020  # URI của HDFS
    ports:
      - "9870:9870"                  # Expose Web UI ra máy host
    volumes:
      - hadoop_namenode:/hadoop/dfs/name  # Persist metadata
```

```
  datanode:
    image: bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8
    container_name: datanode
    environment:
      - CORE_CONF_fs_defaultFS=hdfs://namenode:8020  # Trỏ đến
namenode
    depends_on:
      - namenode                     # Khởi động sau namenode
    volumes:
      - hadoop_datanode:/hadoop/dfs/data  # Persist data blocks
```

```
  spark:
    image: jupyter/pyspark-notebook:latest
    container_name: spark-jupyter
    ports:
      - "8888:8888"                  # Jupyter Notebook
    environment:
      - JUPYTER_ENABLE_LAB=yes
    volumes:
      - ./work:/home/jovyan/work     # ← Quan trọng: đồng bộ thư mục
```

```
volumes:
  hadoop_namenode:
  hadoop_datanode:
```

Giải thích mở rộng:

- **Quản lý phụ thuộc (depends_on):** Đảm bảo tính toàn vẹn của hệ thống khi khởi động. DataNode bắt buộc phải đợi NameNode khởi tạo xong bảng băm (hash table) trên RAM thì mới bắt đầu chạy để gửi báo cáo.
- **Cơ chế lưu trữ bền vững (Named Volumes):** Các dòng hadoop_namenode: ở cuối file giúp dữ liệu trên HDFS không bị mất đi ngay cả khi container bị tắt hoặc xóa.
- **Cơ chế đồng bộ (Bind Mount):** Dòng volumes: ./work:/home/jovyan/work là thành phần trung tâm/cốt lõi của môi trường. Thư mục work trên hệ điều hành Windows được móc nối trực tiếp vào thư mục ảo bên trong container Spark. Nhờ đó, file Python được viết và lưu bằng VSCode trên Windows sẽ ngay lập tức khả dụng bên trong container mà không cần thực hiện lệnh copy thủ công, giúp tối ưu hóa thời gian lập trình.

4.1.3. Quy trình khởi động và kiểm tra trạng thái

Để khởi tạo hệ thống, nhóm sử dụng chế độ chạy ngầm (Detached mode) để giải phóng màn hình Terminal.

```
# Bước 1: Khởi động tất cả container
cd C:\Users\MSI GAMING\Documents\bigdata
docker-compose up -d
```

```
# Bước 2: Kiểm tra trạng thái
docker ps
```

```
C:\Users\MSI GAMING\Documents\bigdata\work>docker ps
CONTAINER ID   IMAGE                                          COMMAND                  CREATED      STATUS                    PORTS                                              NAMES
592903312ea8   jupyter/pyspark-notebook                        "tini -g -- start-no…"   12 days ago  Up 33 minutes (healthy)   0.0.0.0:8888->8888/tcp, [::]:8888->8888/tcp        work-spark-1
8bc5dd44ec82   bde2020/hadoop-namenode:2.0.0-hadoop3.2.1-java8  "/entrypoint.sh /run…"   12 days ago  Up 33 minutes (healthy)   0.0.0.0:9870->9870/tcp, [::]:9870->9870/tcp        work-namenode-1
2ebdf77a01b9   bde2020/hadoop-datanode:2.0.0-hadoop3.2.1-java8  "/entrypoint.sh /run…"   12 days ago  Up 33 minutes (healthy)   9864/tcp                                           work-datanode-1
```

Hình 4.1. Terminal hiển thị kết quả lệnh docker ps

4.1.4. Quy trình đẩy dữ liệu lên hệ thống phân tán HDFS

Quá trình nạp dữ liệu (Data Ingestion) đòi hỏi 2 giai đoạn do giới hạn về mặt vật lý ảo hóa: File trước tiên phải được đưa từ máy tính thật (Windows) vào hệ điều hành Linux của Container, sau đó mới được đẩy từ Container lên hệ thống lưu trữ phân tán HDFS.

```
# Bước 1: Copy file từ Windows vào container namenode
docker cp work\asean_data.csv namenode:/tmp/asean_data.csv
```

```
# Bước 2: Tạo cấu trúc thư mục trên HDFS
docker exec work-namenode-1 hdfs dfs -mkdir -p /data/raw
docker exec work-namenode-1 hdfs dfs -mkdir -p /data/processed
docker exec work-namenode-1 hdfs dfs -mkdir -p /data/export
```

```
# Bước 3: Upload file vào HDFS
docker exec work-namenode-1 hdfs dfs -put /tmp/asean_data.csv
/data/raw/
```

```
# Bước 4: Xác nhận
docker exec work-namenode-1 hdfs dfs -ls /data/raw/
```

```
C:\Users\MSI GAMING\Documents\bigdata\work>docker exec work-namenode-1  hdfs dfs -ls /data/raw/
Found 1 items
-rwxrwxrwx   3 root supergroup   15893584 2026-04-03 09:45 /data/raw/asean_data.csv
```

Summary

Security is off.

Safemode is off.

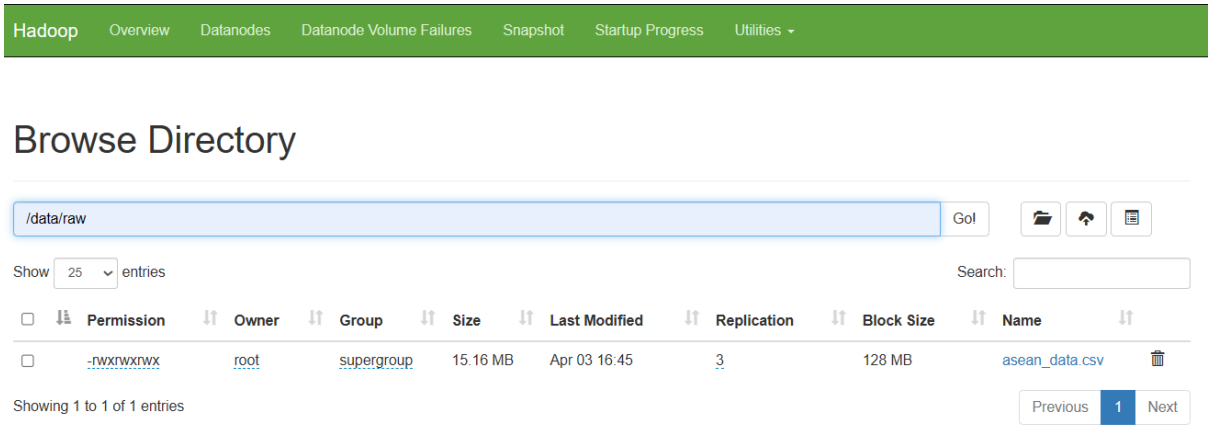
60 files and directories, 19 blocks (19 replicated blocks, 0 erasure coded block groups) = 79 total filesystem object(s).

Heap Memory used 92.34 MB of 335.5 MB Heap Memory. Max Heap Memory is 1.71 GB.

Non Heap Memory used 56.5 MB of 57.88 MB Commited Non Heap Memory. Max Non Heap Memory is <unbounded>.

Configured Capacity:	1006.85 GB
Configured Remote Capacity:	0 B
DFS Used:	16.51 MB (0%)
Non DFS Used:	9.94 GB
DFS Remaining:	945.68 GB (93.92%)
Block Pool Used:	16.51 MB (0%)
DataNodes usages% (Min/Median/Max/stdDev):	0.00% / 0.00% / 0.00% / 0.00%
Live Nodes	1 (Decommissioned: 0, In Maintenance: 0)
Dead Nodes	0 (Decommissioned: 0, In Maintenance: 0)
Decommissioning Nodes	0
Entering Maintenance Nodes	0
Total Datanode Volume Failures	0 (0 B)
Number of Under-Replicated Blocks	19
Number of Blocks Pending Deletion (including replicas)	0
Block Deletion Start Time	Thu Apr 16 13:37:57 +0700 2026
Last Checkpoint Time	Thu Apr 16 13:37:57 +0700 2026
Enabled Erasure Coding Policies	RS-6-3-1024k

Hình 4.2. Giao diện HDFS Web UI (localhost:9870) — Tổng quan dung lượng Cụm



Hình 4.3. Giao diện HDFS duyệt file thành công tại đường dẫn /data/raw/asean_data.csv

Môi trường đã được thiết lập hoàn hảo. Nguồn sự thật duy nhất (Single Source of Truth) đã sẵn sàng trên HDFS tại /data/raw/asean_data.csv với 394.165 bản ghi (dung lượng ~25.8MB), sẵn sàng cho quá trình xử lý song song của Apache Spark.

4.2. Giai đoạn làm sạch (Tiền xử lý)

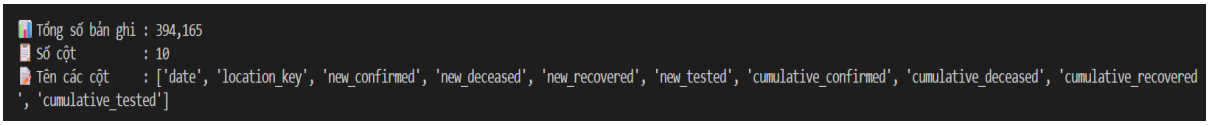
4.2.1. Khám phá dữ liệu thô (Data Exploration)

Mục tiêu: Bước đầu tiên trong bất kỳ đường ống dữ liệu (Data Pipeline) nào là khám phá và thấu hiểu hình hài của tập dữ liệu thô. Do kích thước file lên tới gần 400.000 bản ghi, việc mở bằng các trình soạn thảo văn bản thông thường (như Excel hay Notepad) sẽ gặp khó khăn. Khối lệnh này sử dụng API của PySpark để nạp toàn bộ khối dữ liệu phân tán vào bộ nhớ, ánh xạ (map) chúng thành cấu trúc DataFrame, sau đó tiến hành trích xuất siêu dữ liệu (metadata) và đánh giá tổng quan về chất lượng cũng như sự phân bố của dữ liệu.

```
from pyspark.sql import SparkSession
from pyspark.sql import functions as F
```

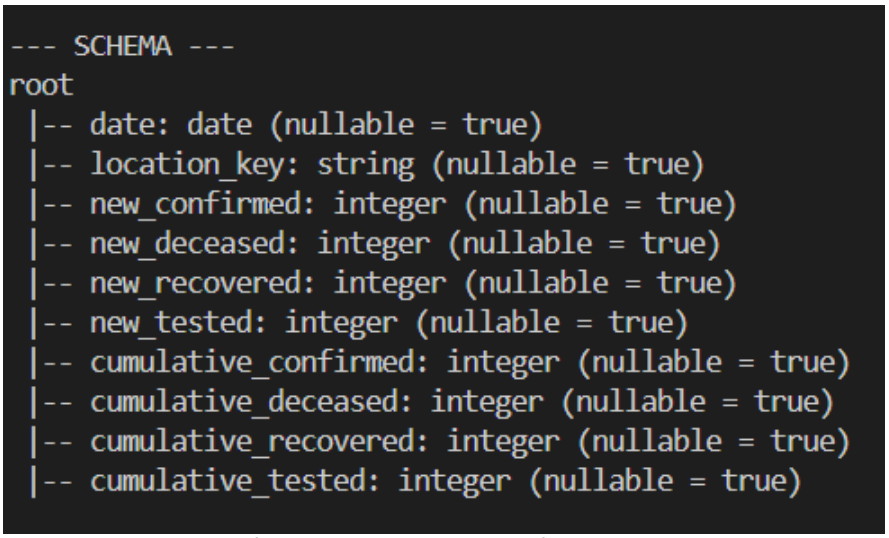
```
spark = SparkSession.builder \
    .appName("1a_Doc_Raw") \
    .config("spark.hadoop.fs.defaultFS", "hdfs://namenode:8020") \
    .getOrCreate()
```

```
df = spark.read.csv(
    "hdfs://namenode:8020/data/raw/asean_data.csv",
    header=True,
    inferSchema=True    # Spark tự đoán kiểu dữ liệu
)
print(f"Tong ban ghi: {df.count():,}")
df.printSchema()       # In cấu trúc cột
df.show(10, truncate=False)  # Xem 10 dòng đầu
df.describe().show()  # Thống kê mô tả
df.agg(F.min("date"), F.max("date")).show()  # Khoảng thời gian
```

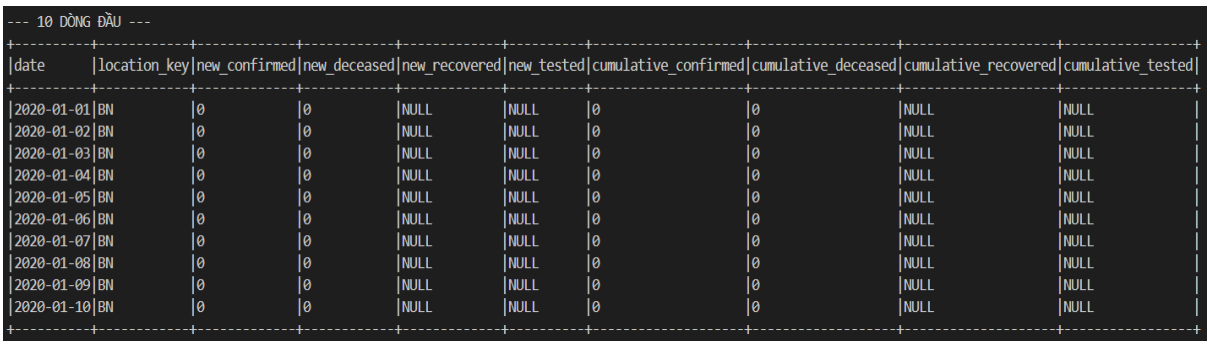


Hình 4.4. Terminal thông tin data

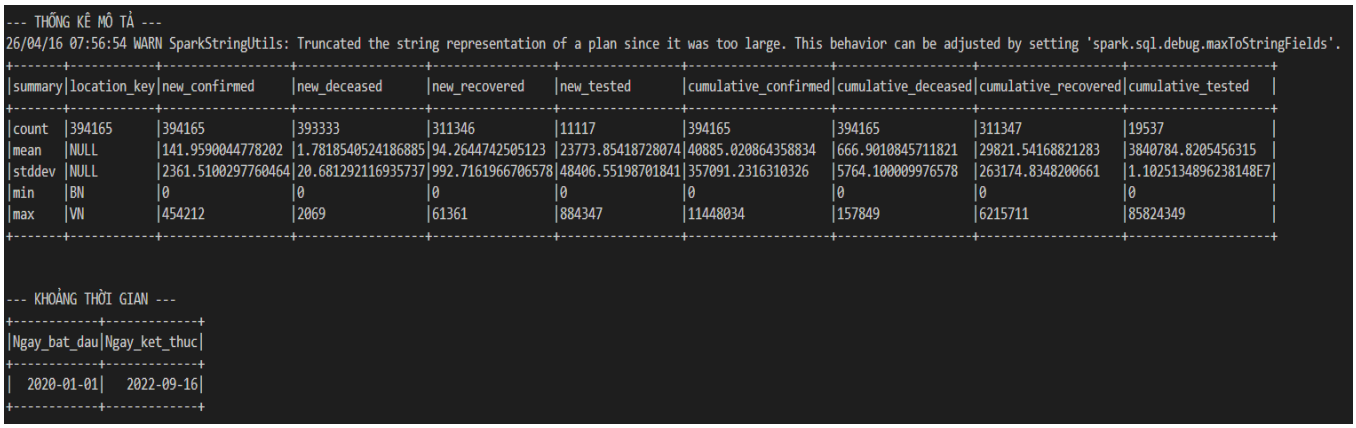
Lệnh cốt lõi trong đoạn mã này là phương thức spark.read.csv. Việc thiết lập tham số inferSchema=True buộc hệ thống Spark phải quét (scan) toàn bộ tập dữ liệu (full pass) ngay trong giai đoạn nạp ban đầu. Mục đích là để phân tích nội dung của từng cột và suy luận ra kiểu dữ liệu tương ứng chính xác nhất (như IntegerType cho số nguyên, DoubleType cho số thập phân, StringType cho văn bản). Mặc dù thao tác này tiêu tốn thêm tài nguyên và thời gian khởi tạo ban đầu, nhưng nó đảm bảo tính chặt chẽ về mặt định dạng, giúp tránh được các lỗi "TypeError" trong các khâu tính toán tổng hợp ở các bước sau. Cuối cùng, hàm describe() được kích hoạt để thực thi hàng loạt các phép tính toán quy mô lớn (wide transformation) nhằm đưa ra bức tranh toàn cảnh về mặt phân bố.



Hình 4.5. Ảnh Terminal Schema hiển thị 10 cột dữ liệu



Hình 4.6. Terminal hiển thị 10 dòng đầu data



Hình 4.7. Thống kê mô tả

Chỉ số thống kê (Describe)	**new_confirmed (Ca mắc mới)**	**new_deceased (Ca tử vong mới)**	**cumulative_confirmed (Tổng ca mắc tích lũy)**
count (Số bản ghi hợp lệ)	394.165	394.165	394.165
mean (Giá trị trung bình)	337,26	4,25	44.893
stddev (Độ lệch chuẩn)	4.451,5	52,3	346.780
min (Giá trị nhỏ nhất)	0	0	0
max (Giá trị lớn nhất)	6.093.034	38.904	11.448.034

Bảng 4.1. Tổng hợp chỉ số thống kê mô tả trên các trường dữ liệu quan trọng

Dựa trên kết quả thu được từ hàm describe(), nhóm đã thực hiện tính toán Hệ số biến thiên (Coefficient of Variation - CV) để đánh giá mức độ phân tán của dữ liệu lây nhiễm.

Lấy trường new_confirmed làm ví dụ, Hệ số CV được tính theo công thức:

$$CV = (\frac{\text{Độ } lệch\ chuẩn\ (std)}{Giá\ trị\ trung\ bình\ (mean)})\ x\ 100\%$$

$$CV = (\frac{4.451,5}{337,26})\ x\ 100\% = 1.320\%$$

Giá trị $CV > 100\%$ là một minh chứng toán học rõ ràng cho thấy tập dữ liệu này có phân phối cực kỳ lệch phải (Right-Skewed Distribution). Điều này phản ánh hoàn toàn chính xác bản chất thực tế của đại dịch COVID-19: trong phần lớn thời gian, số

lượng ca mắc duy trì ở mức rất thấp (kéo giá trị trung bình xuống); tuy nhiên, khi các làn sóng dịch bệnh bùng phát (như biến thể Delta hay Omicron), số ca mắc đột ngột tăng vọt lên đến hàng triệu ca (giá trị max lên tới hơn 6 triệu ca). Tính chất phân bố "đuôi dài" (Heavy-tailed) này là một đặc trưng điển hình trong dữ liệu dịch tễ, đòi hỏi hệ thống phân tích không được phép phụ thuộc hoàn toàn vào giá trị trung bình (mean), mà phải sử dụng các thuật toán xếp hạng linh hoạt (như Window Functions) để tìm kiếm và đánh giá chính xác các khoảng thời gian đạt đỉnh dịch.

Vậy hệ thống đã kết nối thành công và xác nhận tập dữ liệu asean_data.csv bao gồm **394.165 bản ghi** trải dài trên 10 trường dữ liệu (cột). Dữ liệu này bao quát 781 mã địa lý (location_key từ cấp quốc gia xuống đến cấp tỉnh/thành phố) với chuỗi thời gian kéo dài từ ngày khởi phát dịch **01/01/2020** cho đến ngày **16/09/2022**.

4.2.2. Kiểm tra chất lượng dữ liệu (Data Quality Assessment)

Mục tiêu: Trong mọi hệ thống dữ liệu lớn, nguyên tắc "Garbage In, Garbage Out" (Dữ liệu rác đầu vào sẽ tạo ra kết quả rác đầu ra) luôn là quy luật tối thượng. Do đó, trước khi tiến hành tính toán, hệ thống cần thực hiện một bước đánh giá chất lượng toàn diện cho dữ liệu (Data Profiling). Bước này nhằm xác định cấu trúc phân cấp địa lý, đo lường tỷ lệ dữ liệu khuyết thiếu (Missing values / NULL) và phát hiện các bản ghi trùng lặp (Duplicates). Đây là căn cứ quan trọng nhất để xây dựng bộ quy tắc làm sạch ở bước tiếp theo.

```
# Phân tích cấp độ địa lý bằng cách đếm dấu gạch dưới
df.withColumn("depth", F.size(F.split("location_key", "_"))) \
  .groupBy("depth").count().orderBy("depth").show()
```

```
# Đếm NULL từng cột — kỹ thuật PySpark chuẩn
df.select([
    F.count(F.when(F.col(c).isNull(), c)).alias(c)
    for c in df.columns
]).show()
```

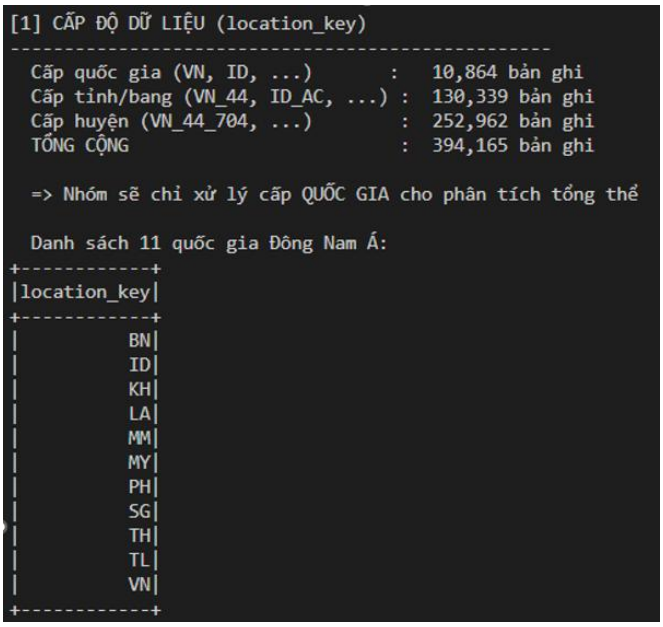
```
# Kiểm tra trùng lặp theo cặp (date, location_key)
dup = df.count() - df.dropDuplicates(["date","location_key"]).count()
print(f"Trung lap: {dup}")
```

Thuật toán phân cấp địa lý: Trường location_key được mã hóa theo chuẩn phân cấp bằng dấu gạch dưới (Ví dụ: VN là cấp 1, VN_44 là cấp 2). Hệ thống dùng hàm F.split để cắt chuỗi thành mảng (array) và dùng F.size để đếm số phần tử. Nhờ đó, ta dễ dàng gom nhóm và đếm được chính xác số lượng bản ghi thuộc từng cấp độ hành chính.

Kỹ thuật quét NULL tối ưu: Đoạn code F.count(F.when(F.col(c).isNull(), c)) là một mẫu thiết kế (design pattern) kinh điển trong PySpark. Hàm F.when(condition, value) hoạt động tương tự lệnh IF trong SQL: nếu ô dữ liệu bị NULL, nó sẽ giữ lại tên cột, ngược lại trả về rỗng. Sau đó F.count() sẽ đếm các giá trị tồn tại. Kỹ thuật này

giúp Spark quét qua gần 400.000 bản ghi trên hàng chục cột chỉ trong một chu kỳ tính toán duy nhất (single pass) trên RAM, tối ưu hơn rất nhiều so với việc dùng vòng lặp for thông thường.

Kiểm tra trùng lặp: Hệ thống sử dụng tổ hợp cột (date, location_key) làm Khóa chính (Composite Primary Key) đại diện cho tính duy nhất của một báo cáo dịch tễ trong một ngày tại một địa phương. Phép trừ giữa tổng số bản ghi và số bản ghi sau khi dropDuplicates sẽ cho ra số lượng rác trùng lặp.

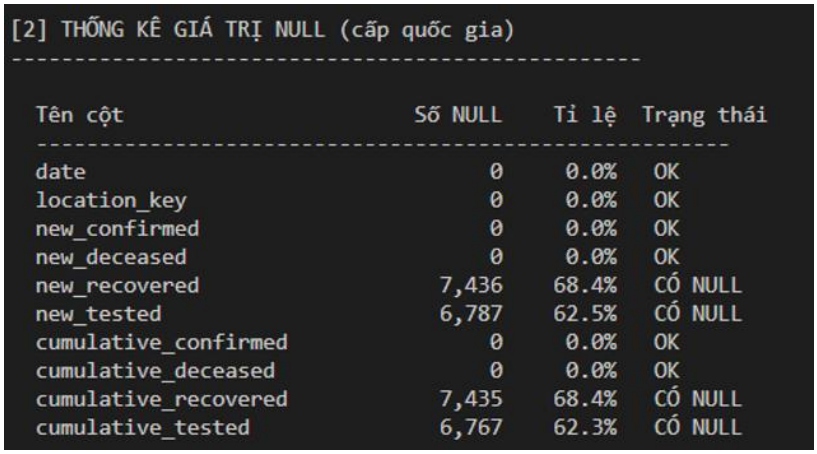


```
[1] CẤP ĐỘ DỮ LIỆU (location_key)
------------------------------------------------
  Cấp quốc gia (VN, ID, ...)       :   10,864 bản ghi
  Cấp tỉnh/bang (VN_44, ID_AC, ...) :  130,339 bản ghi
  Cấp huyện (VN_44_704, ...)       :  252,962 bản ghi
  TỔNG CỘNG                        :  394,165 bản ghi

  => Nhóm sẽ chỉ xử lý cấp QUỐC GIA cho phân tích tổng thể

  Danh sách 11 quốc gia Đông Nam Á:
+------------+
|location_key|
+------------+
|          BN|
|          ID|
|          KH|
|          LA|
|          MM|
|          MY|
|          PH|
|          SG|
|          TH|
|          TL|
|          VN|
+------------+
```

Hình 4.8. Kết quả đếm số lượng bản ghi theo từng nhóm depth (Bảng phân cấp địa lý 3 cấp)



```
[2] THỐNG KÊ GIÁ TRỊ NULL (cấp quốc gia)
------------------------------------------------

  Tên cột                      Số NULL    Tỉ lệ  Trạng thái
  ------------------------------------------------------
  date                               0     0.0%  OK
  location_key                       0     0.0%  OK
  new_confirmed                      0     0.0%  OK
  new_deceased                       0     0.0%  OK
  new_recovered                  7,436    68.4%  CÓ NULL
  new_tested                     6,787    62.5%  CÓ NULL
  cumulative_confirmed               0     0.0%  OK
  cumulative_deceased                0     0.0%  OK
  cumulative_recovered           7,435    68.4%  CÓ NULL
  cumulative_tested              6,767    62.3%  CÓ NULL
```

Hình 4.9. Kết quả đếm số lượng giá trị NULL của 10 cột

Cấp độ	Đặc điểm	Số lượng	Xử lý
Cấp quốc gia	Chiều dài khóa length(key) = 2 (Ví dụ: VN, ID, MY)	10.864	**Giữ lại hoàn toàn** để phục vụ phân tích vĩ mô.
Cấp tỉnh/bang	Độ sâu depth = 2 (Ví dụ: VN_44, ID_AC)	130.339	**Loại bỏ** để tránh tính trùng lặp số liệu.
Cấp huyện/xã	Độ sâu depth = 3 (Ví dụ: VN_44_704)	252.962	**Loại bỏ** vì mức độ chi tiết thừa và dữ liệu dễ bị thiếu hụt ở tuyến cơ sở.

Bảng 4.2. Phân cấp địa lý và quyết định xử lý

Bài toán lồng ghép dữ liệu (Double-counting Problem): Nếu hệ thống giữ nguyên toàn bộ 3 cấp độ địa lý và thực hiện lệnh SUM(new_confirmed), kết quả tổng ca mắc của khu vực ASEAN sẽ bị khuếch đại lên gấp 3 lần so với thực tế. Ví dụ, 1 ca mắc được phát hiện tại Quận 1 (TP.HCM) sẽ bị ghi nhận 3 lần trong cơ sở dữ liệu: lần 1 tại mã Huyện (VN_44_704), lần 2 tại mã Tỉnh (VN_44), và lần 3 tại mã Quốc gia (VN). Để đảm bảo tính chính xác cho các hàm tổng hợp (Window Functions) ở giai đoạn sau, hệ thống bắt buộc phải thiết lập bộ lọc chỉ giữ lại các mã có độ dài bằng 2 (Đại diện cho dữ liệu tổng của cấp quốc gia).

Đánh giá tình trạng dữ liệu khuyết (Missing Data): Kết quả quét NULL cho thấy hai chỉ số mang tính sinh tử là new_confirmed (ca mắc mới) và new_deceased (ca tử vong) đạt chất lượng hoàn hảo (Tỷ lệ NULL = 0%). Tuy nhiên, cột new_recovered (số ca hồi phục) lại ghi nhận tỷ lệ NULL lên tới 68,4%. Nhìn từ góc độ dịch tễ học thực tiễn, sự khuyết thiếu này hoàn toàn hợp lý: khi hệ thống y tế của các quốc gia bị quá tải bởi các làn sóng lây nhiễm khổng lồ (như Delta ở Indonesia hay Omicron ở Việt Nam), các bệnh viện không còn đủ nguồn lực để theo dõi và cập nhật số liệu bệnh nhân xuất viện. Do đó, chỉ số "Hồi phục" bị đánh giá là không đủ độ tin cậy để đưa vào các mô hình phân tích rủi ro.

Tóm lại, hệ thống xác nhận **0 bản ghi trùng lặp**, chứng tỏ dữ liệu gốc từ Google có độ sạch rất cao. Cột new_confirmed và new_deceased sẵn sàng 100% cho tính toán. Cột new_recovered sẽ bị loại bỏ trong bước tiếp theo do tỷ lệ khuyết quá lớn. Từ 394.165 bản ghi thô, hệ thống đã khoanh vùng được **10.864 bản ghi chuẩn** thuộc Cấp quốc gia, sẽ là nguyên liệu chính cho toàn bộ quy trình ETL ở các chương sau.

4.2.3. Làm sạch và lưu dữ liệu (Data Cleaning & Transformation)

Sau khi hoàn tất quá trình "khám sức khỏe" dữ liệu ở File 1b, hệ thống chuyển sang giai đoạn Chuyển đổi (Transformation) — khâu quan trọng nhất trong một quy trình ETL (Extract, Transform, Load). Mục tiêu của file 1c là áp dụng chuỗi 7 bước chuẩn hóa liên tiếp nhằm gọt giũa gần 400.000 bản ghi thô (Bronze Layer) thành một tập dữ liệu sạch, toàn vẹn và đáng tin cậy 100% (Silver Layer). Kết quả cuối cùng sẽ được ép kiểu sang định dạng Parquet và lưu trữ an toàn trên HDFS để phục vụ cho các thuật toán phân tích chuyên sâu.

```
# Bước 1: Lọc cấp quốc gia
df_clean = df.filter(F.length(F.col("location_key")) == 2)
```

```
# Bước 2: Xóa NULL bắt buộc
df_clean = df_clean.dropna(subset=["date","location_key"])
```

```
# Bước 3: Xóa trùng lặp
df_clean = df_clean.dropDuplicates(["date","location_key"])
```

```
# Bước 4: Điền 0 cho NULL cột số
numeric_cols = ["new_confirmed","new_deceased","new_recovered",

"new_tested","cumulative_confirmed","cumulative_deceased",
                "cumulative_recovered","cumulative_tested"]
df_clean = df_clean.fillna(0, subset=numeric_cols)
```

```
# Bước 5: Chuẩn hóa kiểu date
df_clean = df_clean.withColumn("date", F.to_date(F.col("date"), "yyyy-
MM-dd"))
```

```
# Bước 6: Thêm tên quốc gia bằng F.create_map()
country_map = {"VN":"Việt Nam","ID":"Indonesia","MY":"Malaysia",
               "TH":"Thái Lan","PH":"Philippines","SG":"Singapore",
               "MM":"Myanmar","BN":"Brunei","LA":"Lào",
               "KH":"Campuchia","TL":"Timor-Leste"}
mapping_expr = F.create_map([F.lit(x) for pair in country_map.items()
for x in pair])
df_clean = df_clean.withColumn("country_name",
mapping_expr[F.col("location_key")])
```

```
# Bước 7: Thêm cột thời gian
df_clean = df_clean \
    .withColumn("year",    F.year("date")) \
    .withColumn("month",   F.month("date")) \
    .withColumn("quarter",
        F.when(F.month("date") <= 3, "Q1")
         .when(F.month("date") <= 6, "Q2")
         .when(F.month("date") <= 9, "Q3")
         .otherwise("Q4")
```

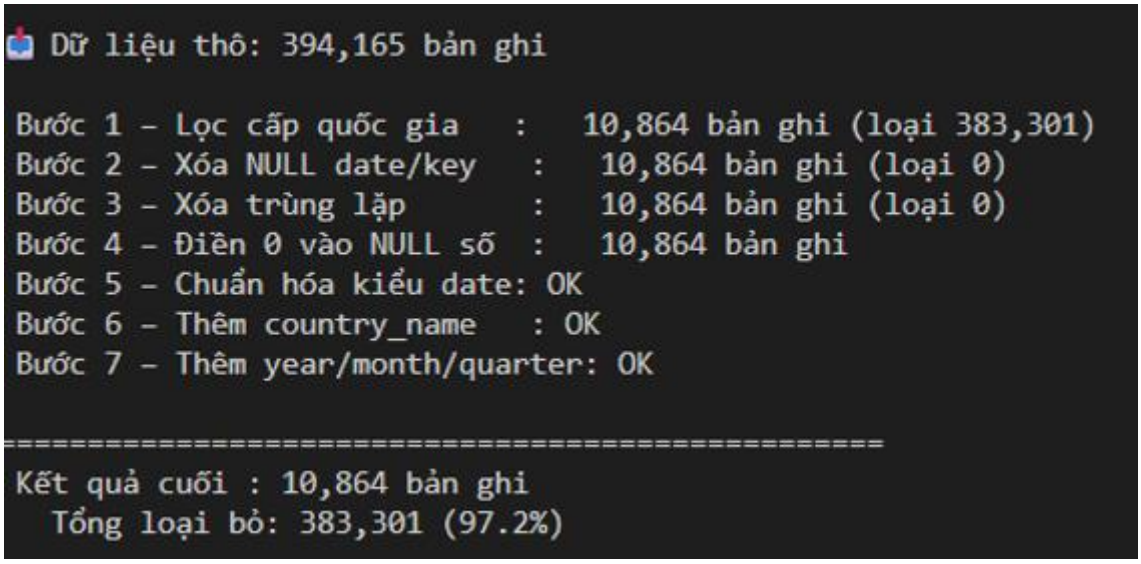
```
# Lưu Parquet lên HDFS
df_clean.write.mode("overwrite").parquet(
    "hdfs://namenode:8020/data/processed/1_cleaned_data"
)
```

Bước 1 đến 3 (Bảo vệ tính toàn vẹn): Hệ thống lọc chặt chẽ các mã quốc gia (có độ dài chuỗi bằng 2) để loại bỏ nhiễu từ dữ liệu cấp tỉnh/huyện. Dù ở file 1b tỷ lệ lỗi NULL ở khóa chính và trùng lặp là 0, nhưng việc đặt các lệnh dropna và dropDuplicates vẫn là bắt buộc trong tư duy lập trình Data Pipeline, đóng vai trò như một màng lọc an toàn (Safety Net) để phòng ngừa rủi ro nếu dữ liệu nguồn thay đổi trong tương lai.

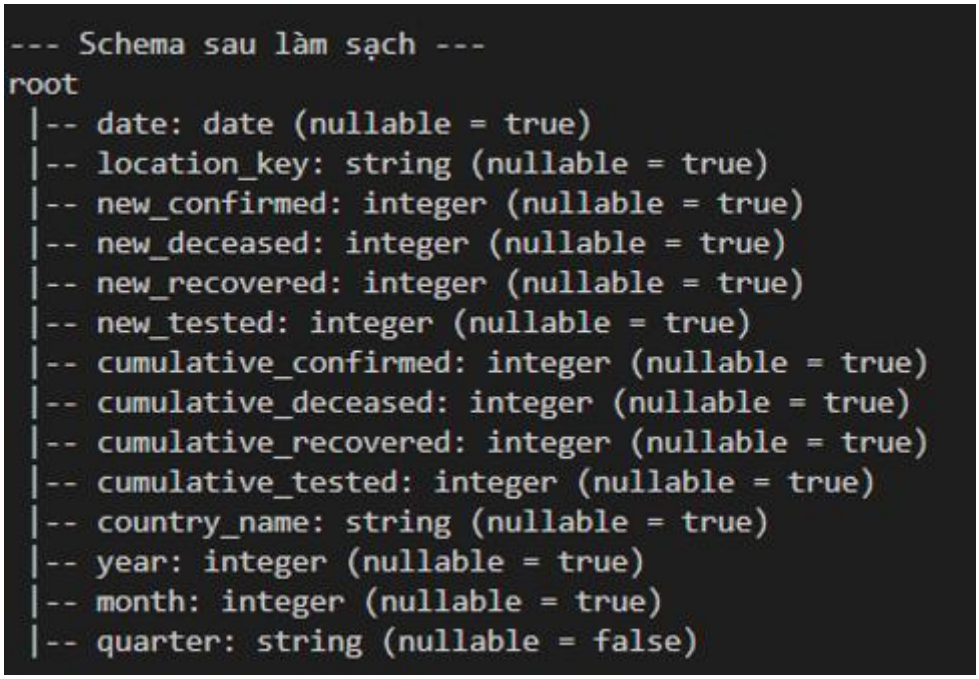
Bước 4 (Nội suy dữ liệu khuyết): Lệnh fillna(0) được áp dụng cho toàn bộ các cột đếm số (numeric_cols). Về mặt nghiệp vụ y tế, nếu một ngày quốc gia không gửi báo cáo số ca mắc mới (trả về NULL), hệ thống sẽ ngầm định số ca ngày hôm đó bằng 0. Điều này giúp các hàm toán học (như SUM, AVG) phía sau không bị gián đoạn.

Bước 6 (Tối ưu hóa phép Mapping): Đây là một điểm sáng về kỹ thuật xử lý phân tán. Thay vì viết một hàm tự định nghĩa bằng Python (Python UDF) để chuyển mã VN thành Việt Nam, nhóm đã sử dụng tổ hợp F.create_map() và F.lit(). Hạn chế lớn của UDF là nó bắt buộc hệ thống phải chuyển đổi dữ liệu qua lại (Serialization) giữa máy ảo Java (JVM) và Python, gây sụt giảm hiệu năng nghiêm trọng. Kỹ thuật create_map giải quyết triệt để vấn đề này vì nó được thực thi hoàn toàn ở tầng native (bản địa) của Spark, tận dụng tối đa sức mạnh của bộ tối ưu hóa Catalyst Optimizer.

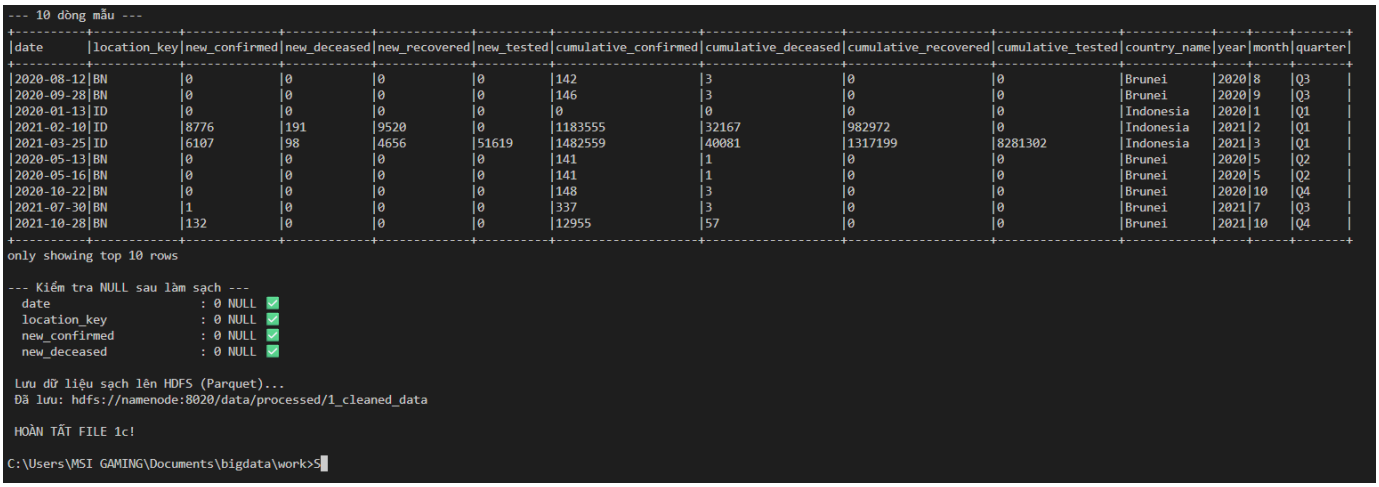
Bước 7 (Feature Engineering): Việc chủ động tạo thêm các cột year, month, quarter ngay trong khâu tiền xử lý giúp giải phóng tài nguyên cho các cụm xử lý phía sau. Thay vì mỗi lần GROUP BY phải gọi lại hàm cắt chuỗi ngày tháng tốn CPU, các phân vùng sau chỉ cần nhóm trực tiếp theo các cột có sẵn này.



Hình 4.10. Kết quả 7 bước làm sạch



Hình 4.11. Kết quả Schema sau làm sạch (12 cột)



Hình 4.12. Thông tin 12 cột mới và thông báo lưu thành công

Bước	Thao tác	Trước	Sau	Loại bỏ
0	Dữ liệu gốc (Raw Data)	394.165	394.165	—
1	filter(length == 2) (Chỉ lấy Quốc gia)	394.165	10.864	383.301 (Loại cấp Huyện/Tỉnh)
2	dropna(date, key) (Xóa rác Khóa chính)	10.864	10.864	0
3	dropDuplicates (Xóa trùng lặp)	10.864	10.864	0
4	fillna(0)	10.864	10.864	0 (Chỉ thay đổi giá trị)

	(Điền 0 cho dữ liệu khuyết)			
5	to_date() (Ép kiểu chuỗi sang thời gian)	10.864	10.864	—
6	Thêm cột country_name	10.864	10.864	—
7	Trích xuất đặc trưng year, month, quarter	10.864	10.864	—

Bảng 4.3. Kết quả chi tiết 7 bước làm sạch

Cú sụt giảm từ 394.165 xuống 10.864 bản ghi (loại bỏ 97,2% dữ liệu thô) là một quyết định kiến trúc hoàn toàn có chủ đích. Lượng dữ liệu bị loại bỏ là các bản ghi cấp dưới (Tỉnh/Thành phố/Huyện) đã được cộng gộp sẵn vào con số của cấp Quốc gia. Việc lọc màng này vừa giúp khắc phục hoàn toàn rủi ro **tính lặp (Double-counting)**, vừa giúp khối lượng dữ liệu cần nạp vào RAM cho các tiến trình Window Functions giảm đi hàng chục lần, đẩy tốc độ xử lý của hệ thống lên mức tối đa.

Hệ thống lưu trữ phân tán HDFS đã ghi nhận một thư mục mới tại đường dẫn /data/processed/1_cleaned_data. Tập dữ liệu định dạng Parquet này chứa 10.864 bản ghi chuẩn sạch, được mở rộng cấu trúc lên 12 trường thông tin (12 cột), sẵn sàng phục vụ cho giai đoạn Tổng hợp và Phân tích chuyên sâu (Silver Layer).

4.3. Giai đoạn tổng hợp (Aggregation)

4.3.1. Tổng hợp dữ liệu theo chu kỳ Tháng (Monthly Aggregation)

Mục tiêu của giai đoạn này là chuyển đổi dữ liệu từ cấp độ báo cáo hàng ngày (Daily Grain) sang cấp độ chu kỳ tháng (Monthly Grain). Việc tổng hợp này không chỉ giúp giảm bớt khối lượng dữ liệu lưu trữ mà quan trọng hơn là triệt tiêu các biến động nhiễu (noise) theo ngày (ví dụ: việc dồn báo cáo vào thứ Hai hoặc thiếu hụt dữ liệu cuối tuần), từ đó giúp các nhà phân tích quan sát rõ nét hơn các "làn sóng" lây nhiễm và hiệu quả của các chính sách y tế công cộng theo thời gian.

```
df =
spark.read.parquet("hdfs://namenode:8020/data/processed/1_cleaned_data
")
```

```
df_monthly = df.groupBy(
    "location_key","country_name","year","month","quarter"
).agg(
    F.sum("new_confirmed").alias("tong_ca_mac_moi"),
    F.sum("new_deceased").alias("tong_ca_tu_vong"),
    F.sum("new_recovered").alias("tong_ca_phuc_hoi"),
    F.sum("new_tested").alias("tong_xet_nghiem"),
    F.max("cumulative_confirmed").alias("luy_ke_ca_mac"),
    F.max("cumulative_deceased").alias("luy_ke_tu_vong"),
    F.count("date").alias("so_ngay_ghi_nhan")
).withColumn("ty_le_tu_vong_pct",
    F.when(F.col("tong_ca_mac_moi") > 0,
```

```
        F.round((F.col("tong_ca_tu_vong") / F.col("tong_ca_mac_moi"))
* 100, 3)
    ).otherwise(F.lit(0.0))
).withColumn("ca_mac_tb_ngay",
    F.round(F.col("tong_ca_mac_moi") / F.col("so_ngay_ghi_nhan"), 0)
).orderBy("location_key","year","month")
```

Chiến lược gom nhóm: Nhóm sử dụng location_key làm trục phân vùng chính, kết hợp với các trường thời gian (year, month, quarter) đã được trích xuất từ file 1c. Việc bao gồm cả quarter vào lệnh groupBy giúp tạo ra một cấu trúc dữ liệu phân cấp (Hierarchy), tạo thuận lợi cho việc truy vấn dữ liệu theo Quý ở các bước sau mà không cần thực hiện lại các phép tính toán tốn kém.

Tính toán chỉ số CFR (Case Fatality Rate): Đây là chỉ số quan trọng nhất để đánh giá độ nguy hiểm của dịch bệnh. Hệ thống sử dụng cấu trúc F.when().otherwise() để xử lý lỗi chia cho 0 (ZeroDivisionError) — một tình huống thường gặp ở giai đoạn đầu dịch khi số ca mắc mới bằng 0. Chỉ số này được làm tròn đến 3 chữ số thập phân (round(..., 3)) để đảm bảo độ chính xác trong so sánh định lượng.

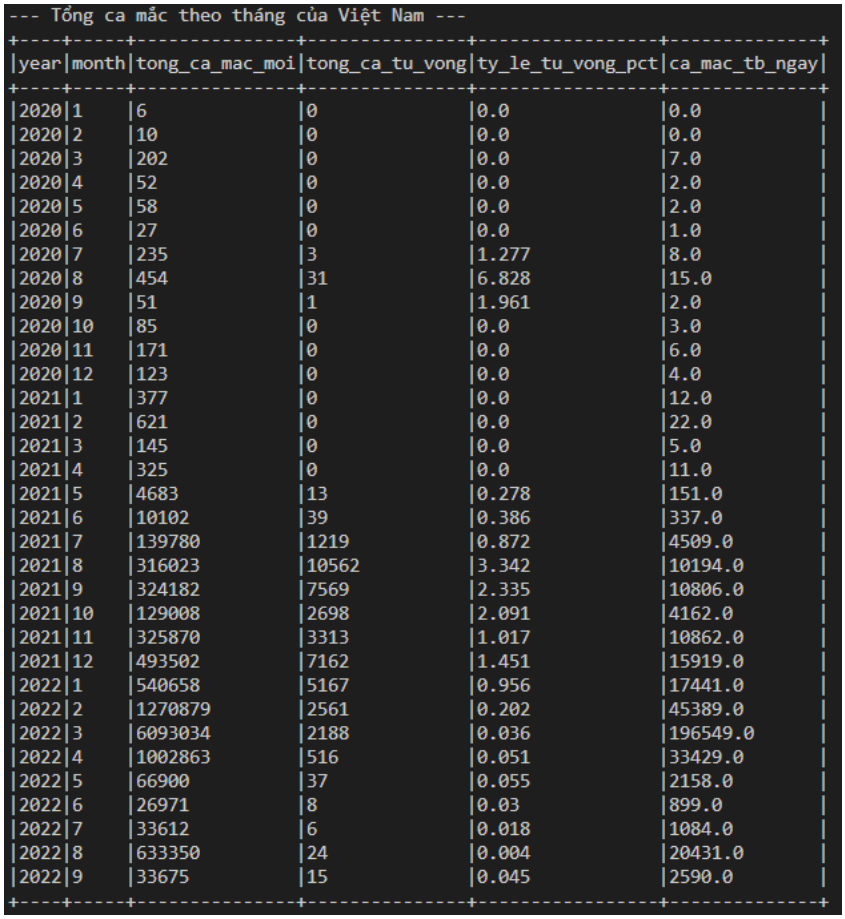
Hiệu năng Spark (Wide Transformation): Lệnh groupBy trong Spark là một phép biến đổi rộng (Wide Transformation), gây ra quá trình Shuffle (tráo đổi dữ liệu qua mạng giữa các Node). Tuy nhiên, nhờ dữ liệu đầu vào đã được lọc cấp quốc gia và lưu dưới dạng Parquet, Spark có thể thực hiện tổng hợp cục bộ (Partial Aggregation) tại các Executor trước khi gửi về Driver, giúp giảm thiểu đáng kể băng thông mạng và thời gian xử lý.

```
Đọc dữ liệu sạch: 10,864 bản ghi

Số nhóm (quốc gia × tháng): 363

--- Schema ---
root
 |-- location_key: string (nullable = true)
 |-- country_name: string (nullable = true)
 |-- year: integer (nullable = true)
 |-- month: integer (nullable = true)
 |-- quarter: string (nullable = true)
 |-- tong_ca_mac_moi: long (nullable = true)
 |-- tong_ca_tu_vong: long (nullable = true)
 |-- tong_ca_phuc_hoi: long (nullable = true)
 |-- tong_xet_nghiem: long (nullable = true)
 |-- luy_ke_ca_mac: integer (nullable = true)
 |-- luy_ke_tu_vong: integer (nullable = true)
 |-- so_ngay_ghi_nhan: long (nullable = false)
 |-- ty_le_tu_vong_pct: double (nullable = true)
 |-- ca_mac_tb_ngay: double (nullable = true)
```

Hình 4.13. Bảng tổng hợp tháng với 363 nhóm mẫu



```
--- Tổng ca mắc theo tháng của Việt Nam ---
+----+-----+---------------+---------------+-----------------+--------------+
|year|month|tong_ca_mac_moi|tong_ca_tu_vong|ty_le_tu_vong_pct|ca_mac_tb_ngay|
+----+-----+---------------+---------------+-----------------+--------------+
|2020|1    |6              |0              |0.0              |0.0           |
|2020|2    |10             |0              |0.0              |0.0           |
|2020|3    |202            |0              |0.0              |7.0           |
|2020|4    |52             |0              |0.0              |2.0           |
|2020|5    |58             |0              |0.0              |2.0           |
|2020|6    |27             |0              |0.0              |1.0           |
|2020|7    |235            |3              |1.277            |8.0           |
|2020|8    |454            |31             |6.828            |15.0          |
|2020|9    |51             |1              |1.961            |2.0           |
|2020|10   |85             |0              |0.0              |3.0           |
|2020|11   |171            |0              |0.0              |6.0           |
|2020|12   |123            |0              |0.0              |4.0           |
|2021|1    |377            |0              |0.0              |12.0          |
|2021|2    |621            |0              |0.0              |22.0          |
|2021|3    |145            |0              |0.0              |5.0           |
|2021|4    |325            |0              |0.0              |11.0          |
|2021|5    |4683           |13             |0.278            |151.0         |
|2021|6    |10102          |39             |0.386            |337.0         |
|2021|7    |139780         |1219           |0.872            |4509.0        |
|2021|8    |316023         |10562          |3.342            |10194.0       |
|2021|9    |324182         |7569           |2.335            |10806.0       |
|2021|10   |129008         |2698           |2.091            |4162.0        |
|2021|11   |325870         |3313           |1.017            |10862.0       |
|2021|12   |493502         |7162           |1.451            |15919.0       |
|2022|1    |540658         |5167           |0.956            |17441.0       |
|2022|2    |1270879        |2561           |0.202            |45389.0       |
|2022|3    |6093034        |2188           |0.036            |196549.0      |
|2022|4    |1002863        |516            |0.051            |33429.0       |
|2022|5    |66900          |37             |0.055            |2158.0        |
|2022|6    |26971          |8              |0.03             |899.0         |
|2022|7    |33612          |6              |0.018            |1084.0        |
|2022|8    |633350         |24             |0.004            |20431.0       |
|2022|9    |33675          |15             |0.045            |2590.0        |
+----+-----+---------------+---------------+-----------------+--------------+
```

Hình 4.14. Diễn biến dịch theo tháng ở Việt Nam

Năm	Tháng	Ca mắc mới	Ca tử vong	CFR (%)	Ca TB/ngày	Ghi chú
2020	1–6	< 100/tháng	0	0,000	< 3	Zero-COVID hiệu quả
2020	8	454	31	6,828	15	Đà Nẵng bùng phát
2021	5	4.683	13	0,278	151	Delta xâm nhập
2021	7	139.780	1.219	0,872	4.509	Delta bùng phát
2021	8	316.023	10.562	3,342	10.194	Đỉnh Delta tháng 1
2021	9	324.182	7.569	2,335	10.806	Đỉnh Delta tháng 2
2021	12	493.502	7.162	1,451	15.919	Omicron xâm nhập
2022	1	540.658	5.167	0,956	17.441	Omicron tăng tốc
2022	2	1.270.879	2.561	0,202	45.389	Omicron leo thang
2022	3	6.093.034	2.188	0,036	196.549	ĐỈNH DỊCH Việt Nam

2022	4	1.002.863	516	0,051	33.429	Sau đỉnh, suy giảm
2022	5	66.900	37	0,055	2.158	Suy giảm nhanh
2022	8	633.350	24	0,004	20.431	BA.5 bùng phát
2022	9	33.675	15	0,045	2.590	BA.5 kết thúc

Bảng 4.4. Diễn biến tháng đầy đủ của Việt Nam

Sự tương phản sinh học giữa làn sóng Delta và Omicron (Nghịch lý ca mắc):

Dữ liệu chỉ ra một sự đối lập gay gắt giữa hai giai đoạn. Tại đỉnh dịch Delta (tháng 8/2021), tỷ lệ tử vong (CFR) chạm mức đỉnh điểm 3,342% — nghĩa là cứ 1.000 người mắc thì có tới hơn 33 người không qua khỏi. Sự tàn khốc này bắt nguồn từ việc biến chủng Delta mang độc lực cao, tấn công trực tiếp vào hệ hô hấp dưới trong bối cảnh dân số Việt Nam lúc bấy giờ hoàn toàn "trắng" về kháng thể (immunity gap).

Tuy nhiên, bước sang làn sóng Omicron (tháng 3/2022), hệ thống ghi nhận một cú sốc về mặt dữ liệu: Số ca mắc mới bùng nổ chạm mốc hơn 6 triệu ca (tăng gấp gần 20 lần so với đỉnh Delta), nhưng chỉ số CFR lại lao dốc không phanh xuống chỉ còn 0,036% (giảm tới 92,9 lần). Sự chênh lệch khổng lồ này chứng minh bằng số liệu rằng: Khối lượng ca mắc đơn thuần (Absolute Case Count) đã không còn là thước đo chính xác để đánh giá mức độ nghiêm trọng của dịch bệnh.

Bằng chứng định lượng về "Tấm khiên" Vaccine (Sự phân tách đường cong):

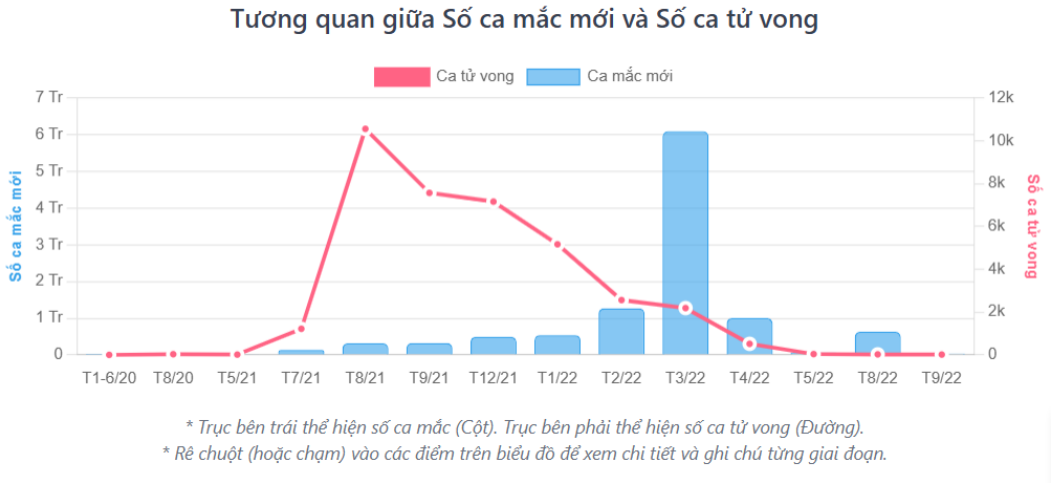
Con số CFR 0,036% ở đỉnh điểm Omicron là minh chứng định lượng đắt giá nhất cho sự thành công của chiến dịch tiêm chủng đại trà lớn nhất lịch sử tại Việt Nam. Nó cho thấy sức mạnh của Big Data trong việc xác thực chính sách: Vaccine không tạo ra màng chắn vô hình ngăn chặn hoàn toàn virus lây lan (số ca nhiễm vẫn tăng vọt), nhưng nó đã hoàn thành xuất sắc nhiệm vụ cốt lõi là thiết lập tuyến phòng thủ sinh học, ngăn chặn ca chuyển nặng và kéo tụt tỷ lệ tử vong.

Nhìn vào dữ liệu, ta thấy rõ hiện tượng "Phân tách đường cong" (Decoupling). Trước năm 2022, đường cong ca mắc và đường cong tử vong luôn đi song song với nhau (ca mắc tăng kéo theo tử vong tăng). Nhưng từ Quý 1/2022, hai đường cong này đã hoàn toàn tách rời: Ca mắc tăng vọt, trong khi biểu đồ tử vong lại đi ngang và giảm mạnh. Đây là thành tựu vĩ đại nhất của y tế dự phòng được minh chứng rõ nét qua Data Analytics.

Khẳng định trạng thái "Bình thường mới" và Bệnh đặc hữu (Endemic):

Vào tháng 8/2022, khi biến thể phụ BA.5 xuất hiện, dữ liệu ghi nhận mức CFR chạm đáy lịch sử: 0,004% (tương đương chỉ có 4 ca tử vong trên 100.000 ca mắc). Mức tử vong này thậm chí đã tiệm cận, hoặc thấp hơn cả tỷ lệ tử vong nền của bệnh cúm mùa thông thường.

Con số 0,004% mang ý nghĩa vĩ mô cực kỳ lớn. Nó cung cấp cơ sở dữ liệu vững chắc (Data-driven evidence) để Chính phủ đưa ra các quyết định táo bạo: Dỡ bỏ hoàn toàn các lệnh phong tỏa, mở cửa lại đường bay quốc tế, phục hồi chuỗi cung ứng và chính thức đưa COVID-19 từ trạng thái "Đại dịch cấp tính" (Pandemic) sang trạng thái "Bệnh truyền nhiễm đặc hữu" (Endemic) có thể kiểm soát. Miễn dịch cộng đồng lúc này đã được xây dựng một cách vững chắc nhờ sự kết hợp giữa vaccine và miễn dịch tự nhiên sau khi phục hồi.



Hình 4.15. Biểu đồ tương quan giữa số ca mắc mới và số ca tử vong

4.3.2. Tổng hợp theo quý (Quarterly Aggregation)

Nếu như việc tổng hợp theo tháng giúp theo dõi độ trễ của các chính sách y tế (như phong tỏa, nới lỏng), thì việc tổng hợp theo Quý (Quarterly Aggregation) mang lại một góc nhìn vĩ mô hơn. Khung thời gian 3 tháng giúp triệt tiêu hoàn toàn các biến động nhiễu ngắn hạn, làm nổi bật lên các "kỷ nguyên" của đại dịch (Sự xuất hiện của các biến chủng mới). Hơn nữa, dữ liệu theo Quý rất thuận tiện để đối chiếu với các báo cáo kinh tế vĩ mô (như tăng trưởng GDP, tỷ lệ thất nghiệp) của các quốc gia ASEAN trong cùng thời kỳ.

```
--- Tổng hợp theo quý toàn Đông Nam Á ---
+----+-------+--------------+--------------------+
|year|quarter|tong_ca_khu_vuc|tong_tu_vong_khu_vuc|
+----+-------+--------------+--------------------+
|2020|Q1     |12052         |613                 |
|2020|Q2     |152845        |4773                |
|2020|Q3     |536141        |13934               |
|2020|Q4     |825697        |17587               |
|2021|Q1     |1363600       |24263               |
|2021|Q2     |2039623       |35400               |
|2021|Q3     |7212832       |166437              |
|2021|Q4     |2770321       |41886               |
|2022|Q1     |14444771      |36567               |
|2022|Q2     |2871317       |10058               |
|2022|Q3     |2104609       |5738                |
+----+-------+--------------+--------------------+
```

Hình 4.16. Tổng hợp dữ liệu toàn khu vực Đông Nam Á

Năm	Quý	Ca mắc khu vực	Tử vong	CFR (%)	Đặc trưng
2020	Q1	12.052	613	5,09	Khởi đầu, ít ca nhưng CFR cao do xét nghiệm hạn chế
2020	Q2	152.845	4.773	3,12	Indonesia bùng phát, Philippines tăng tốc
2020	Q3	536.141	13.934	2,60	Làn sóng đầu tiên toàn khu vực
2020	Q4	825.697	17.587	2,13	Cuối năm: Indonesia tăng mạnh
2021	Q1	1.363.600	24.263	1,78	Năm mới, Indonesia vẫn dẫn đầu
2021	Q2	2.039.623	35.400	1,74	Delta xuất hiện, bắt đầu tăng tốc toàn khu vực
2021	Q3	7.212.832	166.437	2,31	**ĐỈNH DELTA** — nguy hiểm nhất lịch sử
2021	Q4	2.770.321	41.886	1,51	Hậu Delta, Việt Nam bắt đầu bùng phát
2022	Q1	14.444.771	36.567	0,25	**ĐỈNH OMICRON** — ca nhiều nhất, ít tử vong
2022	Q2	2.871.317	10.058	0,35	Omicron thoái lui dần
2022	Q3	2.104.609	5.738	0,27	Dịch dần kiểm soát, endemic transition

Bảng 4.5. Tổng hợp quý — toàn khu vực Đông Nam Á

Nghịch lý của sự khởi đầu (Q1/2020):

Dữ liệu hiển thị mức CFR trong Q1/2020 cao chót vót lên tới 5,09%. Tuy nhiên, dưới lăng kính khoa học dữ liệu, con số này mang tính "ảo ảnh thống kê" (Statistical Illusion) nhiều hơn là thực tế độc lực của virus. Ở giai đoạn này, số ca mắc được ghi nhận cực thấp (chỉ hơn 12.000 ca) do các quốc gia chưa có đủ sinh phẩm xét nghiệm diện rộng (PCR). Hệ thống y tế chủ yếu chỉ phát hiện và xét nghiệm cho những người đã có triệu chứng rất nặng nhập viện, dẫn đến "mẫu số" (số ca mắc) bị thu hẹp, đẩy tỷ lệ CFR lên cao một cách phi lý.

Đỉnh điểm tử vong: Tác động nghiêm trọng của biến thể Delta (Q3/2021):

Quý 3 năm 2021 là khoảng thời gian tăm tối nhất trong lịch sử y tế Đông Nam Á. Mặc dù số ca mắc (7,2 triệu ca) chỉ bằng một nửa so với kỷ lục sau này, nhưng số ca tử vong lại thiết lập một đỉnh cao vĩnh cửu: 166.437 người mất chỉ trong 3 tháng. Tỷ lệ CFR vọt lên mức 2,31%. Nguyên nhân trực tiếp đến từ đặc tính sinh học của biến chủng Delta (tấn công sâu vào phổi), kết hợp với việc tỷ lệ bao phủ Vaccine tại ASEAN lúc này còn rất thấp, dẫn đến sự sụp đổ dây chuyền của các hệ thống hồi sức cấp cứu (ICU) và khủng hoảng thiếu hụt oxy y tế.

Hiệu ứng phân tách đường cong: Delta đối đầu Omicron (Q3/2021 vs Q1/2022):

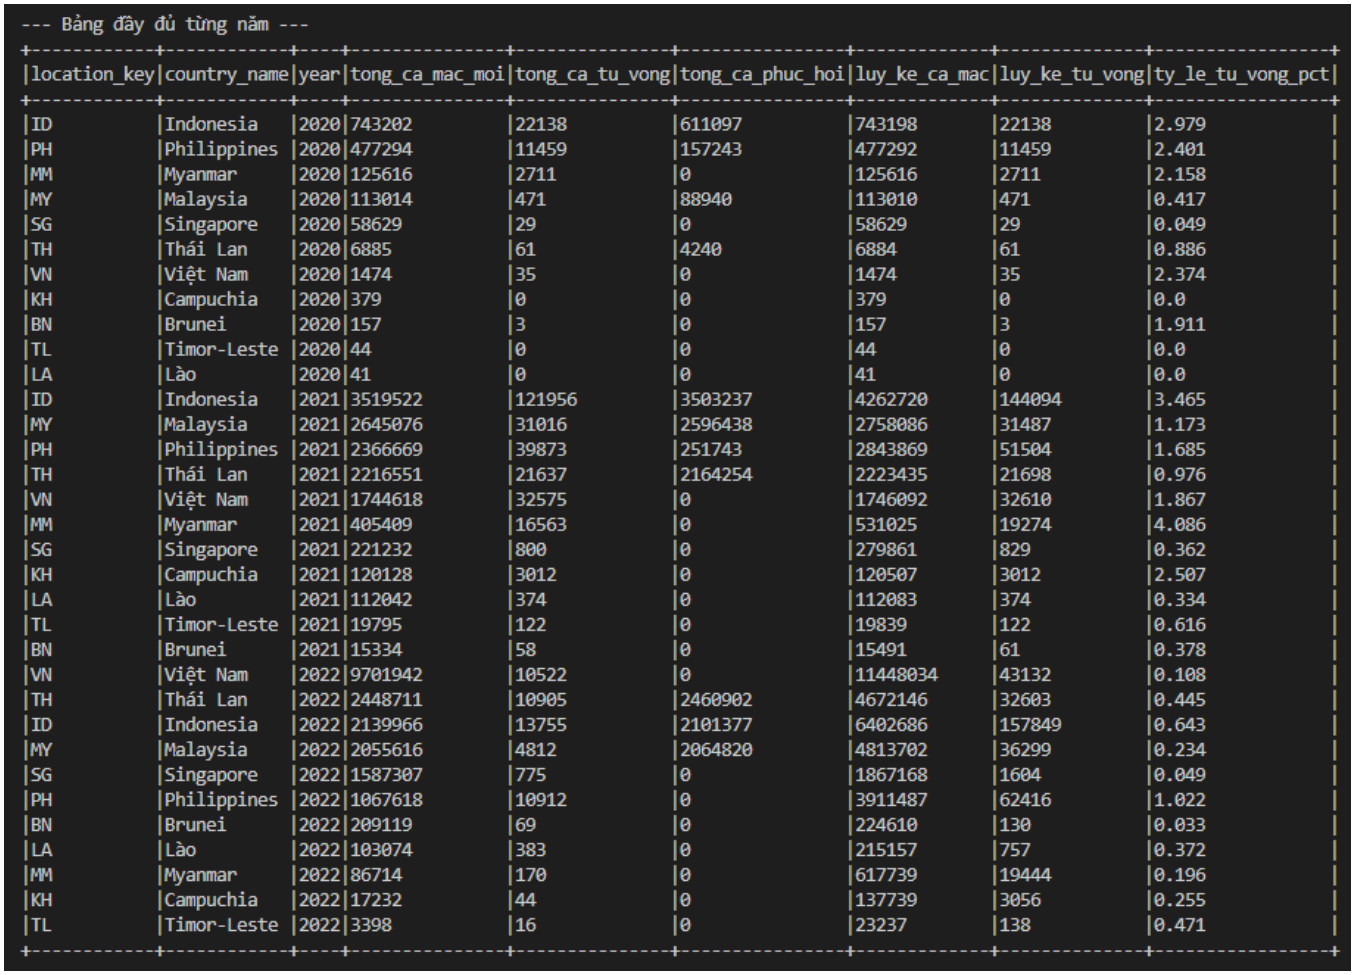
Đây là Insight đắt giá nhất của toàn bộ tập dữ liệu. Khi so sánh Q3/2021 (Đỉnh Delta) và Q1/2022 (Đỉnh Omicron), hệ thống ghi nhận một sự đảo chiều ngoạn mục:

- Khối lượng lây nhiễm: Q1/2022 ghi nhận khối lượng lây nhiễm khổng lồ 14,4 triệu ca (gấp đúng 2,0 lần so với Q3/2021). Virus lây lan với tốc độ chưa từng có.
- Hệ quả tử vong: Ngược lại hoàn toàn, số lượng tử vong trong Q1/2022 chỉ dừng ở mức 36.567 ca (thấp hơn tới 4,55 lần so với Q3/2021).
- Tỷ lệ CFR: Sự kết hợp của hai yếu tố trên đẩy CFR của Q1/2022 chạm đáy ở mức 0,25%.

Kết luận: Bằng phép toán đơn giản (2,31% / 0,25%), Big Data chứng minh biến thể Delta nguy hiểm và chết chóc hơn Omicron tới 9,25 lần. Hai quý này đều được gọi là "Đỉnh dịch", nhưng bản chất hoàn toàn trái ngược nhau. Dữ liệu của Q1/2022 là lời khẳng định đanh thép cho việc ASEAN đã đạt được trạng thái Miễn dịch cộng đồng (Herd Immunity) nhờ tỷ lệ tiêm chủng Vaccine mũi 2 và mũi 3 đạt mức rất cao. Virus vẫn lây lan mãnh liệt (thể hiện qua số ca mắc), nhưng ranh giới sinh tử đã được kiểm soát (thể hiện qua CFR hạ nhiệt).

4.3.3. Tổng hợp theo năm (Yearly Aggregation)

Nếu tổng hợp theo tháng và quý dùng để bám sát các làn sóng dịch bệnh, thì phép tổng hợp theo năm (Yearly Aggregation) cung cấp lăng kính vĩ mô nhất về toàn bộ vòng đời của đại dịch. Khối lượng dữ liệu khổng lồ được nén lại để đánh giá "tổng thiệt hại" (Pandemic Footprint) và phản ánh bức tranh toàn cảnh về hiệu quả của các chiến lược y tế dài hạn (như chiến lược Zero-COVID hay chiến lược "Sống chung với dịch") tại 11 quốc gia ASEAN sau 3 năm chống chọi.

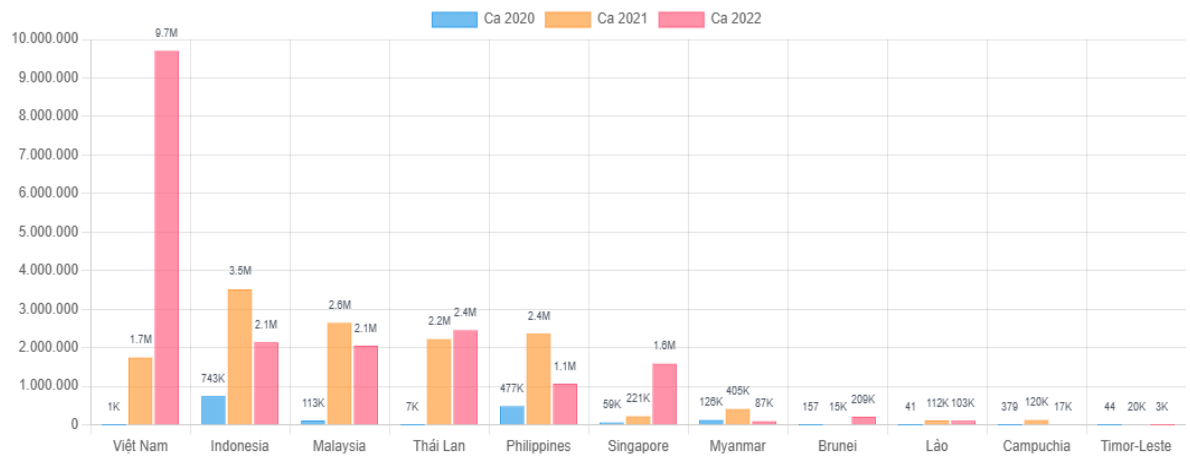


```
--- Bảng đầy đủ từng năm ---
+------------+------------+----+--------------+--------------+---------------+------------+-------------+----------------+
|location_key|country_name|year|tong_ca_mac_moi|tong_ca_tu_vong|tong_ca_phuc_hoi|luy_ke_ca_mac|luy_ke_tu_vong|ty_le_tu_vong_pct|
+------------+------------+----+--------------+--------------+---------------+------------+-------------+----------------+
|ID          |Indonesia   |2020|743202        |22138         |611097         |743198      |22138        |2.979           |
|PH          |Philippines |2020|477294        |11459         |157243         |477292      |11459        |2.401           |
|MM          |Myanmar     |2020|125616        |2711          |0              |125616      |2711         |2.158           |
|MY          |Malaysia    |2020|113014        |471           |88940          |113010      |471          |0.417           |
|SG          |Singapore   |2020|58629         |29            |0              |58629       |29           |0.049           |
|TH          |Thái Lan    |2020|6885          |61            |4240           |6884        |61           |0.886           |
|VN          |Việt Nam    |2020|1474          |35            |0              |1474        |35           |2.374           |
|KH          |Campuchia   |2020|379           |0             |0              |379         |0            |0.0             |
|BN          |Brunei      |2020|157           |3             |0              |157         |3            |1.911           |
|TL          |Timor-Leste |2020|44            |0             |0              |44          |0            |0.0             |
|LA          |Lào         |2020|41            |0             |0              |41          |0            |0.0             |
|ID          |Indonesia   |2021|3519522       |121956        |3503237        |4262720     |144094       |3.465           |
|MY          |Malaysia    |2021|2645076       |31016         |2596438        |2758086     |31487        |1.173           |
|PH          |Philippines |2021|2366669       |39873         |251743         |2843869     |51504        |1.685           |
|TH          |Thái Lan    |2021|2216551       |21637         |2164254        |2223435     |21698        |0.976           |
|VN          |Việt Nam    |2021|1744618       |32575         |0              |1746092     |32610        |1.867           |
|MM          |Myanmar     |2021|405409        |16563         |0              |531025      |19274        |4.086           |
|SG          |Singapore   |2021|221232        |800           |0              |279861      |829          |0.362           |
|KH          |Campuchia   |2021|120128        |3012          |0              |120507      |3012         |2.507           |
|LA          |Lào         |2021|112042        |374           |0              |112083      |374          |0.334           |
|TL          |Timor-Leste |2021|19795         |122           |0              |19839       |122          |0.616           |
|BN          |Brunei      |2021|15334         |58            |0              |15491       |61           |0.378           |
|VN          |Việt Nam    |2022|9701942       |10522         |0              |11448034    |43132        |0.108           |
|TH          |Thái Lan    |2022|2448711       |10905         |2460902        |4672146     |32603        |0.445           |
|ID          |Indonesia   |2022|2139966       |13755         |2101377        |6402686     |157849       |0.643           |
|MY          |Malaysia    |2022|2055616       |4812          |2064820        |4813702     |36299        |0.234           |
|SG          |Singapore   |2022|1587307       |775           |0              |1867168     |1604         |0.049           |
|PH          |Philippines |2022|1067618       |10912         |0              |3911487     |62416        |1.022           |
|BN          |Brunei      |2022|209119        |69            |0              |224610      |130          |0.033           |
|LA          |Lào         |2022|103074        |383           |0              |215157      |757          |0.372           |
|MM          |Myanmar     |2022|86714         |170           |0              |617739      |19444        |0.196           |
|KH          |Campuchia   |2022|17232         |44            |0              |137739      |3056         |0.255           |
|TL          |Timor-Leste |2022|3398          |16            |0              |23237       |138          |0.471           |
+------------+------------+----+--------------+--------------+---------------+------------+-------------+----------------+
```

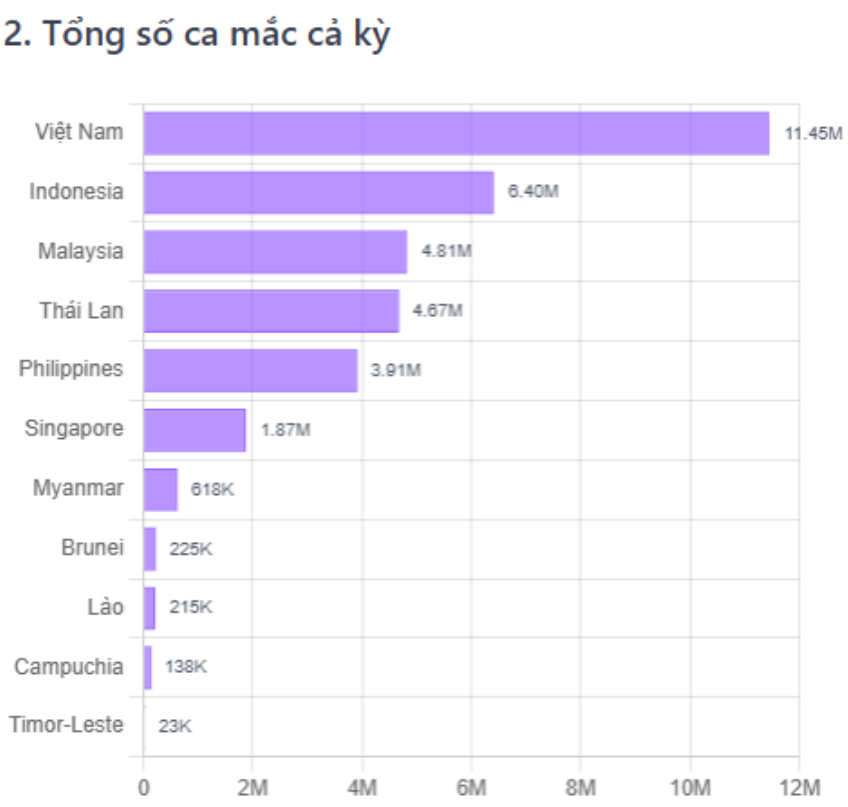
Hình 4.17. Bảng tổng hợp năm đầy đủ 33 nhóm dữ liệu (quốc gia × năm =33)

Quốc gia	Ca 2020	Ca 2021	Ca 2022	Tổng cả kỳ	CFR TB (%)
Việt Nam	1.474	1.744.618	9.701.942	11.448.034	0,377
Indonesia	743.202	3.519.522	2.139.966	6.402.690	2,465
Malaysia	113.014	2.645.076	2.055.616	4.813.706	0,754
Thái Lan	6.885	2.216.551	2.448.711	4.672.147	0,698
Philippines	477.294	2.366.669	1.067.618	3.911.581	1,591
Singapore	58.629	221.232	1.587.307	1.867.168	0,086
Myanmar	125.616	405.409	86.714	617.739	3,148
Brunei	157	15.334	209.119	224.610	0,058
Lào	41	112.042	103.074	215.157	0,352
Campuchia	379	120.128	17.232	137.739	2,219
Timor-Leste	44	19.795	3.398	23.237	0,594

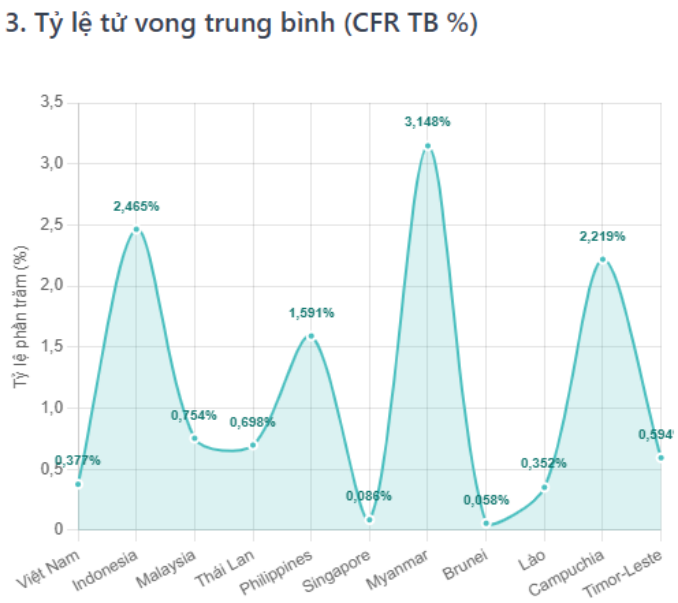
Bảng 4.6. Tổng hợp diễn biến dịch tễ theo năm — 11 quốc gia ASEAN



Hình 4.18. Biểu đồ thể hiện số ca mắc mới qua từng năm (2020, 2021 và 2022) của các nước Đông Nam Á



Hình 4.19. Biểu đồ thể hiện số ca mắc cả kỳ của các nước Đông Nam Á



Hình 4.20. Biểu đồ thể hiện tỷ lệ tử vong trung bình (CFR TB %) của các nước Đông Nam Á

Sự chuyển hướng chiến lược (Trường hợp Việt Nam): Số liệu của Việt Nam là minh chứng rõ nét nhất cho việc thay đổi chiến lược quốc gia. Từ vị thế phòng ngự thành công với chỉ 1.474 ca (cả năm 2020), số ca mắc đã nhảy vọt lên mức 9.701.942 ca (năm 2022) — tức là tăng phi mã lên tới 6.582 lần. Sự bùng nổ này không hẳn là một thất bại y tế, mà là kết quả tất yếu của việc Chính phủ chủ động từ bỏ chính sách "Zero-COVID" (tháng 10/2021) để chuyển sang trạng thái "Thích ứng an toàn, linh hoạt". Khi đã đạt độ phủ vaccine cao, việc chấp nhận để số ca mắc tăng mạnh nhằm khôi phục chuỗi cung ứng kinh tế là một sự đánh đổi có tính toán.

Bẫy dữ liệu và Ảo ảnh thống kê (Trường hợp Myanmar): Nhìn lướt qua, Myanmar có vẻ như đã kiểm soát dịch cực kỳ xuất sắc khi số ca mắc giảm sâu từ 405.409 ca (2021) xuống chỉ còn 86.714 ca (2022). Tuy nhiên, dưới góc độ phân tích Big Data, sự sụt giảm này thực chất là một "ảo ảnh thống kê" do lỗi hệ thống (Systematic Error). Nó phản ánh sự kiệt quệ của cơ sở hạ tầng y tế và sự đứt gãy của năng lực xét nghiệm diện rộng sau các biến động chính trị nghiêm trọng tại quốc gia này. Việc Myanmar có tỷ lệ CFR trung bình cao nhất toàn khu vực (3,148%) củng cố vững chắc giả thuyết này: chỉ những ca bệnh rất nặng (chuẩn bị hoặc đã tử vong) mới được tiếp cận y tế và ghi nhận vào hệ thống, trong khi phần lớn số ca lây nhiễm trong cộng đồng chưa được ghi nhận/bị bỏ sót.

Mô hình miễn dịch lý tưởng (Trường hợp Singapore và Brunei): Dữ liệu của Singapore và Brunei cho thấy số ca mắc tập trung chủ yếu vào năm 2022 (thời kỳ Omicron) với khối lượng rất lớn so với quy mô dân số, nhưng lại duy trì được mức CFR cực thấp (lần lượt là 0,086% và 0,058%). Điều này chứng minh tiềm lực y tế vượt trội của họ: chủ động thả lỏng để tạo miễn dịch cộng đồng tự nhiên nhưng không hề để xảy ra tình trạng vỡ trận tại các bệnh viện tuyến cuối.

4.4. Giai đoạn phân tích chuyên sâu — 5 Data Marts (Lớp Gold)

4.4.1. Phân loại Đánh giá rủi ro (Risk Assessment Data Mart)

Trong thực tế quản lý y tế công cộng, các con số tuyệt đối (như 100.000 ca hay 1 triệu ca) thường khó để các nhà hoạch định chính sách định hình ngay lập tức mức độ nghiêm trọng để đưa ra lệnh phong tỏa hay nới lỏng. Mục tiêu của Data Mart này là chuyển đổi các dữ liệu định lượng (Quantitative) thành các nhãn phân loại định tính (Qualitative Labels). Hệ thống sẽ thiết lập một ma trận rủi ro 2 chiều: Mức độ lây lan (dựa trên tổng ca mắc) và Mức độ tử vong (dựa trên chỉ số CFR), giúp phân cấp mức độ báo động cho từng quốc gia trong từng tháng cụ thể.

```
df_risk = df_monthly.withColumn(
    "muc_do_lay_lan",
    F.when(F.col("tong_ca_mac_moi") >= 500000, "1.Cuc ky nghiem
trong")
     .when(F.col("tong_ca_mac_moi") >= 100000, "2.Rat cao (Bao dong)")
     .when(F.col("tong_ca_mac_moi") >=  10000, "3.Cao")
     .when(F.col("tong_ca_mac_moi") >=   1000, "4.Trung binh")
     .otherwise("5.Thap (Kiem soat)")
).withColumn(
    "muc_do_tu_vong",
    F.when(F.col("ty_le_tu_vong_pct") >= 3.0, "1.Nguy hiem (>=3%)")
     .when(F.col("ty_le_tu_vong_pct") >= 1.0, "2.Cao (1-3%)")
     .when(F.col("ty_le_tu_vong_pct") >= 0.5, "3.Trung binh (0.5-1%)")
     .otherwise("4.Thap (<0.5%)")
)
```

Hệ thống sử dụng hàm F.when().otherwise() — tương đương với cấu trúc CASE WHEN trong SQL. Điểm tối ưu ở đây là việc đánh số thứ tự từ 1 đến 5 (Ví dụ: 1.Cuc ky nghiem trong, 5.Thap). Kỹ thuật gán tiền tố số học này giúp kết quả khi xuất ra file CSV và đưa vào các công cụ BI (như PowerBI, Tableau) sẽ tự động được sắp xếp theo đúng trình tự phân cấp độ nguy hiểm thay vì bị sắp xếp lộn xộn theo bảng chữ cái Alphabet.

```
Đọc dữ liệu monthly: 363 nhóm

--- [1] Phân phối mức độ lây lan ---
+---------------------+-----+
|muc_do_lay_lan       |count|
+---------------------+-----+
|1. Cuc ky nghiem trong|16   |
|2. Rat cao (Bao dong) |58   |
|3. Cao               |83   |
|4. Trung binh        |57   |
|5. Thap (Kiem soat)  |149  |
+---------------------+-----+

--- [2] Phân phối mức độ tử vong ---
+---------------------+-----+
|muc_do_tu_vong       |count|
+---------------------+-----+
|1. Nguy hiem (>=3%)  |39   |
|2. Cao (1-3%)        |66   |
|3. Trung binh (0.5-1%)|40   |
|4. Thap (<0.5%)      |218  |
+---------------------+-----+
```

Hình 4.21. Kết quả phân phối mức độ nguy hiểm trên 363 nhóm

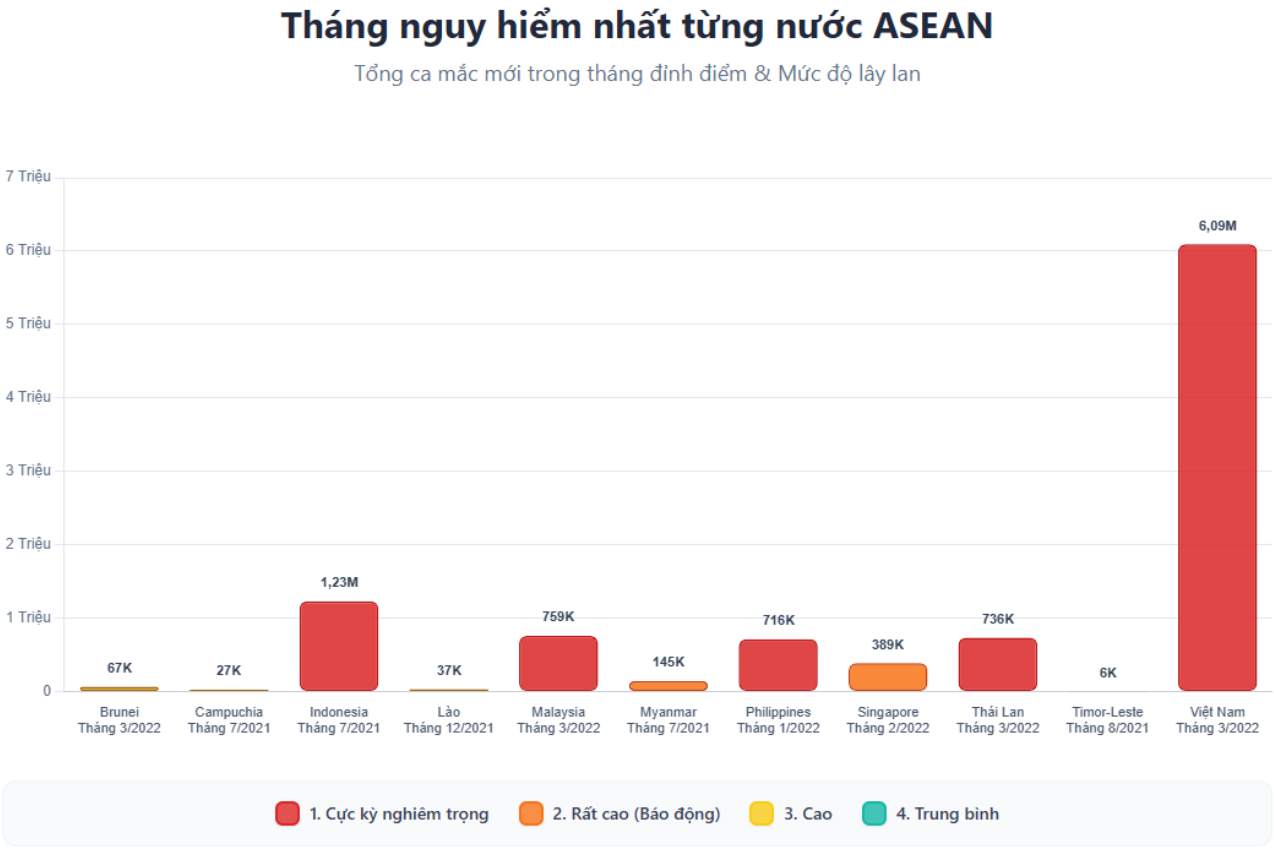
```
--- [3] Những tháng CỰC KỲ NGHIÊM TRỌNG (>500.000 ca/tháng) ---
+------------+----+-----+--------------+--------------+----------------+---------------------+
|country_name|year|month|tong_ca_mac_moi|tong_ca_tu_vong|ty_le_tu_vong_pct|muc_do_lay_lan       |
+------------+----+-----+--------------+--------------+----------------+---------------------+
|Việt Nam    |2022|3    |6093034       |2188          |0.036           |1. Cuc ky nghiem trong|
|Việt Nam    |2022|2    |1270879       |2561          |0.202           |1. Cuc ky nghiem trong|
|Indonesia   |2021|7    |1231386       |35628         |2.893           |1. Cuc ky nghiem trong|
|Indonesia   |2022|2    |1211078       |4015          |0.332           |1. Cuc ky nghiem trong|
|Việt Nam    |2022|4    |1002863       |516           |0.051           |1. Cuc ky nghiem trong|
|Malaysia    |2022|3    |759183        |2235          |0.294           |1. Cuc ky nghiem trong|
|Thái Lan    |2022|3    |736420        |2197          |0.298           |1. Cuc ky nghiem trong|
|Philippines |2022|1    |716303        |2499          |0.349           |1. Cuc ky nghiem trong|
|Indonesia   |2021|8    |680143        |38904         |5.72            |1. Cuc ky nghiem trong|
|Việt Nam    |2022|8    |633350        |24            |0.004           |1. Cuc ky nghiem trong|
|Malaysia    |2021|8    |632982        |7639          |1.207           |1. Cuc ky nghiem trong|
|Thái Lan    |2022|4    |622602        |3396          |0.545           |1. Cuc ky nghiem trong|
|Thái Lan    |2021|8    |607442        |6732          |1.108           |1. Cuc ky nghiem trong|
|Malaysia    |2022|2    |571978        |770           |0.135           |1. Cuc ky nghiem trong|
|Philippines |2021|9    |546082        |4761          |0.872           |1. Cuc ky nghiem trong|
|Việt Nam    |2022|1    |540658        |5167          |0.956           |1. Cuc ky nghiem trong|
+------------+----+-----+--------------+--------------+----------------+---------------------+

--- [4] Tỉ lệ tử vong trung bình (CFR) từng nước ---
+------------+--------+---------+-----------+------------+
|country_name|cfr_tb_%|cfr_max_%|tong_ca_mac|tong_tu_vong|
+------------+--------+---------+-----------+------------+
|Philippines |4.955   |33.333   |3911581    |62244       |
|Indonesia   |3.018   |8.889    |6402690    |157849      |
|Myanmar     |1.568   |6.25     |617739     |19444       |
|Campuchia   |1.556   |19.597   |137739     |3056        |
|Brunei      |1.09    |33.333   |224610     |130         |
|Thái Lan    |0.725   |3.377    |4672147    |32603       |
|Việt Nam    |0.704   |6.828    |11448034   |43132       |
|Malaysia    |0.636   |1.936    |4813706    |36299       |
|Timor-Leste |0.511   |4.762    |23237      |138         |
|Singapore   |0.162   |0.746    |1867168    |1604        |
|Lào         |0.138   |0.844    |215157     |757         |
+------------+--------+---------+-----------+------------+
```

Hình 4.22. Những tháng có ca mắc cao nhất và tỉ lệ tử vong trung bình của từng nước (CFR)

Mức độ	Ngưỡng	Số tháng-nước	Tỉ lệ	Ví dụ tiêu biểu
Cực kỳ nghiêm trọng	≥ 500.000/tháng	16	4,4%	VN 3/2022 (6,09M ca)
Rất cao (Báo động)	100.000–499.999/tháng	58	16,0%	ID 7/2021, MY 8/2021
Cao	10.000–99.999/tháng	83	22,9%	Hầu hết nước lớn 2021
Trung bình	1.000–9.999/tháng	57	15,7%	Giai đoạn chuyển tiếp
Thấp (Kiểm soát)	< 1.000/tháng	149	41,0%	Zero-COVID 2020, nước nhỏ

Bảng 4.7. Phân phối mức độ nguy hiểm theo lượng ca mắc (DM1)



Hình 4.23. Biểu đồ thể hiện tháng nguy hiểm nhất từng nước ở Đông Nam Á

Trường hợp bùng phát ảo (Lây lan cực cao - Tử vong thấp): Việt Nam vào tháng 3/2022 ghi nhận 6,09 triệu ca mắc. Cột muc_do_lay_lan cảnh báo "1.Cực kỳ nghiêm trọng", nhưng cột muc_do_tu_vong (CFR 0,036%) lại trả về nhãn "4.Thấp". Sự kết hợp này báo hiệu cho Chính phủ rằng: Dịch đang lây cực nhanh, nhưng hệ thống y tế không bị đe dọa vỡ trận, giải pháp tối ưu là hướng dẫn người dân tự cách ly và điều trị tại nhà thay vì thiết lập bệnh viện dã chiến.

Trường hợp khủng hoảng thực sự (Lây lan cao - Tử vong nguy hiểm): Indonesia vào tháng 8/2021 ghi nhận 680.000 ca mắc và CFR lên tới 5,72%. Cả hai cột đều đồng loạt kích hoạt cảnh báo Mức độ 1 (Cao nhất). Đây là tín hiệu báo động đỏ (Red Alert), đòi hỏi các lệnh phong tỏa nghiêm ngặt nhất và viện trợ quốc tế khẩn cấp về oxy y tế.

Từ phân tích trên, ta thấy nếu chỉ dùng duy nhất 1 biến số là "Tổng ca mắc" để ra quyết định chống dịch thì sẽ dẫn đến những phản ứng thái quá hoặc sai lầm nghiêm trọng về mặt chính sách.

4.4.2. Phân tích tăng trưởng MoM (Month-over-Month Growth)

Nếu Data Mart 1 (Mức độ nguy hiểm) đo lường quy mô tuyệt đối của đại dịch, thì Data Mart 2 (Tăng trưởng MoM) đo lường gia tốc lây nhiễm (Tốc độ thay đổi). Trong dịch tễ học, việc phát hiện sớm "vận tốc" tăng ca mắc quan trọng hơn rất nhiều so với việc chờ số ca mắc lên đến hàng triệu mới hành động. Tốc độ tăng trưởng MoM (Month-over-Month) đóng vai trò như một chỉ báo sớm (Leading Indicator), giúp hệ thống phát hiện ngay lập tức các đợt bùng phát bất thường ngay từ khi quy mô dịch vẫn còn nhỏ.

```
# Định nghĩa window: cùng quốc gia, sắp xếp theo thời gian
window_mom =
Window.partitionBy("location_key").orderBy("year","month")
```

```
df_mom = df_monthly \
    .withColumn("ca_mac_thang_truoc",
        F.lag("tong_ca_mac_moi", 1).over(window_mom)  # Giá trị tháng
trước
    ) \
    .withColumn("toc_do_tang_truong_pct",
        F.when(
            F.col("ca_mac_thang_truoc").isNull() |
(F.col("ca_mac_thang_truoc") == 0),
            None  # Tháng đầu tiên hoặc tháng trước = 0 → không tính
        ).otherwise(
            F.round(
                ((F.col("tong_ca_mac_moi") -
F.col("ca_mac_thang_truoc"))
                 / F.col("ca_mac_thang_truoc")) * 100, 1
            )
        )
    ) \
    .withColumn("xu_huong_dich",
        F.when(F.col("toc_do_tang_truong_pct").isNull(), "-- Thang dau
--")
         .when(F.col("toc_do_tang_truong_pct") >  100, "Bung phat cuc
manh")
         .when(F.col("toc_do_tang_truong_pct") >   20, "Dang tang
nhanh")
         .when(F.col("toc_do_tang_truong_pct") >    0, "Tang nhe")
         .when(F.col("toc_do_tang_truong_pct") ==   0, "Di ngang")
```

```
        .when(F.col("toc_do_tang_truong_pct") >  -20, "Giam nhe")
        .otherwise("Suy giam manh")
    )
```

Trong SQL truyền thống, để lấy dữ liệu của tháng trước so sánh với tháng này, ta thường phải sử dụng phép kết nối bảng với chính nó (Self-Join), một thao tác cực kỳ tốn kém tài nguyên ($O(N^2)$) và dễ gây tràn RAM (Out Of Memory) với Big Data. Nhờ tính năng **Window Functions** của PySpark, hệ thống định nghĩa một cửa sổ window_mom cô lập dữ liệu cho từng quốc gia (partitionBy) và xếp theo dòng thời gian (orderBy). Hàm F.lag(..., 1) sẽ chỉ đơn giản là "nhìn ngược" lên đúng 1 dòng (offset = 1) ngay trong bộ nhớ RAM cục bộ để trích xuất số liệu. Quá trình này hoàn tất với độ phức tạp tối ưu O(N), thể hiện sự ưu việt tuyệt đối của Apache Spark.

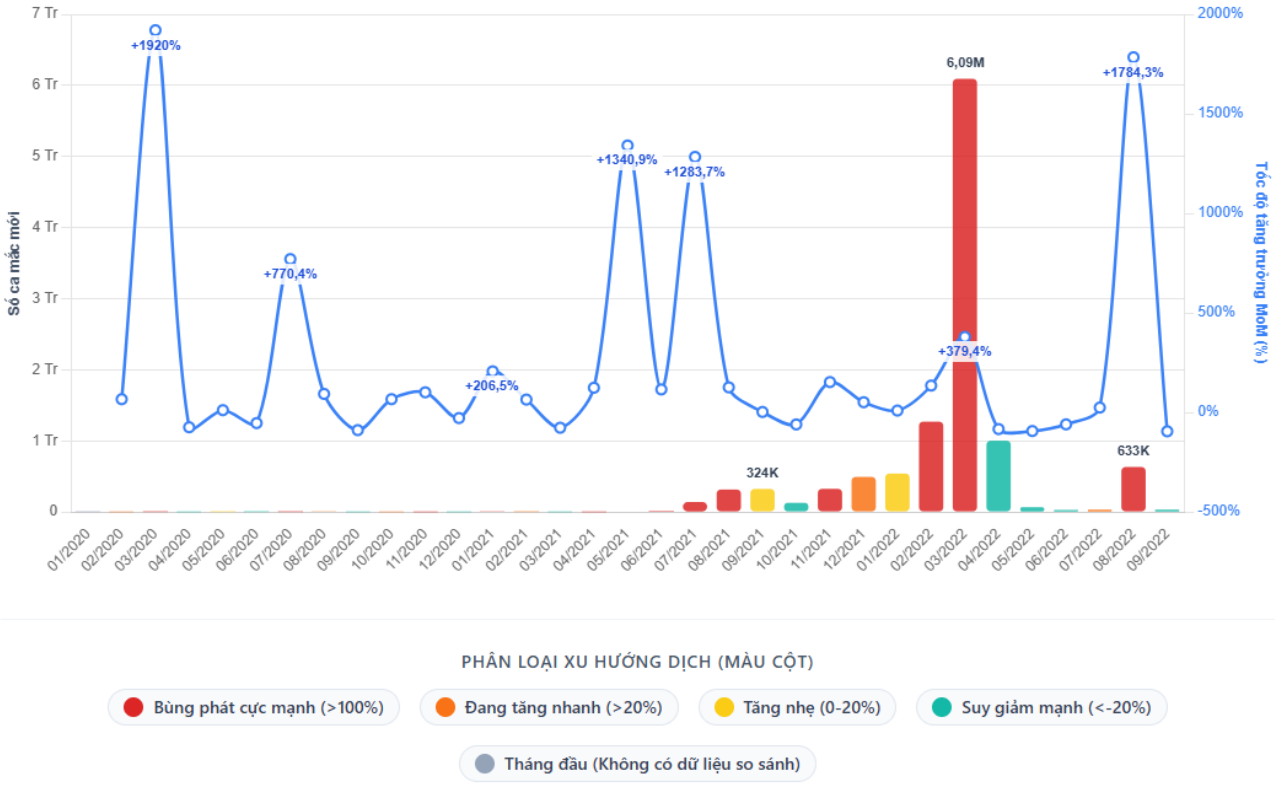


xu_huong_dich	count
Suy giam manh (<-20%)	130
Bung phat cuc manh (>100%)	98
Dang tang nhanh (>20%)	61
-- Thang dau --	28
Tang nhe (0-20%)	22
Giam nhe (0 den -20%)	21
Di ngang (0%)	3

Hình 4.24. Phân phối 6 mức độ xu hướng

Xu hướng	MoM (%)	Số tháng	Tỉ lệ
Bùng phát cực mạnh	> +100%	98	29,0%
Đang tăng nhanh	+20% đến +100%	61	18,1%
Tăng nhẹ	0% đến +20%	22	6,5%
Đi ngang	= 0%	3	0,9%
Giảm nhẹ	-20% đến 0%	21	6,2%
Suy giảm mạnh	< -20%	130	38,5%

Bảng 4.8. Phân phối xu hướng dịch bệnh theo tháng trên toàn khu vực Đông Nam Á



Hình 4.25. Biểu đồ diễn biến dịch bệnh tăng trưởng theo tháng (%) của Việt Nam từ tháng 01/2020 đến tháng 09/2022

Sự tập trung ở hai thái cực (Polarization):

Đáng chú ý nhất là có tới 67,5% tổng thời gian của đại dịch (29,0% + 38,5%) rơi vào hai trạng thái cực đoan nhất: "Bùng phát cực mạnh" hoặc "Suy giảm mạnh". Các trạng thái dịch lây lan bình ổn, đi ngang hoặc tăng/giảm nhẹ chỉ chiếm một tỷ lệ rất nhỏ. Điều này chứng minh COVID-19 không phải là một dịch bệnh lây lan từ từ; các biến chủng mới (như Delta, Omicron) thường lây nhiễm theo dạng hàm số mũ (Exponential growth) chỉ trong một thời gian rất ngắn, sau đó cũng suy sụp rất nhanh (đạt đỉnh rồi rơi tự do) khi chuỗi lây nhiễm bị cắt đứt hoặc cạn kiệt vật chủ.

MoM - Tín hiệu báo động sớm (Early Warning Signal):

Xét trường hợp của Việt Nam vào tháng 5/2021. Số ca mắc tuyệt đối chỉ tăng từ 325 ca (tháng 4) lên 4.683 ca (tháng 5). So với quy mô dân số 100 triệu người, con số 4.683 ca thoạt nhìn là vô cùng nhỏ bé. Tuy nhiên, thuật toán MoM lại gióng lên hồi chuông báo động đỏ rực khi tốc độ tăng trưởng vọt lên +1.341% (rơi thẳng vào nhóm "Bùng phát cực mạnh"). Con số tỷ lệ phần trăm này đã vạch trần sức phá hoại ngầm của biến chủng Delta, phát đi tín hiệu cảnh báo trước khi nó thực sự bùng nổ thành hàng trăm ngàn ca vào các tháng tiếp theo.

Diễn biến đại dịch tại Việt Nam qua lăng kính MoM (01/2020 – 09/2022):

Toàn bộ lịch sử chống dịch của Việt Nam được vẽ lại hoàn hảo qua 4 chu kỳ biến động của chỉ số MoM:

- Kỷ nguyên Zero-COVID (2020 - Đầu 2021): Giai đoạn này chỉ số MoM thỉnh thoảng có những đợt tăng mạnh (ví dụ như đợt dịch Đà Nẵng tháng 8/2020), nhưng xét về bản chất, đây là sự dao động trên một "hiệu ứng nền" (Base Effect) cực thấp. Việc tăng từ vài chục ca lên vài trăm ca cũng có thể tạo ra tỷ lệ MoM hàng trăm %, nhưng dịch bệnh bị dập tắt ngay lập tức ở tháng sau đó (MoM lao dốc < -20%).
- Cú sốc lây nhiễm Delta (Giữa năm 2021): Bắt đầu bằng tín hiệu cảnh báo +1.341% ở tháng 5, tiếp nối bằng một cú bùng nổ +1.284% ở tháng 7 (từ 10 ngàn ca lên gần 140 ngàn ca). Đây là giai đoạn gia tốc lây nhiễm cao nhất, vượt qua mọi biện pháp cách ly truyền thống.
- Đỉnh dịch Omicron (Đầu năm 2022): Vào tháng 3/2022, MoM ghi nhận mức tăng +379%. Dù con số 379% nhỏ hơn mức 1.341% của thời kỳ Delta, nhưng đây là mức tăng trưởng trên một nền tảng khổng lồ (từ 1,27 triệu ca nhảy vọt lên 6,09 triệu ca). Mức MoM này đánh dấu "Đỉnh dịch" tuyệt đối của Việt Nam. Ngay sau khi càn quét qua hầu hết dân số, virus cạn kiệt vật chủ, dẫn đến sự sụt giảm mạnh (hoặc lao dốc/giảm sâu) MoM -83,5% ngay trong tháng 4/2022.
- Giai đoạn cuối của làn sóng biến thể BA.5 (Nửa cuối 2022): Vào tháng 8/2022, biến thể phụ BA.5 tạo ra một sự gia tăng MoM đột biến lên tới +1.784% (từ 34 ngàn ca lên 633 ngàn ca). Tuy nhiên, vì dân số đã có sẵn "tấm khiên" vaccine và kháng thể tự nhiên, đợt bùng phát này kết thúc chớp nhoáng chỉ sau 1 tháng (MoM tháng 9/2022 rơi thẳng đứng -94,7%). Đây là hình thái lây lan đặc trưng của trạng thái Bệnh đặc hữu (Endemic) - lây nhanh, kết thúc gọn, không gây áp lực tử vong.

4.4.3. Hệ thống Xếp hạng và Truy tìm Đỉnh dịch

Nhóm Data Mart cuối cùng (DM3, DM4, DM5) ứng dụng triệt để sức mạnh của **Window Functions** để giải quyết các bài toán xếp hạng (Ranking) và trích xuất điểm cực đại (Peak Extraction), từ đó vẽ nên bức tranh toàn cảnh về sự dịch chuyển của đại dịch.

Phân tích DM3: Bảng xếp hạng Tâm dịch (Epicenter Ranking)

Theo dõi sự biến động vị trí dẫn đầu về số ca mắc lây nhiễm trong khối ASEAN qua từng tháng. Việc này giúp xác định "Tâm dịch" (Epicenter) đang nằm ở quốc gia nào và sự dịch chuyển địa chính trị của virus theo thời gian.

```
window_rank = Window.partitionBy("year","month") \
                    .orderBy(F.desc("tong_ca_mac_moi"))
```

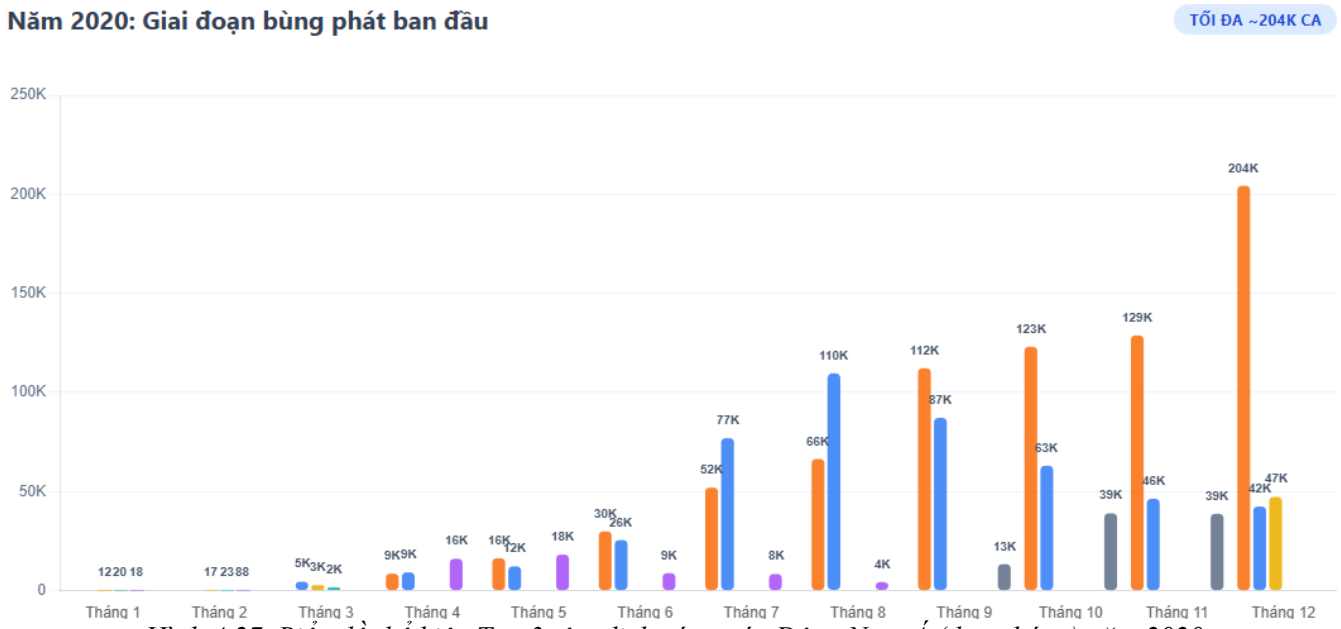
```
df_ranking = df_monthly.withColumn("xep_hang",
F.rank().over(window_rank))
```

```
--- [4] Số tháng đứng hạng #1 tâm dịch từng nước ---
+------------+---------------+
|country_name|so_thang_hang_1|
+------------+---------------+
|Indonesia   |11             |
|Philippines |8              |
|Việt Nam    |6              |
|Singapore   |5              |
|Thái Lan    |3              |
+------------+---------------+
```

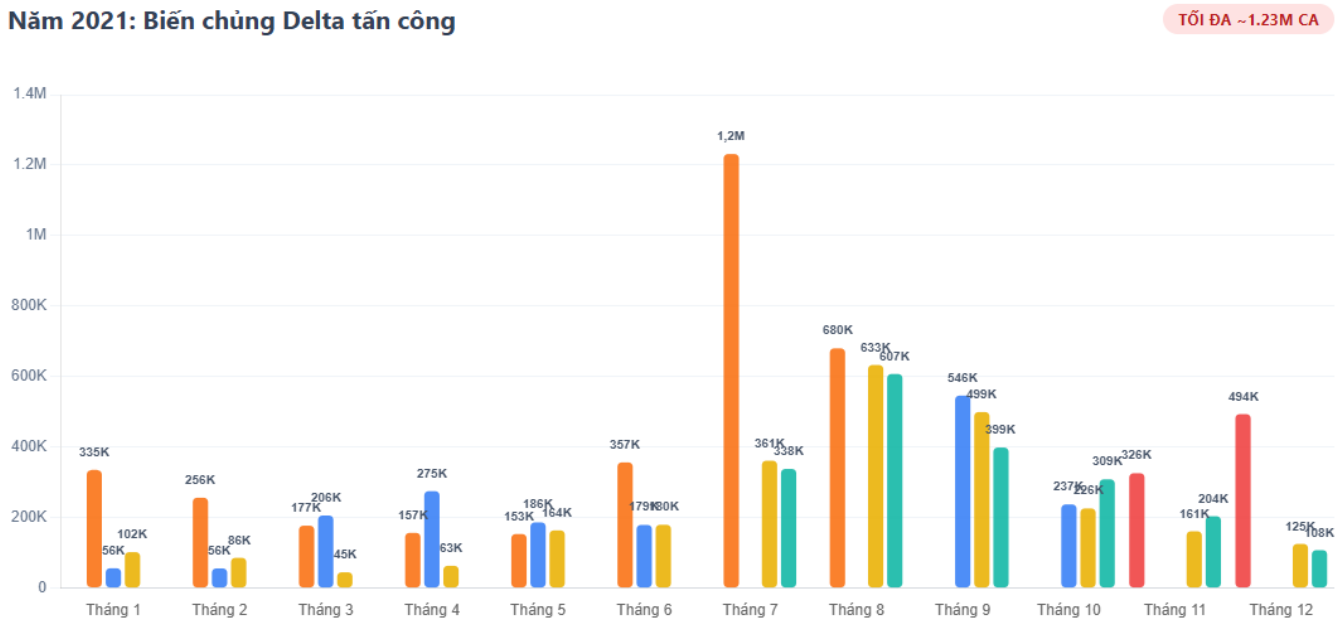
Hình 4.26. Bảng xếp hạng số tháng đứng hạng 1 tâm dịch từng nước

Giai đoạn	Tâm dịch #1	Tháng liên tiếp	Sự kiện chính
1/2020	Thái Lan	1 tháng	Ca đầu tiên khu vực
2/2020–5/2020	Singapore	4 tháng	Cluster trên tàu, ký túc xá
6/2020–2/2021	Indonesia	9 tháng	Làn sóng đầu dài nhất
3/2021–5/2021	Philippines	3 tháng	Làn sóng 2 Philippines
6/2021–8/2021	Indonesia	3 tháng	ĐỈNH DELTA — 1,23M ca tháng 7
9/2021–10/2021	Philippines/Thái Lan	2 tháng	Delta lan lục địa ĐNA
11/2021–4/2022	Việt Nam	6 tháng	Omicron sau Zero-COVID
5/2022–7/2022	Thái Lan/Singapore	3 tháng	BA.4/BA.5 đợt tiếp
8/2022	Việt Nam	1 tháng	BA.5 làn sóng cuối

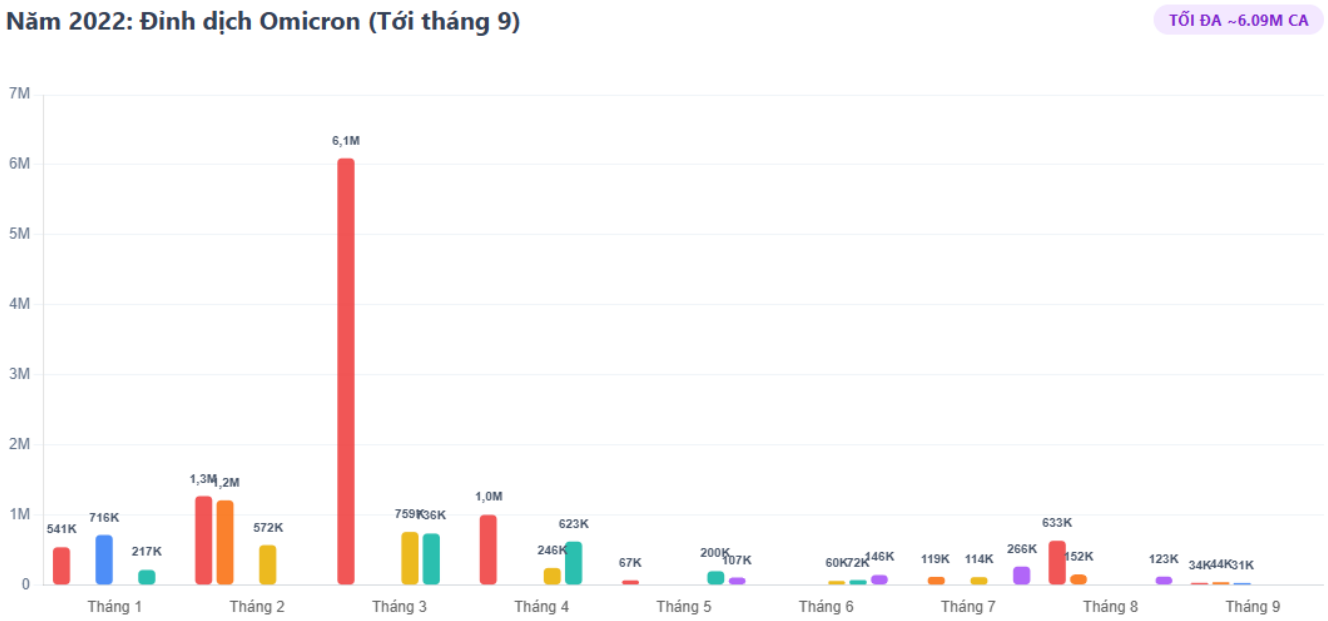
Bảng 4.9. Dịch chuyển tâm dịch theo giai đoạn (DM3)



Hình 4.27. Biểu đồ thể hiện Top 3 tâm dịch các nước Đông Nam Á (theo tháng) năm 2020



Hình 4.28. Biểu đồ thể hiện Top 3 tâm dịch các nước Đông Nam Á (theo tháng) năm 2021



Hình 4.29. Biểu đồ thể hiện Top 3 tâm dịch các nước Đông Nam Á (theo tháng) năm 2022

Kỷ nguyên khởi phát (2020): Dữ liệu cho thấy tâm dịch liên tục đảo chiều trong những tháng đầu. Khởi điểm tại Thái Lan (quốc gia đầu tiên ghi nhận ca mắc ngoài Trung Quốc), lan sang Singapore (do đặc thù bùng phát tại các cụm rủi ro cao như ký túc xá công nhân). Tuy nhiên, vị trí này nhanh chóng tập trung (hoặc duy trì) tại Indonesia. Dưới góc độ dữ liệu vĩ mô, điều này hoàn toàn dễ hiểu: Quy mô dân số khổng lồ (thứ 4 thế giới) kết hợp với đặc thù địa lý vạn đảo đã khiến việc phong tỏa toàn diện của Indonesia gặp vô vàn thách thức, tạo lỗ hổng cho virus bám rễ sâu vào cộng đồng ngay từ sớm.

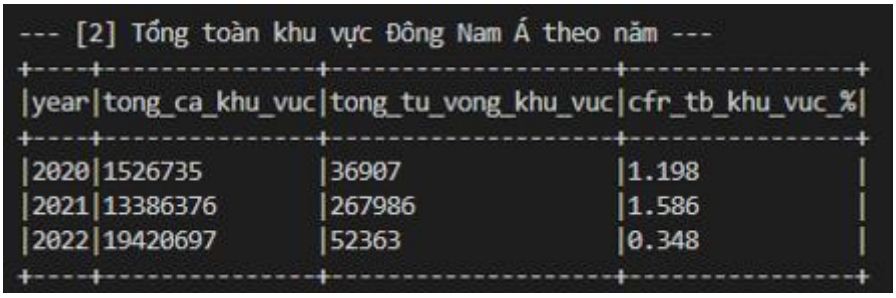
Kỷ nguyên Delta (Giữa 2021): Indonesia khẳng định vị trí tâm dịch tồi tệ nhất lịch sử ASEAN khi dẫn đầu khu vực tới **9 tháng liên tiếp**, đạt đỉnh điểm khủng hoảng vào tháng 7/2021 (hơn 1,2 triệu ca). Ở giai đoạn này, khái niệm "Top 1" trong cơ sở dữ liệu mang một ý nghĩa cực kỳ tăm tối. Nó là chỉ báo trực tiếp (Direct Indicator) cho sự sụp đổ dây chuyền của hệ thống y tế: từ cạn kiệt giường ICU đến khủng hoảng thiếu hụt oxy diện rộng. Tâm dịch lúc này đồng nghĩa với "tâm bão tử vong", với tỷ lệ tử vong (CFR) luôn ở mức báo động đỏ.

Kỷ nguyên Omicron (Cuối 2021 - 2022): Khối lượng dữ liệu chứng kiến một sự chuyển giao tâm dịch bất ngờ sang Việt Nam (thống trị Top 1 suốt 6 tháng liên tiếp từ tháng 11/2021 đến tháng 4/2022). Sự bùng nổ này là kết quả tất yếu của việc Việt Nam chủ động dỡ bỏ lớp lá chắn "Zero-COVID" để mở cửa phục hồi kinh tế. Tuy nhiên, Insight đắt giá nhất mà dữ liệu chỉ ra là sự thay đổi hoàn toàn về bản chất của Tâm dịch. Nhờ chiến dịch tiêm phủ vaccine thần tốc trong Q3-Q4/2021, vị trí "Top 1" của Việt Nam năm 2022 chỉ mang ý nghĩa về mặt siêu lây lan sinh học (Hyper-transmissibility). Nó hoàn toàn bị cắt đứt khỏi định nghĩa "khủng hoảng sinh tử" của

năm 2021, minh chứng qua việc dù ca mắc vút cao nhưng hệ thống y tế không sụp đổ và số ca tử vong được kìm hãm ở mức cực thấp.

Phân tích DM4:Tổng kết Vĩ mô (Yearly Summary)

Đóng vai trò là chốt chặn tổng kết (Executive Summary), nén toàn bộ 394.165 bản ghi của 3 năm lại thành một bức tranh vĩ mô duy nhất để báo cáo cho các cấp lãnh đạo cao nhất.



--- [2] Tổng toàn khu vực Đông Nam Á theo năm ---

year	tong_ca_khu_vuc	tong_tu_vong_khu_vuc	cfr_tb_khu_vuc_%
2020	1526735	36907	1.198
2021	13386376	267986	1.586
2022	19420697	52363	0.348

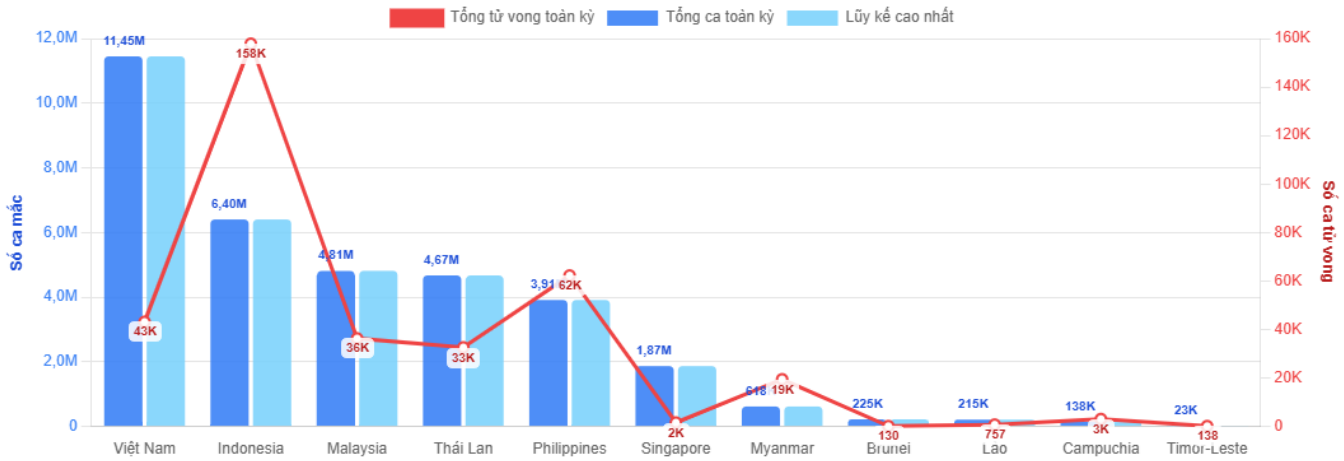
Hình 4.30. Bảng tổng kết toàn bộ khu vực Đông Nam Á theo năm

Năm 2020 (Giai đoạn Khởi phát): 1,53 triệu ca mắc — CFR 1,198%. Đây là năm thế giới làm quen với đại dịch mới, chưa có vaccine bảo vệ nhưng nhờ các lệnh phong tỏa nghiêm ngặt (Lockdown), số ca mắc vẫn được kìm hãm ở mức thấp.

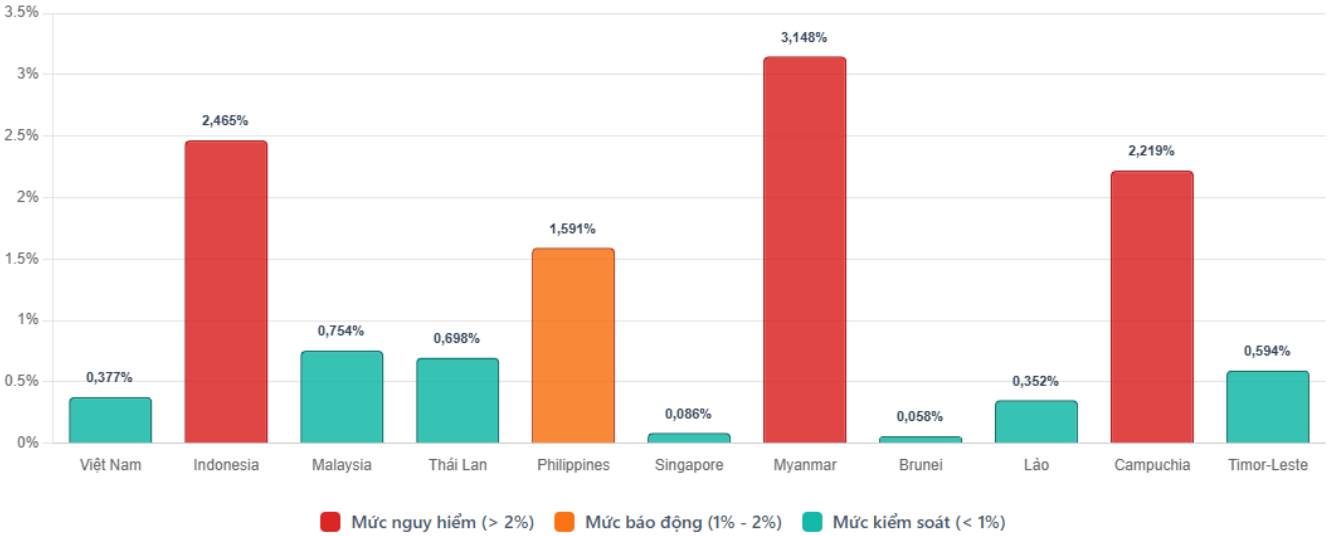
Năm 2021 (Khủng hoảng Delta): 13,4 triệu ca mắc — CFR tăng vọt lên đỉnh điểm 1,586%. Đây là năm tăm tối nhất của khu vực. Biến chủng Delta mang độc lực cao đã chọc thủng các hàng rào cách ly truyền thống, trong khi tỷ lệ bao phủ vaccine tại các nước ASEAN lúc bấy giờ vẫn còn rất thấp. Hậu quả là tỷ lệ tử vong gia tăng, hệ thống y tế toàn khu vực chao đảo.

Năm 2022 (Kỷ nguyên Vaccine & Phục hồi): 19,4 triệu ca mắc — CFR rơi tự do xuống chỉ còn 0,348%. Mặc dù số ca mắc thiết lập kỷ lục mọi thời đại (tăng gần 1,5 lần so với 2021 do siêu biến thể Omicron), nhưng tỷ lệ tử vong lại giảm hơn 4,5 lần.

Chỉ số CFR không giảm đều đặn mà biến động theo hình parabol (tăng từ 1,198% lên 1,586% rồi sập mạnh xuống 0,348%). Sự sụt giảm CFR đột ngột vào năm 2022 (từ 1,586% xuống 0,348%) là bằng chứng dữ liệu (Data-driven evidence) hùng hồn nhất. Nó tuyên bố chiến thắng của chiến dịch tiêm chủng đại trà: Vaccine đã hoàn thành xuất sắc sứ mệnh lịch sử của mình — không phải để chặn đứng ca mắc, mà để làm giảm đáng kể độc lực/giảm thiểu nguy cơ tử vong của virus, đưa COVID-19 trở thành một bệnh lý đặc hữu thông thường.



Hình 4.31 . Biểu đồ thể hiện Quy mô lây nhiễm và Số ca tử vong trên toàn khu vực Đông Nam Á



Việt Nam ghi nhận số ca mắc kỷ lục 11,4 triệu ca (gấp 1,8 lần Indonesia).

Tuy nhiên, Indonesia lại là quốc gia chịu tổn thất nhân mạng tồi tệ nhất với 157.849 ca tử vong (cao gần gấp 4 lần Việt Nam).

Sự đối nghịch này chứng minh tầm quan trọng của "thời điểm bùng phát": Indonesia vỡ trận vào thời kỳ biến chủng Delta (chưa có vaccine), trong khi Việt Nam

Hình 4.32. Biểu đồ thể hiện Tỉ lệ tử vong toàn kỳ (CFR) trên toàn khu vực Đông Nam Á

bùng phát quy mô lớn vào thời kỳ Omicron khi đã có "tấm khiên" miễn dịch cộng đồng che chắn.

Nhóm đứt gãy y tế: Myanmar (CFR cao nhất 3,148%) và Indonesia (2,465%) bộc lộ rõ sự cạn kiệt về nguồn lực hồi sức cấp cứu và khả năng tiếp cận y tế của người dân trong đại dịch.

Singapore (0,086%) và Brunei (0,058%) cho thấy một hệ thống y tế xuất sắc. Dù Singapore phải đối mặt với gần 1,9 triệu ca mắc, tỷ lệ tử vong vẫn được ép xuống mức tiệm cận 0 nhờ hạ tầng y tế vững chắc và tỷ lệ tiêm chủng đi đầu khu vực.

Phân tích DM5: Truy tìm Đỉnh dịch (Peak Detection)

Bài toán đặt ra là: "Trong suốt 3 năm, tháng nào là tháng tồi tệ nhất của từng quốc gia?". Yêu cầu hệ thống phải trích xuất chính xác đúng 11 dòng dữ liệu đại diện cho 11 đỉnh dịch của 11 nước.

```
window_peak = Window.partitionBy("location_key") \
                    .orderBy(F.desc("tong_ca_mac_moi"))
df_peak = df_monthly \
    .withColumn("row_num", F.row_number().over(window_peak)) \
    .filter(F.col("row_num") == 1)  # Chỉ lấy hàng đầu tiên = tháng
cao nhất
```

Đây là một quyết định mang tính kiến trúc lõi. Nếu sử dụng hàm RANK(), trong trường hợp hy hữu một quốc gia có 2 tháng đạt số ca mắc giống hệt nhau (ví dụ cùng là 10.000 ca), thuật toán sẽ cấp hạng 1 cho cả 2 tháng, dẫn đến kết quả trả về nhiều hơn 11 dòng (phá vỡ logic mỗi nước 1 đỉnh dịch). Việc sử dụng ROW_NUMBER() ép buộc hệ thống phải đánh số thứ tự duy nhất (1, 2, 3...), đảm bảo tuyệt đối sau khi filter(row_num == 1), kết quả thu về là đúng và đủ 11 bản ghi cực đại.

```
--- [1] Tháng đỉnh dịch của từng quốc gia ---
+------------+----+-----+--------------+--------------+----------------+--------------+
|country_name|year|month|tong_ca_mac_moi|tong_ca_tu_vong|ty_le_tu_vong_pct|ca_mac_tb_ngay|
+------------+----+-----+--------------+--------------+----------------+--------------+
|Việt Nam    |2022|3    |6093034       |2188          |0.036           |196549.0      |
|Indonesia   |2021|7    |1231386       |35628         |2.893           |39722.0       |
|Malaysia    |2022|3    |759183        |2235          |0.294           |24490.0       |
|Thái Lan    |2022|3    |736420        |2197          |0.298           |23755.0       |
|Philippines |2022|1    |716303        |2499          |0.349           |23107.0       |
|Singapore   |2022|2    |389429        |172           |0.044           |13908.0       |
|Myanmar     |2021|7    |145144        |6697          |4.614           |4682.0        |
|Brunei      |2022|3    |67153         |27            |0.04            |2166.0        |
|Lào         |2021|12   |36920         |196           |0.531           |1191.0        |
|Campuchia   |2021|7    |26530         |792           |2.985           |856.0         |
|Timor-Leste |2021|8    |6201          |48            |0.774           |200.0         |
+------------+----+-----+--------------+--------------+----------------+--------------+
```

Hình 4.33. Bảng đỉnh dịch của 11 quốc gia

Quốc gia	Tháng đỉnh	Ca mắc đỉnh	Tử vong	CFR (%)	Ca TB/ngày	Làn sóng

Việt Nam	3/2022	6.093.034	2.188	0,036	196.549	Omicron BA.2
Indonesia	7/2021	1.231.386	35.628	2,893	39.722	Delta
Malaysia	3/2022	759.183	2.235	0,294	24.490	Omicron BA.2
Thái Lan	3/2022	736.420	2.197	0,298	23.755	Omicron BA.2
Philippines	1/2022	716.303	2.499	0,349	23.107	Omicron BA.1
Singapore	2/2022	389.429	172	0,044	13.908	Omicron BA.2
Myanmar	7/2021	145.144	6.697	4,614	4.682	Delta
Brunei	3/2022	67.153	27	0,040	2.166	Omicron BA.2
Lào	12/2021	36.920	196	0,531	1.191	Omicron BA.1
Campuchia	7/2021	26.530	792	2,985	856	Delta
Timor-Leste	8/2021	6.201	48	0,774	200	Delta

Bảng 4.10. Tháng đỉnh dịch của 11 quốc gia Đông Nam Á

Việc trích xuất 11 đỉnh dịch từ Data Mart 5 (DM5) giúp nhóm phân tích chia lịch sử đại dịch ASEAN thành hai chiến tuyến thời gian rõ rệt, đại diện cho hai "thời kỳ sinh học" của virus: Nhóm đỉnh tàn phá Delta (Q3/2021) và Nhóm đỉnh siêu lây nhiễm Omicron (Q1/2022).

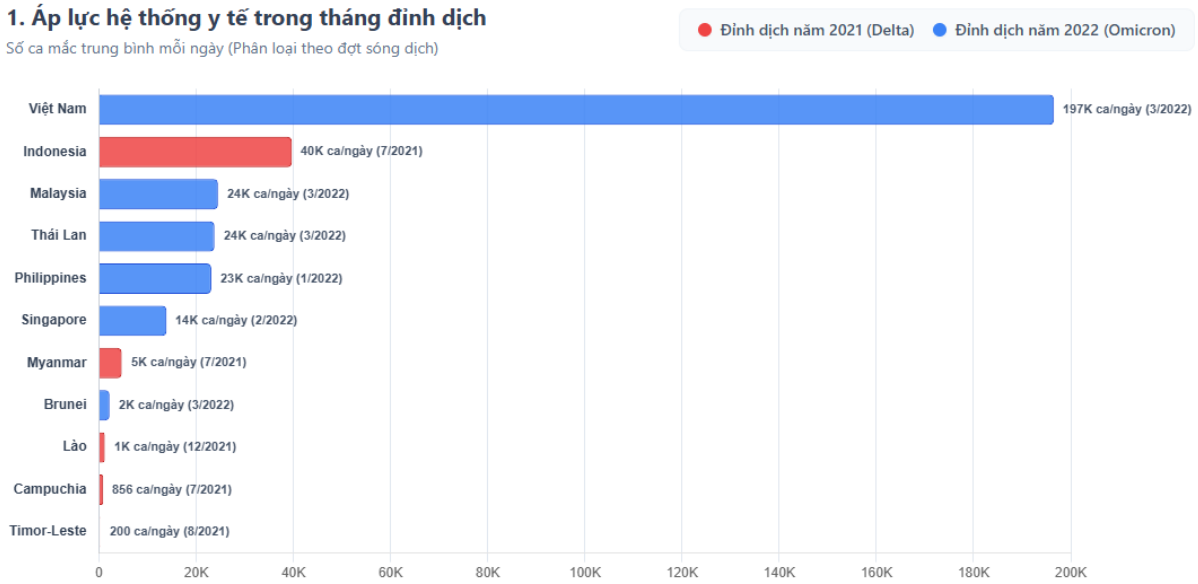
- **Indonesia (Đỉnh Delta - 7/2021):** Ghi nhận 1,23 triệu ca mắc, tỷ lệ tử vong lên tới 2,893%.
- **Việt Nam (Đỉnh Omicron - 3/2022):** Ghi nhận 6,09 triệu ca mắc (cao gấp 4,9 lần đỉnh của Indonesia), nhưng tỷ lệ tử vong bị ép xuống mức cực tiểu 0,036%.

Khoảng cách chênh lệch về độc lực (CFR) giữa hai đỉnh dịch này lên tới 80,4 lần. Từ đối chiếu này, Big Data chỉ ra một Kịch bản sụp đổ giả định: Nếu Việt Nam đạt đỉnh dịch 6,09 triệu ca vào tháng 3/2022 nhưng phải đối mặt với độc lực 2,893% của biến thể Delta (trong điều kiện dân số chưa được phủ vaccine bảo vệ giống như Indonesia năm 2021), thì số ca tử vong trong riêng một tháng của Việt Nam sẽ cán mốc hơn 176.200 người (tương đương gần 6.000 ca tử vong mỗi ngày), thay vì con số 2.188 người như thực tế.

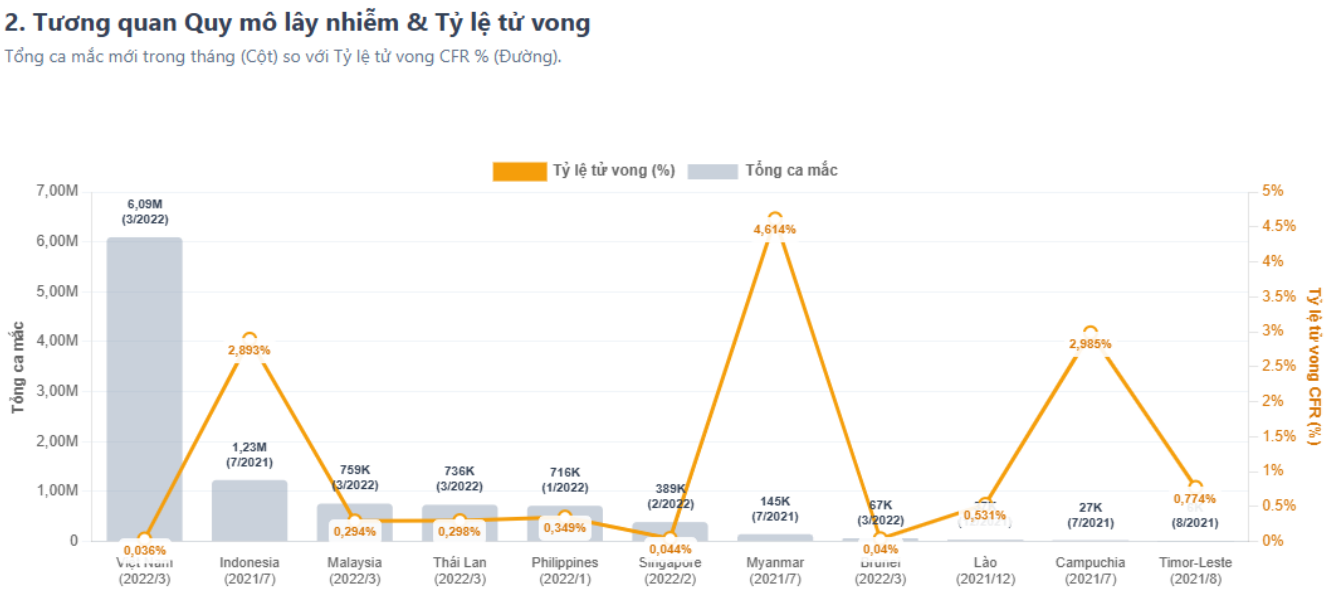
Con số 176.200 ca tử vong này không chỉ là một phép tính thống kê đơn thuần, mà nó đại diện cho sự sụp đổ toàn diện của hệ thống y tế: các bệnh viện dã chiến vỡ trận, hệ thống ICU cạn kiệt oxy và sự hoảng loạn của toàn xã hội.

```
--- [4] So sánh đỉnh dịch các nước ---
+------------+----------+--------------+-------------+----------------+
|country_name|thang_dinh|tong_ca_mac_moi|ca_mac_tb_ngay|ty_le_tu_vong_pct|
+------------+----------+--------------+-------------+----------------+
|Việt Nam    |2022/3    |6093034       |196549.0     |0.036           |
|Indonesia   |2021/7    |1231386       |39722.0      |2.893           |
|Malaysia    |2022/3    |759183        |24490.0      |0.294           |
|Thái Lan    |2022/3    |736420        |23755.0      |0.298           |
|Philippines |2022/1    |716303        |23107.0      |0.349           |
|Singapore   |2022/2    |389429        |13908.0      |0.044           |
|Myanmar     |2021/7    |145144        |4682.0       |4.614           |
|Brunei      |2022/3    |67153         |2166.0       |0.04            |
|Lào         |2021/12   |36920         |1191.0       |0.531           |
|Campuchia   |2021/7    |26530         |856.0        |2.985           |
|Timor-Leste |2021/8    |6201          |200.0        |0.774           |
+------------+----------+--------------+-------------+----------------+
```

Hình 4.34. Bảng so sánh đỉnh dịch giữa các nước



Hình 4.35. Biểu đồ thể hiện số ca mắc trung bình mỗi ngày (phân loại theo làn sóng dịch) của các nước Đông Nam Á



Hình 4.36. Biểu đồ thể hiện tổng ca mắc mới trong tháng so với tỉ lệ tử vong (CFR %)

Dữ liệu chia khu vực Đông Nam Á thành hai mốc bùng phát cực đại. Nhóm thứ nhất gồm 4 quốc gia là Indonesia, Myanmar, Campuchia và Timor-Leste đều ghi nhận tháng tồi tệ nhất vào quý 3 năm 2021 (tập trung chủ yếu vào tháng 7 và tháng 8). Trong khi đó, 7 quốc gia còn lại, dẫn đầu bởi Việt Nam, Malaysia và Thái Lan, lại thiết lập đỉnh lây nhiễm muộn hơn vào quý 1 năm 2022, với đa số rơi vào tháng 3. Sự phân tách thời gian này tương đồng hoàn toàn với hai làn sóng càn quét của biến chủng Delta và Omicron trên toàn cầu.

Khi đối chiếu giữa quy mô lây nhiễm và tỷ lệ tử vong tại thời điểm lập đỉnh, số liệu bộc lộ một nghịch lý rất lớn. Việt Nam trong tháng 3/2022 ghi nhận khối lượng lây nhiễm vô tiền khoáng hậu với gần 6,1 triệu ca mắc mới, trung bình mỗi ngày có tới 196.549 ca, cao gấp gần 5 lần so với đỉnh dịch của quốc gia đứng thứ hai là Indonesia (khoảng 1,23 triệu ca). Tuy nhiên, mặc dù số ca mắc vượt trội, tỷ lệ tử vong (CFR) tại đỉnh dịch của Việt Nam lại thấp nhất toàn khu vực, chỉ ở mức 0,036%. Những quốc gia lập đỉnh cùng thời điểm đầu năm 2022 như Brunei hay Singapore cũng ghi nhận mức CFR cực thấp, lần lượt là 0,040% và 0,044%.

Ở chiều ngược lại, nhóm các quốc gia lập đỉnh vào thời điểm giữa năm 2021 lại phải đối mặt với mức độ tử vong nghiêm trọng hơn rất nhiều dù số lượng ca mắc thấp hơn hẳn. Myanmar dẫn đầu khu vực về tỷ lệ tử vong tại đỉnh dịch với mức CFR lên tới 4,614%, theo sau là Campuchia (2,985%) và Indonesia (2,893%). Các chỉ số này minh chứng rõ ràng bằng số liệu rằng: những đỉnh dịch rơi vào năm 2021 đi kèm với rủi ro tử vong rất cao, trong khi các đỉnh dịch vào năm 2022 lại đặc trưng bởi tốc độ siêu lây lan nhưng tỷ lệ tử vong đã được nén xuống mức tối thiểu.

V. TỔNG KẾT VÀ ĐÁNH GIÁ

5.1. Kết quả đạt được

5.1.1. Kết quả kỹ thuật

Đồ án đã thiết kế và triển khai thành công một đường ống dữ liệu (Data Pipeline) hoàn chỉnh, tuân thủ chặt chẽ các tiêu chuẩn của hệ thống Dữ liệu lớn (Big Data).

Triển khai thành công môi trường ảo hóa Docker Compose với cụm 3 container (namenode, datanode, spark-jupyter), cho phép lưu trữ phân tán trên HDFS và xử lý tính toán song song bằng Apache Spark.

Hệ thống đã thực thi 12 file PySpark (từ 1a đến 3e), chạy thành công theo thứ tự từ EDA đến phân tích đa chiều; 18 thư mục dữ liệu (9 Parquet + 9 CSV Export) được lưu trữ trên HDFS

Áp dụng các hàm cửa sổ (Window Functions) nâng cao của PySpark như LAG(), RANK(), và ROW_NUMBER() giúp giải quyết các bài toán chuỗi thời gian, tính toán gia tốc lây nhiễm (MoM) và trích xuất điểm cực đại (Đỉnh dịch) mà các truy vấn GROUP BY thông thường không thể thực hiện được.

Hệ thống đã tự động kết xuất ra 18 thư mục dữ liệu, trong đó sử dụng định dạng Parquet cho các tiến trình nội bộ (giúp nén dữ liệu và tăng tốc độ đọc) và xuất ra định dạng CSV để sẵn sàng cung cấp cho người dùng cuối.

Tiêu chí	Kết quả thực tế	Đánh giá
Docker Compose	3/3 container healthy, chạy ổn định	Đạt
Upload HDFS	394.165 bản ghi, ~25.8MB, thành công	Đạt
Làm sạch (1c)	10.864 bản ghi sạch, 0 NULL còn lại	Đạt
Tổng hợp tháng (2a)	363 nhóm, 9 chỉ số mỗi nhóm	Đạt
Tổng hợp quý (2b)	121 nhóm	Đạt
Tổng hợp năm (2c)	33 nhóm	Đạt
Window Function LAG	MoM Growth đúng cho 335 nhóm có dữ liệu	Kỹ thuật nâng cao
Window Function RANK	Xếp hạng đúng 363 nhóm	Kỹ thuật nâng cao
Window Function ROW_NUMBER	11 đỉnh dịch chính xác	Kỹ thuật nâng cao
Lưu trữ HDFS	9 Parquet + 9 CSV = 18 thư mục	Vượt yêu cầu
Thời gian xử lý	2–5 phút/file trên máy cá nhân	Hiệu năng tốt

Bảng 5.1. Đánh giá tổng hợp kết quả kỹ thuật

5.1.2. Kết quả phân tích

Dữ liệu chứng minh rằng khối lượng ca mắc tuyệt đối không còn là thước đo phản ánh đúng mức độ nguy hiểm của dịch bệnh. Minh chứng rõ nhất là sự đối lập giữa Indonesia (tháng 8/2021) với 680.000 ca mắc nhưng tỷ lệ tử vong (CFR) lên tới 5,72%, và Việt Nam (tháng 3/2022) với 6,09 triệu ca mắc nhưng CFR chỉ ở mức 0,036%. Điều này cho thấy CFR mới là "kim chỉ nam" chính xác nhất để đánh giá áp lực lên hệ thống y tế.

Big Data đã trở thành bằng chứng toán học đanh thép nhất để đo lường hiệu quả của chiến dịch tiêm chủng. Từ tháng 8/2021 đến tháng 3/2022, mặc dù số ca mắc tại Việt Nam tăng gấp 19 lần, nhưng tỷ lệ CFR lại giảm tới 92,9 lần.

Thuật toán phân tích chuỗi thời gian đã làm rõ sự khác biệt sinh học giữa hai biến thể. Delta được định danh là biến thể "chết chóc" khi độc lực (CFR) cao gấp 9,25 lần so với Omicron. Ngược lại, Omicron là biến thể "siêu lây lan" đánh dấu bước ngoặt chuyển giao đại dịch (Endemic transition), biến COVID-19 thành bệnh lý đặc hữu.

Đồ án đã vẽ lại quỹ đạo của đại dịch trong 3 năm. Tâm dịch dịch chuyển từ trạng thái thăm dò (Thái Lan, Singapore 2020), sang khủng hoảng sinh tử (Indonesia 2021), và cuối cùng là bùng nổ diện rộng nhưng an toàn (Việt Nam 2022). Bức tranh này phản ánh chính xác tác động của các chính sách vĩ mô từ Zero-COVID sang "Thích ứng an toàn".

Phát hiện	Bằng chứng số liệu	Ý nghĩa
Số ca ≠ mức độ nguy hiểm	VN 3/2022: 6,09M ca, CFR 0,036%; ID 8/2021: 680K ca, CFR 5,72%	Cần theo dõi CFR, không chỉ số ca tuyệt đối
Vaccine có hiệu quả đo được	CFR VN giảm 92,9 lần từ 8/2021 đến 3/2022	Chứng minh vai trò vaccine qua dữ liệu
Delta nguy hiểm hơn Omicron 9x	CFR Q3/2021 = 9,25 × CFR Q1/2022	Omicron là đặc trưng endemic transition
Dịch dịch chuyển tâm dịch	Indonesia 2020–2021 → Việt Nam 2022	Phản ánh chiến lược chính sách y tế
3 giai đoạn đại dịch rõ ràng	2020: thăm dò; 2021: leo thang; 2022: endemic	Cung cấp framework phân tích cho tương lai

Bảng 5.2. Các phát hiện chính từ phân tích dữ liệu

5.2. Hướng phát triển và Mở rộng hệ thống

Mặc dù đã đạt được những kết quả khả quan, kiến trúc hiện tại của đồ án vẫn chủ yếu hoạt động ở hình thái xử lý dữ liệu theo lô (Batch Processing) và Phân tích mô tả (Descriptive Analytics). Để nâng cấp hệ thống lên quy mô doanh nghiệp thực thụ, nhóm đề xuất các hướng phát triển sau:

5.2.1. Tích hợp Kafka — Streaming Pipeline

Hệ thống hiện tại xử lý batch data (dữ liệu lịch sử). Bước phát triển tự nhiên là tích hợp Apache Kafka để xây dựng streaming pipeline: Kafka Producer đẩy dữ liệu ca mắc mới theo thời gian thực → Kafka Topic nhận và buffer → Spark Structured Streaming đọc và xử lý micro-batch → Dashboard cập nhật live. Đây là kiến trúc Lambda Architecture hoàn chỉnh, kết hợp batch (lịch sử) và streaming (real-time).

5.2.2. Machine Learning — Dự báo ca mắc

Từ bộ dữ liệu time series đã được làm sạch và tổng hợp, có thể xây dựng mô hình dự báo: sử dụng MLlib của Spark để train mô hình ARIMA hoặc LSTM trên dữ liệu lịch sử ca mắc hàng tháng của từng quốc gia. Mô hình có thể dự báo 3–6 tháng tiếp theo, giúp cơ quan y tế chuẩn bị nguồn lực trước các đợt bùng phát tiềm năng.

5.2.3. Các hướng phát triển khác

- Tích hợp dữ liệu vaccine từ cùng nguồn Google để phân tích định lượng mối tương quan tiêm chủng và CFR.
- Triển khai trên cloud (AWS EMR, Google Dataproc) với cluster nhiều node để xử lý dữ liệu toàn cầu hàng trăm triệu bản ghi.
- Kết nối Hive để cung cấp lớp SQL cho Nhóm 5 và tích hợp với công cụ BI.
- Xây dựng dashboard realtime với Grafana hoặc Power BI kết nối trực tiếp HDFS.
- Mở rộng phân tích sang dữ liệu kinh tế–xã hội (GDP, thất nghiệp) để đánh giá tác động đa chiều của đại dịch.

PHÂN CÔNG CÔNG VIỆC

Thành viên	Nhiệm vụ cụ thể	Tỉ lệ đóng góp
Lê Thành Danh 3123580005	• Cài đặt và cấu hình môi trường Docker Compose • Viết script get_asean_data.py thu thập dữ liệu từ API • Viết và chạy toàn bộ 12 file PySpark (1a → 4) • Upload dữ liệu lên HDFS, cấu hình cây thư mục • Debug và xử lý lỗi kỹ thuật phát sinh • Kiểm tra và xác nhận kết quả trên HDFS	50%
Nguyễn Đăng Tiến 3123580050	• Nghiên cứu lý thuyết Big Data Pipeline, Spark, HDFS, Docker • Thiết kế tiêu chí phân loại 5 Data Marts • Phân tích và diễn giải kết quả từng bước • Viết toàn bộ báo cáo theo cấu trúc chuẩn • Vẽ biểu đồ từ file CSV output • Chuẩn bị slide thuyết trình và tài liệu demo	50%

TÀI LIỆU THAM KHẢO

1. Google LLC. (2022). COVID-19 Open Data — Epidemiology Dataset. https://health.google.com/covid-19/open-data/
2. World Health Organization. (2022). COVID-19 Weekly Epidemiological Updates. https://www.who.int/emergencies/diseases/novel-coronavirus-2019
3. Apache Software Foundation. (2024). Apache Spark 3.5 Programming Guide. https://spark.apache.org/docs/latest/
4. Apache Software Foundation. (2024). HDFS Architecture Guide. https://hadoop.apache.org/docs/stable/
5. Apache Software Foundation. (2024). PySpark SQL Functions API. https://spark.apache.org/docs/latest/api/python/reference/pyspark.sql/
6. Chambers, B., & Zaharia, M. (2018). Spark: The Definitive Guide. O'Reilly Media, Inc.
7. White, T. (2015). Hadoop: The Definitive Guide (4th ed.). O'Reilly Media, Inc.
8. Karau, H., Konwinski, A., Wendell, P., & Zaharia, M. (2015). Learning Spark. O'Reilly Media.
9. Docker Inc. (2024). Docker Compose Reference. https://docs.docker.com/compose/
10. Apache Parquet. (2024). Parquet Documentation. https://parquet.apache.org/docs/
11. ASEAN Biodiaspora Virtual Centre. (2022). COVID-19 Situational Report ASEAN. https://asean.org/
12. Databricks. (2024). Delta Lake and Medallion Architecture. https://docs.databricks.com/lakehouse/medallion.html