ỦY BAN NHÂN DÂN THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC SÀI GÒN



BÁO CÁO MÔN HỌC
DỮ LIỆU LỚN

ĐỀ TÀI: XÂY DỰNG PIPELINE XỬ LÝ VÀ PHÂN TÍCH DỮ LIỆU TAXI NYC

Thành phố Hồ Chí Minh, tháng 4 năm 2026

Phân công công việc nhóm

Họ và Tên	**MSSV**	**Công việc được giao**	**Mức độ hoàn thành**	**Chữ ký**
		- Viết chương I, V. - Upload và quản lý dữ liệu trên HDFS - Phân tích EDA (schema, missing) - Tối ưu pipeline, kiểm thử	100%	
		- Viết chương II, V. - Xử lý outlier (IQR) - Làm sạch dữ liệu (duplicate) - Áp dụng business rules - Feature engineering, unit test	100%	
		- Viết chương IV, V. - Phân tích dữ liệu theo ngày/giờ - Xác định outlier - Tối ưu Aggregation, trực quan hóa	100%	
		- Viết chương III, V. - EDA thống kê mô tả - Phân tích passenger/payment - Kiểm thử end-to-end hệ thống	100%	

Tp. HCM, tháng 4 năm 2026

Các tác giả

Tp. HCM, tháng 4 năm 2026

Các tác giả

Lời nhận xét

Của giảng viên hướng dẫn

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Mục lục

Lời cam đoan **ii**

Lời cảm ơn **iii**

Lời nhận xét **iv**

Mục lục **v**

Danh sách hình ảnh **viii**

Danh sách bảng **ix**

I Tổng quan về dữ liệu lớn và bài toán phân tích giao thông đô thị **1**

1.1 Đặt vấn đề về sự cần thiết của dữ liệu lớn trong giao thông đô thị 1

1.2 Giới thiệu các công nghệ nền tảng xử lý dữ liệu lớn 2

1.3 Tổng quan về bộ dữ liệu New York Cars 3

1.4 Mục tiêu và phạm vi của dự án 4

II Kiến trúc hệ thống và cài đặt môi trường **7**

2.1 Kiến trúc pipeline 8

2.1.1 Cơ sở thiết kế 8

2.1.2 Mô hình tổng thể của pipeline 8

2.1.3 Giải thích luồng dữ liệu 9
2.1.4 Ý nghĩa của kiến trúc được lựa chọn 10
2.2 Mô hình môi trường thực thi 10
2.2.1 Vai trò của Docker trong dự án 10
2.2.2 Kiến trúc triển khai bằng Docker 11
2.2.3 Các thành phần phần mềm nền tảng 12
2.2.4 Môi trường tham chiếu cho việc giải thích kỹ thuật . . 12
2.3 Tổ chức lưu trữ trong HDFS 13
2.3.1 Nguyên tắc tổ chức dữ liệu 13
2.3.2 Cấu trúc thư mục trong HDFS 13
2.3.3 Quy trình nạp và xác nhận dữ liệu 14
2.4 Quy trình kiểm tra môi trường trước xử lý dữ liệu 14
2.4.1 Mục đích của bước kiểm tra 14
2.4.2 Sơ đồ xác nhận môi trường 15
2.4.3 Tiêu chí đánh giá trạng thái sẵn sàng 15

III Phân tích khám phá dữ liệu và làm sạch 17

3.1 Khám phá dữ liệu 17
3.1.1 Đặc điểm cấu trúc và quy mô tập dữ liệu 17
3.1.2 Kiểm tra lược đồ dữ liệu 20
3.1.3 Thống kê mô tả và nhận diện giá trị bất thường 21
3.1.4 Phân tích sự thiếu hụt và trùng lặp dữ liệu 22
3.2 Chiến lược làm sạch và xử lý dữ liệu nhiễu 24
3.2.1 Khử trùng lặp và loại bỏ giá trị thiếu 25
3.2.2 Áp dụng quy tắc nghiệp vụ để lọc dữ liệu 25
3.2.3 Chuẩn hóa thời gian và không gian 27
3.3 Kiểm soát giá trị ngoại lệ 28
3.4 Kỹ thuật đặc trưng và làm giàu dữ liệu 29

3.4.1 Chuyển đổi đặc trưng thời gian 29
3.4.2 Tính toán chỉ số hiệu suất chuyến đi 30
3.4.3 Phân tích hành vi kinh tế 30
3.5 Đánh giá chất lượng dữ liệu sau tiền xử lý 31
3.5.1 So sánh biến động dữ liệu 31
3.5.2 Kiểm chứng phân phối sau làm sạch 32

IV Tổng hợp, phân tích và trực quan hóa 34
4.1 Tổng hợp và phân tích theo thời gian 34
4.1.1 Phân tích theo giờ trong ngày 35
4.1.2 Phân tích theo giờ trong tuần 38
4.1.3 Phân tích theo giờ trong tháng 40
4.2 Tổng hợp theo nhà cung cấp, phương thức thanh toán và khu vực 42
4.2.1 So sánh hiệu suất giữa các nhà cung cấp 43
4.2.2 Cơ cấu phương thức thanh toán 44
4.2.3 Phân tích địa điểm và tuyến đường phổ biến 46

V Kết luận và hướng phát triển 50
5.1 Kết luận 50
5.2 Hướng phát triển 51

Tài liệu tham khảo 52

Danh sách hình ảnh

2.1 Kiến trúc tổng thể của pipeline xử lý dữ liệu NYC Taxi 9
2.2 Cấu trúc lưu trữ dữ liệu trong HDFS của dự án 13
2.3 Quy trình kiểm tra môi trường trước khi xử lý dữ liệu 15

3.1 Các kiểu dữ liệu trong data 21
3.2 Quy trình lọc dữ liệu theo nghiệp vụ 26
3.3 Quy trình lọc theo thời gian là không gian 27
3.4 Quy trình làm giàu dữ liệu 31
3.5 Số lượng dòng dữ liệu trước và sau khi sử lý 32

4.1 Biểu đồ thể hiện lượng khách theo từng khung giờ trong một ngày 37
4.2 Biểu đồ tương quan giữa giờ và ngày 39
4.3 Biểu đồ tỷ lệ sử dụng các phương thức thanh toán 45
4.4 Biểu đồ Top 20 điểm nóng đón khách 48
4.5 Đúng xe – đúng nơi – đúng thời điểm 49

Danh sách bảng

3.1 Danh mục thuộc tính dữ liệu NYC Taxi 19
3.2 Thống kê mô tả các thuộc tính chính 21
3.3 Thống kê số lượng giá trị thiếu (Null) trong tập dữ liệu 24
3.4 So sánh hiệu quả loại bỏ ngoại lai theo hệ số m (phương pháp IQR) 28
3.5 Thống kê mô tả các thuộc tính chính sau khi làm sạch 33

4.1 Thống kê hoạt động taxi NYC theo khung giờ 36
4.2 Thống kê hoạt động taxi NYC theo các ngày trong tuần . . . 38
4.3 Thống kê hoạt động taxi NYC chi tiết theo từng ngày trong tháng 01/2026 41
4.4 So sánh hiệu quả hoạt động giữa các nhà cung cấp dịch vụ . . 43
4.5 Thống kê hoạt động theo phương thức thanh toán 44
4.6 Thống kê Top 20 khu vực đón khách có lưu lượng cao nhất . . 47

Chương I

Tổng quan về dữ liệu lớn và bài toán phân tích giao thông đô thị

1.1. Đặt vấn đề về sự cần thiết của dữ liệu lớn trong giao thông đô thị

Trong kỷ nguyên số hóa hiện nay, khối lượng thông tin được sinh ra từ các hoạt động thường nhật của con người cũng như từ các hệ thống giám sát tự động đang tăng trưởng với một tốc độ chưa từng có trong lịch sử nhân loại. Sự bùng nổ thông tin này diễn ra ở hầu hết mọi lĩnh vực của đời sống kinh tế và xã hội, trong đó đặc biệt phải kể đến lĩnh vực quản lý và vận hành giao thông đô thị. Tại các siêu đô thị sầm uất trên thế giới, các hệ thống điều hành phương tiện vận tải công cộng, mạng lưới taxi và các nền tảng gọi xe công nghệ liên tục tạo ra những tập dữ liệu khổng lồ mỗi ngày. Khối lượng dữ liệu giao thông đô thị này vô cùng đồ sộ, điển hình như tập dữ liệu ghi nhận hoạt động của hệ thống taxi tại thành phố New York thường xuyên đạt mức xấp xỉ ba triệu chuyến đi chỉ trong vòng một tháng. Sự gia tăng đột biến về cả quy mô lẫn tốc độ phát sinh dữ liệu đã đặt ra những thách thức kỹ thuật vô cùng to lớn đối với các phương pháp lưu trữ và cơ chế xử lý tính toán cục bộ truyền thống. Khi phải đối mặt với hàng triệu bản ghi giao dịch phức tạp, một hệ thống máy tính thông thường hoặc cấu trúc cơ sở dữ liệu quan hệ đơn

lẻ rất dễ gặp phải tình trạng quá tải tài nguyên, dẫn đến sự chậm trễ trong việc phản hồi, hoặc thậm chí là phát sinh các lỗi nghiêm trọng làm gián đoạn toàn bộ quá trình vận hành. Trong bối cảnh đó, Dữ liệu lớn không còn được xem như một xu hướng công nghệ đơn thuần mà đã trở thành một yêu cầu tất yếu đối với các hệ thống phân tích hiện đại [1, 2]. Các công nghệ Dữ liệu lớn cung cấp một nền tảng kỹ thuật vững chắc, cho phép phân tán gánh nặng tính toán và lưu trữ ra nhiều máy trạm khác nhau, từ đó duy trì được sự ổn định của hệ thống. Thông qua việc ứng dụng các giải pháp kiến trúc hiện đại, quá trình xử lý dữ liệu không chỉ dừng lại ở việc lưu trữ đơn thuần mà còn mở ra cơ hội to lớn để tiến hành phân tích sâu, khai phá những tri thức tiềm ẩn, đánh giá chính xác hiệu suất vận hành của các nhà cung cấp dịch vụ và nắm bắt tường tận hành vi chi tiêu của hành khách. Những giá trị này đặc biệt có ý nghĩa đối với bài toán giao thông đô thị, nơi dữ liệu không chỉ phục vụ quan sát hiện trạng mà còn hỗ trợ cho quy hoạch và điều hành hệ thống vận tải [3].

1.2. Giới thiệu các công nghệ nền tảng xử lý dữ liệu lớn

Để giải quyết một cách triệt để và hiệu quả bài toán phân tích dữ liệu với khối lượng đặc biệt lớn, dự án này đã quyết định áp dụng một hệ sinh thái công nghệ tiên tiến, trong đó lấy nền tảng Apache Hadoop kết hợp cùng Apache Spark làm trung tâm của toàn bộ kiến trúc hệ thống. Thành phần cốt lõi đầu tiên và cũng là nền móng của hệ thống chính là hệ thống lưu trữ phân tán Hadoop Distributed File System, thường được cộng đồng công nghệ gọi tắt là HDFS. Chức năng chính và quan trọng nhất của hệ thống HDFS là cung cấp một không gian lưu trữ được phân tán rộng khắp, cho phép phân mảnh và lưu trữ các tệp dữ liệu khổng lồ trên nhiều máy chủ khác nhau trong

một cụm máy tính, đồng thời vẫn bảo đảm tính nhất quán và khả năng chịu lỗi cao của dữ liệu [5]. Kiến trúc của hệ thống HDFS đóng vai trò như một kho chứa khổng lồ, là nơi trực tiếp tiếp nhận và lưu trữ toàn bộ dữ liệu đầu vào ở trạng thái nguyên bản nhất. Bên cạnh đó, đây cũng là nơi an toàn để lưu lại các kết quả trung gian và kết quả cuối cùng sau khi quá trình tính toán kết thúc, qua đó giúp phân tách một cách rõ ràng giữa các tầng dữ liệu gốc, tầng dữ liệu đang trong quá trình xử lý và tầng dữ liệu đầu ra hoàn chỉnh. Song hành cùng với hệ thống lưu trữ HDFS, nền tảng Apache Spark được tích hợp sâu vào kiến trúc để đảm nhiệm vai trò là bộ máy xử lý tính toán trung tâm của toàn bộ dự án. So với mô hình MapReduce truyền thống, Spark nổi bật nhờ cơ chế xử lý dữ liệu trong bộ nhớ, qua đó làm giảm đáng kể chi phí đọc ghi lặp lại trên đĩa và tăng hiệu năng cho các bài toán phân tích lặp [4, 6]. Việc lựa chọn Spark vì vậy là phù hợp với đặc thù của bài toán phân tích giao thông, nơi dữ liệu vừa có quy mô lớn vừa đòi hỏi khả năng tổng hợp linh hoạt theo nhiều chiều phân tích khác nhau. Nền tảng này không chỉ hỗ trợ xử lý song song trên quy mô lớn mà còn duy trì khả năng tương thích chặt chẽ với hệ sinh thái Hadoop [6]. Để có thể tương tác và điều khiển sức mạnh của Apache Spark, dự án sử dụng Python làm ngôn ngữ lập trình chính yếu, thông qua thư viện PySpark chuyên dụng. Việc sử dụng Python mang lại tính linh hoạt cao trong quá trình phát triển mã nguồn, đồng thời hỗ trợ tốt cho việc xây dựng notebook và trực quan hóa kết quả phân tích [9].

1.3. Tổng quan về bộ dữ liệu New York Cars

Trái tim của toàn bộ quá trình phân tích, khám phá và mô hình hóa trong dự án này chính là bộ dữ liệu thực tế ghi nhận chi tiết các chuyến đi của hệ thống taxi màu vàng đặc trưng tại thành phố New York. Giới hạn phạm vi nghiên cứu của dự án tập trung chuyên sâu vào lượng dữ liệu được thu thập

trong tháng một của năm hai không hai mươi sáu. Bộ dữ liệu này được công bố bởi Ủy ban Taxi và Limousine thành phố New York, là một nguồn dữ liệu chính thức và có độ tin cậy cao đối với các nghiên cứu về giao thông đô thị [10]. Về mặt định dạng kỹ thuật, tập dữ liệu đầu vào được lưu trữ dưới chuẩn định dạng Parquet. Đây là một định dạng lưu trữ theo cấu trúc cột, được tối ưu cho các hệ thống phân tích quy mô lớn nhờ khả năng nén tốt và hỗ trợ truy vấn theo cột hiệu quả [7]. Đánh giá về mặt quy mô, tập dữ liệu này có dung lượng xấp xỉ năm trăm megabyte, chứa đựng một lượng thông tin khổng lồ với tổng cộng 3.724.889 bản ghi riêng biệt. Con số này phản ánh một cách chân thực và sống động mức độ hoạt động tấp nập của mạng lưới giao thông đô thị chỉ trong một khoảng thời gian ngắn là ba mươi mốt ngày. Đi sâu vào phân tích cấu trúc bên trong, bộ dữ liệu được tổ chức một cách khoa học với hai mươi trường thuộc tính thông tin đa dạng, bao phủ gần như toàn diện mọi khía cạnh và đặc trưng quan trọng của mỗi chuyến đi. Các trường thông tin cơ bản bao gồm mã định danh nhà cung cấp dịch vụ, thời điểm đón khách, thời điểm trả khách, số lượng hành khách, quãng đường di chuyển và các mã khu vực đón trả khách. Bên cạnh đó, bộ dữ liệu còn ghi nhận nhóm thông tin có giá trị phân tích cao liên quan đến cấu trúc chi phí và hành vi thanh toán của khách hàng, như giá cước cơ bản, tiền boa, thuế, phụ phí và hình thức thanh toán. Việc khai thác một nguồn dữ liệu mở, có cấu trúc rõ ràng và tính nhất quán cao từ một cơ quan quản lý chính thức đã tạo nền tảng thuận lợi cho các bước làm sạch, chuẩn hóa và phân tích ở những chương tiếp theo [10].

1.4. Mục tiêu và phạm vi của dự án

Dự án này được thiết lập với một mục tiêu cốt lõi và xuyên suốt là xây dựng thành công một chu trình xử lý Dữ liệu lớn hoàn chỉnh, bao quát toàn

bộ mọi khâu từ bước tải và tiếp nhận nguồn dữ liệu thô nguyên bản, thông qua hàng loạt các kỹ thuật làm sạch và xử lý chuyên sâu, cho đến khi xuất ra được những kết quả tổng hợp có giá trị và các báo cáo trực quan sinh động. Để hiện thực hóa được mục tiêu đầy tham vọng này, toàn bộ kiến trúc của hệ thống đã được nhóm nghiên cứu thiết kế và phân chia một cách logic theo một cấu trúc đường ống bao gồm năm bước cơ bản mang tính nối tiếp và kế thừa lẫn nhau. Khởi đầu chu trình, dữ liệu sẽ được hệ thống thu nhận trực tiếp từ nguồn cung cấp công khai của tổ chức quản lý giao thông đô thị. Ngay sau khi được tải về, toàn bộ tập dữ liệu thô này sẽ được đưa thẳng vào lưu trữ bên trong hệ thống phân tán HDFS, đóng vai trò như một tầng dữ liệu gốc nguyên bản. Việc thiết lập tầng lưu trữ sơ khởi này mang một ý nghĩa đặc biệt quan trọng trong việc bảo vệ tính nguyên trạng của thông tin, đồng thời phục vụ đắc lực cho các công tác đối chiếu, so sánh và kiểm chứng kết quả xuyên suốt toàn bộ vòng đời phát triển của dự án [5]. Giai đoạn thứ ba được xem là trái tim của quá trình tính toán cơ học, nơi công cụ Apache Spark chính thức tham gia vào hệ thống để gánh vác các tác vụ nặng nề. Tại đây, Spark sẽ đọc dữ liệu trực tiếp từ HDFS, tiến hành các kỹ thuật khám phá dữ liệu ban đầu, nhận diện các vấn đề bất cập về mặt chất lượng, sau đó thực thi các thuật toán làm sạch, loại bỏ triệt để các giá trị nhiễu, các giá trị ngoại lai và tiến hành tổng hợp dữ liệu theo nhiều chiều hướng phân tích khác nhau. Trải qua quá trình tinh lọc và biến đổi phức tạp, dữ liệu sạch cùng với các bảng thông tin đã được tính toán tổng hợp sẽ một lần nữa được ghi ngược trở lại hệ thống HDFS. Tuy nhiên, ở lần ghi này, dữ liệu được định tuyến để lưu trữ tại một phân vùng hoàn toàn độc lập, tạo thành tầng dữ liệu đã qua xử lý, tách biệt tuyệt đối với nguồn dữ liệu thô ban đầu. Bước cuối cùng của chu trình là việc khai thác khối lượng thông tin đã được tinh chế và tổ chức ngăn nắp này để phục vụ trực tiếp cho các công tác lập báo cáo và thiết kế các biểu đồ trực quan hóa, hỗ trợ tối đa cho quá trình nhận định và ra quyết

định. Về mặt quản trị và vận hành dự án, công việc được phân bổ vô cùng rõ ràng và rành mạch giữa các thành viên trong nhóm nghiên cứu, nhằm tối ưu hóa tiến độ và đảm bảo chất lượng của từng hạng mục. Việc thiết kế một kiến trúc phân tầng kết hợp với sự phân công lao động chuyên môn hóa không chỉ giúp hệ thống duy trì được sự rõ ràng về mặt cấu trúc, dễ dàng trong việc kiểm soát các lỗi phát sinh và theo dõi tiến độ công việc, mà còn cung cấp một khả năng mở rộng hệ thống vô cùng linh hoạt trong tương lai. Hơn thế nữa, để đảm bảo tính đồng nhất cao nhất và loại trừ triệt để mọi rủi ro liên quan đến sự sai lệch môi trường phần mềm giữa các máy tính cá nhân của từng thành viên, nhóm đã thống nhất chuẩn hóa toàn bộ quá trình triển khai hệ thống thông qua mô hình nền tảng Docker kết hợp với hệ điều hành Ubuntu, biến đây trở thành tiêu chuẩn chung cho mọi hoạt động thực thi mã nguồn của dự án [8].

Chương II

Kiến trúc hệ thống và cài đặt môi trường

Trong các bài toán xử lý dữ liệu lớn, hiệu quả của hệ thống không chỉ phụ thuộc vào thuật toán mà còn phụ thuộc chặt chẽ vào cách tổ chức hạ tầng và môi trường thực thi. Nếu kiến trúc lưu trữ, xử lý và khai thác kết quả không được thiết kế đồng bộ, hệ thống rất dễ phát sinh lỗi trong quá trình vận hành, đặc biệt khi triển khai theo hình thức làm việc nhóm trên nhiều máy khác nhau. Đối với đề tài phân tích dữ liệu chuyến đi taxi NYC tháng 01/2026, nhóm lựa chọn kiến trúc kết hợp giữa HDFS và Apache Spark nhằm xây dựng một pipeline có khả năng tiếp nhận dữ liệu đầu vào, lưu trữ phân tán, xử lý song song và cung cấp đầu ra cho báo cáo và trực quan hóa [5, 6].

Điểm cần nhấn mạnh là hệ thống của nhóm không chỉ được mô tả ở mức lý thuyết mà còn được triển khai trên thực tế theo mô hình Docker. Điều này có ý nghĩa đặc biệt quan trọng, bởi cấu hình phần mềm trên máy cá nhân của từng thành viên có thể khác nhau, nhất là ở phiên bản Java, cách cài đặt Hadoop hoặc tổ chức đường dẫn hệ thống. Việc chuẩn hóa bằng Docker giúp giảm sai lệch giữa các môi trường cá nhân, trong khi phần trình bày học thuật của chương này vẫn làm rõ bản chất kỹ thuật của các thành phần như Java, Hadoop, Spark, HDFS và Jupyter Notebook [8, 9].

Trên cơ sở đó, chương này được tổ chức thành bốn nội dung chính. Thứ nhất, chương trình bày kiến trúc tổng thể của pipeline xử lý dữ liệu. Thứ hai, chương mô tả mô hình môi trường thực thi của hệ thống, trong đó nhấn mạnh vai trò chuẩn hóa của Docker và cấu hình kỹ thuật nền tảng. Thứ ba, chương phân tích cách tổ chức không gian lưu trữ trong HDFS. Cuối cùng, chương xây dựng quy trình kiểm tra môi trường trước khi bắt đầu xử lý dữ liệu.

2.1. Kiến trúc pipeline

2.1.1 Cơ sở thiết kế

Kiến trúc hệ thống được xây dựng trên ba yêu cầu chủ đạo. Thứ nhất, dữ liệu đầu vào phải được bảo toàn nguyên trạng để phục vụ đối chiếu và kiểm chứng trong suốt quá trình thực hiện đề tài. Thứ hai, hệ thống cần hỗ trợ xử lý dữ liệu với quy mô lớn hơn khả năng của các công cụ xử lý cục bộ thông thường. Thứ ba, các tầng dữ liệu và các bước xử lý phải được tách biệt đủ rõ ràng để thuận lợi cho việc kiểm tra, tái lập kết quả và mở rộng hệ thống về sau.

Từ các yêu cầu đó, nhóm lựa chọn mô hình pipeline gồm năm bước liên tiếp, trong đó dữ liệu được di chuyển qua các tầng lưu trữ và xử lý theo một thứ tự xác định. Mỗi bước trong pipeline có một chức năng riêng, song tất cả đều liên kết với nhau thông qua HDFS và Spark.

2.1.2 Mô hình tổng thể của pipeline

Pipeline xử lý dữ liệu được tổ chức theo năm bước cơ bản:

1. Thu nhận dữ liệu từ nguồn công bố chính thức.

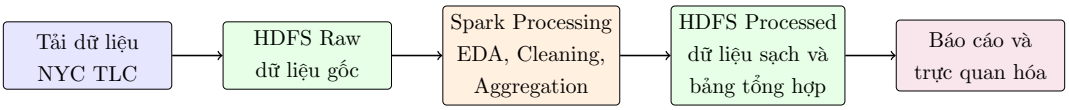
2. Lưu trữ dữ liệu gốc trong HDFS.

3. Xử lý dữ liệu bằng Apache Spark.

4. Ghi dữ liệu đã xử lý trở lại HDFS.

5. Khai thác dữ liệu đầu ra cho báo cáo và trực quan hóa.

Mô hình tổng thể của pipeline được thể hiện trong Hình 2.1.



Hình 2.1: Kiến trúc tổng thể của pipeline xử lý dữ liệu NYC Taxi

2.1.3 Giải thích luồng dữ liệu

Ở giai đoạn đầu, dữ liệu được tải từ nguồn dữ liệu mở của NYC TLC dưới định dạng Parquet. Đây là dữ liệu nguyên bản, chưa trải qua bất kỳ phép biến đổi nào. Việc sử dụng dữ liệu từ nguồn chính thức giúp bảo đảm tính xác thực của bộ dữ liệu và tạo cơ sở cho việc đánh giá chất lượng dữ liệu ở các bước tiếp theo.

Sau khi được tải về, dữ liệu được lưu vào HDFS ở tầng Raw. Trong triển khai thực tế của dự án, dữ liệu được đặt trong không gian tên `/nyc_taxi/bronze/raw/`; tuy nhiên, về bản chất, tầng này vẫn đóng vai trò là nơi lưu trữ dữ liệu đầu vào nguyên gốc. Việc tách riêng dữ liệu nguồn có ý nghĩa quan trọng trong việc bảo toàn tính toàn vẹn và hỗ trợ so sánh trước – sau xử lý.

Từ tầng Raw, Apache Spark đảm nhận vai trò là công cụ xử lý trung tâm. Spark đọc dữ liệu trực tiếp từ HDFS, tiến hành khám phá dữ liệu, nhận diện vấn đề chất lượng, làm sạch dữ liệu, tạo thêm đặc trưng mới và thực hiện các phép tổng hợp. Việc lựa chọn Spark là phù hợp với đặc điểm của bài toán, bởi Spark hỗ trợ xử lý song song, có hiệu năng tốt đối với dữ liệu lớn và tương thích chặt chẽ với hệ sinh thái Hadoop.

Sau khi hoàn tất các bước xử lý, dữ liệu sạch và các bảng tổng hợp được ghi trở lại HDFS ở tầng Processed. Trong cấu trúc thực tế của dự án, tầng này tương ứng với các thư mục `/nyc_taxi/silver/cleaned/` và `/nyc_taxi/gold/`. Cách tổ chức này vừa giúp tách biệt dữ liệu đã xử lý khỏi dữ liệu gốc, vừa tạo ra các đầu ra rõ ràng cho các bước kiểm chứng và trình bày kết quả.

Cuối cùng, dữ liệu ở tầng Processed được khai thác cho báo cáo và trực quan hóa. Các script kiểm tra kết quả, các notebook và các biểu đồ đều làm việc trên dữ liệu ở tầng này thay vì truy cập lại dữ liệu Raw. Nhờ đó, tầng báo cáo được tách biệt với tầng xử lý, phù hợp với nguyên tắc thiết kế hệ thống dữ liệu hiện đại.

2.1.4 Ý nghĩa của kiến trúc được lựa chọn

Kiến trúc pipeline năm bước mang lại ba lợi ích chính. Thứ nhất, hệ thống có cấu trúc rõ ràng, dễ kiểm soát và dễ theo dõi tiến độ xử lý. Thứ hai, việc kết hợp HDFS và Spark cho phép hệ thống xử lý dữ liệu với quy mô lớn hiệu quả hơn so với mô hình cục bộ thông thường. Thứ ba, kiến trúc này có khả năng mở rộng tương đối tốt, bởi các thành phần lưu trữ, xử lý và báo cáo có thể được phát triển độc lập mà không làm phá vỡ cấu trúc chung của hệ thống.

2.2. Mô hình môi trường thực thi

2.2.1 Vai trò của Docker trong dự án

Khác với cách triển khai hoàn toàn cục bộ trên từng máy, hệ thống của nhóm được vận hành chủ yếu thông qua Docker. Đây là một lựa chọn có cơ sở thực tiễn rõ ràng. Trong bối cảnh làm việc nhóm, mỗi thành viên có thể sử dụng máy với cấu hình khác nhau, hệ điều hành khác nhau, thậm chí phiên

bản Java khác nhau. Nếu hệ thống phụ thuộc hoàn toàn vào môi trường cài đặt của từng cá nhân, nguy cơ phát sinh lỗi cấu hình là rất lớn.

Docker giúp chuẩn hóa môi trường thực thi bằng cách đóng gói các thành phần chính của hệ thống vào các container riêng biệt. Trong dự án hiện tại, tệp `docker-compose.yml` mô tả ba dịch vụ trọng tâm gồm `namenode`, `datanode` và `spark`. Hai dịch vụ đầu tạo thành lớp lưu trữ HDFS, còn dịch vụ `spark` là nơi thực thi các script xử lý, các notebook và các ca kiểm thử. Nhờ đó, cùng một mã nguồn có thể được vận hành theo cùng một cách trên các máy khác nhau mà không bị chi phối trực tiếp bởi sự khác biệt của môi trường cá nhân [8].

2.2.2 Kiến trúc triển khai bằng Docker

Trong cấu hình hiện tại, dịch vụ `namenode` đảm nhận quản lý không gian tên của HDFS và cung cấp giao diện web để giám sát hệ thống. Dịch vụ `datanode` chịu trách nhiệm lưu trữ các block dữ liệu. Dịch vụ `spark` được xây dựng từ ảnh nền Spark có hỗ trợ Python, sau đó được bổ sung các thư viện cần thiết thông qua tệp `requirements.txt`. Bên cạnh đó, container `spark` được gắn kết trực tiếp với các thư mục `src/`, `notebooks/`, `data/`, `tests/` và `docs/` của dự án. Điều này cho phép mã nguồn được chỉnh sửa trên máy cục bộ nhưng được thực thi trong một môi trường đã chuẩn hóa.

Một đặc điểm quan trọng của hệ thống là việc truy cập HDFS được điều chỉnh tùy theo môi trường chạy. Khi thực thi trong Docker, Spark kết nối đến HDFS thông qua tên dịch vụ `namenode:9000`. Khi thực thi ngoài Docker, hệ thống có thể chuyển về `localhost:9000`. Cách tổ chức này cho thấy môi trường thực thi của dự án đã được thiết kế theo hướng thích nghi, nhưng Docker vẫn là mô hình triển khai thống nhất trong thực tế sử dụng của nhóm.

2.2.3 Các thành phần phần mềm nền tảng

Mặc dù hệ thống được vận hành bằng Docker, các thành phần phần mềm nền tảng vẫn cần được mô tả rõ trong luận văn để làm rõ bản chất kỹ thuật. Các thành phần này bao gồm:

- OpenJDK 11, đóng vai trò nền tảng thực thi cho Hadoop và Spark.
- Hadoop 3.3.6, đảm nhiệm chức năng lưu trữ phân tán thông qua HDFS.
- Spark 3.5.1, chịu trách nhiệm cho toàn bộ quá trình xử lý dữ liệu.
- Python 3 và Jupyter Notebook, hỗ trợ phát triển script, notebook và trực quan hóa.

Việc mô tả các thành phần trên vẫn là cần thiết dù hệ thống chạy trong Docker, bởi Docker chỉ đóng vai trò lớp triển khai thống nhất, còn bản chất xử lý dữ liệu vẫn phụ thuộc vào sự phối hợp giữa Java, Hadoop, Spark và Python.

2.2.4 Môi trường tham chiếu cho việc giải thích kỹ thuật

Để trình bày bản chất kỹ thuật một cách chặt chẽ, luận văn vẫn sử dụng mô hình Ubuntu hoặc WSL2 kết hợp với Hadoop *pseudo-distributed* làm môi trường tham chiếu. Điều này giúp giải thích rõ cơ chế hoạt động của HDFS, NameNode, DataNode, Spark và các biến môi trường liên quan, vốn khó thể hiện đầy đủ nếu chỉ mô tả ở cấp độ container. Nói cách khác, Docker là mô hình triển khai chuẩn hóa của nhóm, còn môi trường tham chiếu là công cụ học thuật để diễn giải cấu trúc kỹ thuật của hệ thống.

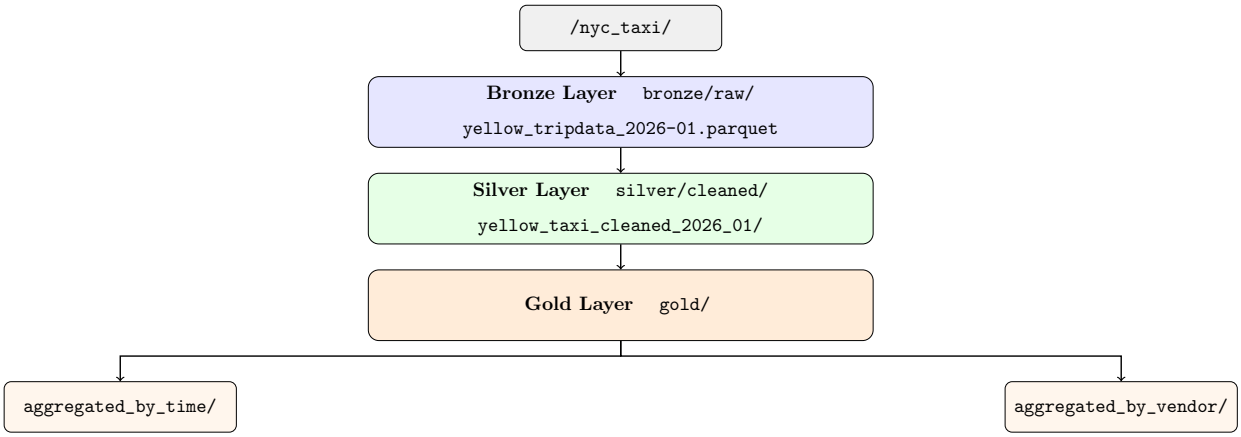
2.3. Tổ chức lưu trữ trong HDFS

2.3.1 Nguyên tắc tổ chức dữ liệu

Hệ thống lưu trữ được xây dựng dựa trên nguyên tắc tách biệt dữ liệu gốc, dữ liệu đã xử lý và các kết quả tổng hợp. Về mặt học thuật, cách tổ chức này phản ánh đúng mô hình phân tầng dữ liệu trong hệ thống Big Data. Về mặt thực tiễn, nó giúp nhóm dễ kiểm tra hơn khi cần xác định dữ liệu đầu vào, dữ liệu trung gian và dữ liệu đầu ra của pipeline.

2.3.2 Cấu trúc thư mục trong HDFS

Trong triển khai hiện tại, không gian lưu trữ của hệ thống được tổ chức dưới namespace `/nyc_taxi/`. Cấu trúc tổng quát được thể hiện trong Hình 2.2.



Hình 2.2: Cấu trúc lưu trữ dữ liệu trong HDFS của dự án

Trong cấu trúc này, thư mục `bronze/raw/` lưu dữ liệu đầu vào nguyên bản. Thư mục `silver/cleaned/` lưu dữ liệu sau khi đã được làm sạch và bổ sung đặc trưng. Tầng `gold/` chứa các tập dữ liệu tổng hợp phục vụ phân tích theo thời gian, theo nhà cung cấp dịch vụ và theo các chiều khác của bài toán. Cách đặt tên theo mô hình Bronze – Silver – Gold giúp liên hệ trực tiếp với kiến trúc dữ liệu hiện đại, trong đó mỗi tầng phản ánh một mức độ tinh chỉnh và giá trị gia tăng của dữ liệu.

2.3.3 Quy trình nạp và xác nhận dữ liệu

Sau khi dữ liệu được tải từ nguồn công bố chính thức, hệ thống thực hiện bước nạp dữ liệu vào HDFS thông qua thành phần xử lý trong môi trường Docker. Về bản chất, đây là giai đoạn đưa dữ liệu từ môi trường lưu trữ cục bộ sang môi trường lưu trữ phân tán. Nếu dữ liệu không được nạp đúng vào tầng `bronze/raw/`, toàn bộ các bước xử lý sau đó sẽ không thể truy cập đúng đầu vào.

Sau khi nạp dữ liệu, hệ thống cần xác nhận rằng dữ liệu đã tồn tại trong HDFS với đúng đường dẫn mong muốn. Việc xác nhận này có thể được thực hiện bằng công cụ dòng lệnh hoặc thông qua giao diện NameNode Web UI. Trong triển khai thực tế của dự án, giao diện web tại cổng 9870 đóng vai trò quan trọng trong việc kiểm tra nhanh cấu trúc thư mục, số lượng tệp và trạng thái lưu trữ của cụm HDFS.

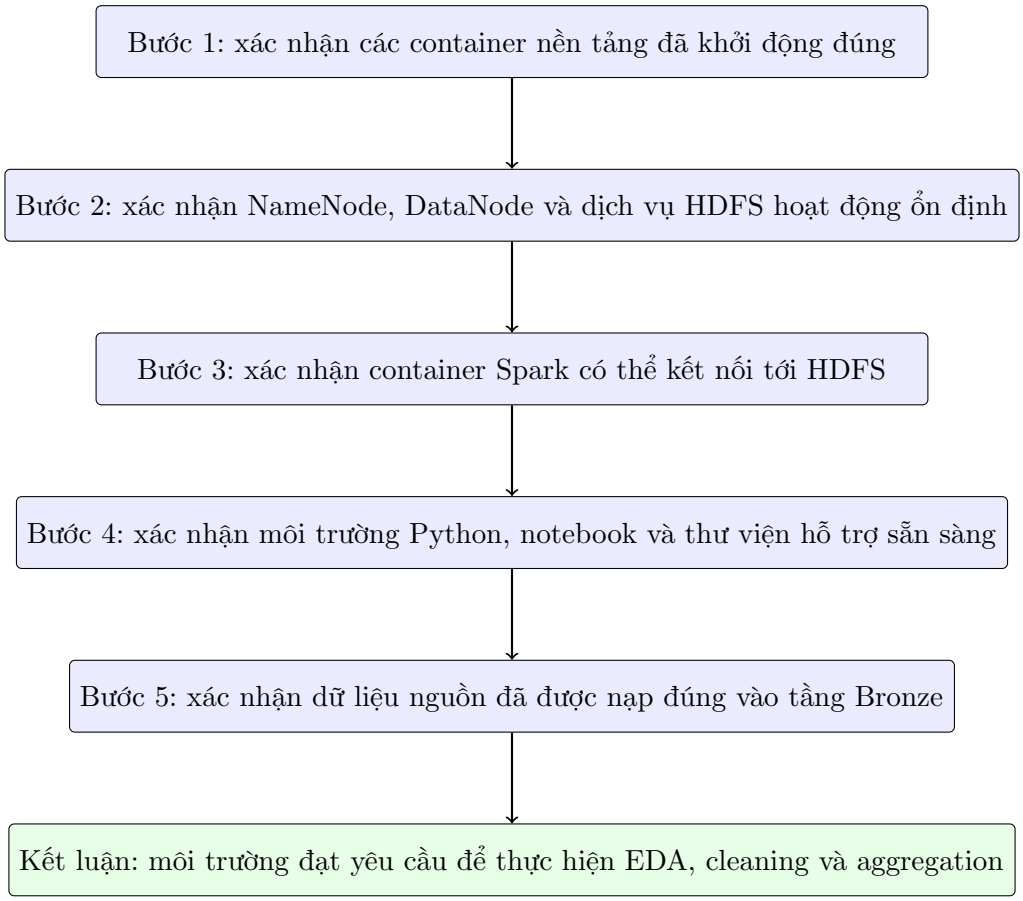
2.4. Quy trình kiểm tra môi trường trước xử lý dữ liệu

2.4.1 Mục đích của bước kiểm tra

Trước khi bắt đầu EDA, làm sạch và tổng hợp dữ liệu, hệ thống cần được kiểm tra để xác nhận rằng mọi thành phần đang hoạt động đúng. Bước kiểm tra này giúp tách biệt lỗi do dữ liệu với lỗi do môi trường. Nếu không thực hiện bước kiểm tra ban đầu, các sai lệch về cấu hình Java, lỗi khởi động HDFS, lỗi kết nối giữa Spark và HDFS hoặc lỗi thiếu thư viện Python sẽ rất khó được phát hiện sớm.

2.4.2 Sơ đồ xác nhận môi trường

Quy trình kiểm tra môi trường được biểu diễn trong Hình 2.3. Trình tự kiểm tra đi từ nền tảng thấp đến nền tảng cao, phản ánh đúng quan hệ phụ thuộc giữa các thành phần của hệ thống.



Hình 2.3: Quy trình kiểm tra môi trường trước khi xử lý dữ liệu

2.4.3 Tiêu chí đánh giá trạng thái sẵn sàng

Một môi trường chỉ được xem là sẵn sàng khi đồng thời đáp ứng ba nhóm điều kiện. Nhóm thứ nhất là điều kiện hạ tầng, bao gồm các dịch vụ Docker và HDFS phải hoạt động ổn định. Nhóm thứ hai là điều kiện xử lý, tức là Spark phải có khả năng truy cập HDFS và khởi tạo tiến trình xử lý dữ liệu. Nhóm thứ ba là điều kiện dữ liệu và công cụ hỗ trợ, bao gồm dữ liệu đầu vào

đã tồn tại đúng vị trí, Python đã sẵn sàng và Jupyter Notebook có thể phục vụ cho việc kiểm tra và trực quan hóa.

Nếu một trong các nhóm điều kiện trên không đạt, quá trình xử lý dữ liệu ở các chương tiếp theo rất dễ phát sinh lỗi. Chẳng hạn, nếu container HDFS chưa khởi động đầy đủ, Spark sẽ không thể đọc dữ liệu; nếu đường dẫn HDFS chưa được thiết lập đúng, các script sẽ phát sinh lỗi truy cập; hoặc nếu môi trường Python thiếu thư viện, notebook hỗ trợ cũng không thể vận hành bình thường. Vì vậy, bước kiểm tra môi trường cần được xem như một giai đoạn bắt buộc trước khi thực hiện pipeline chính.

Nhìn chung, Chương 2 đã trình bày hai lớp nền tảng của đề tài: lớp kiến trúc dữ liệu và lớp môi trường thực thi. Về mặt kiến trúc, hệ thống được tổ chức theo pipeline năm bước với các tầng dữ liệu tách biệt. Về mặt triển khai, hệ thống được chuẩn hóa bằng Docker nhằm bảo đảm tính thống nhất giữa các thành viên trong nhóm. Đây chính là cơ sở để các bước khám phá dữ liệu, làm sạch, tổng hợp và trực quan hóa ở các chương tiếp theo có thể được thực hiện một cách ổn định và có khả năng tái lập.

Chương III

Phân tích khám phá dữ liệu và làm sạch

3.1. Khám phá dữ liệu

Mục tiêu của giai đoạn này là đánh giá tổng quan hiện trạng của bộ dữ liệu gốc trước khi tiến hành các bước tiền xử lý và làm sạch dữ liệu. Thông qua quá trình phân tích khám phá dữ liệu, nhóm tiến hành kiểm tra cấu trúc, kiểu dữ liệu, cũng như phân bố của các biến trong tập dữ liệu.

Kết quả phân tích cho thấy bộ dữ liệu chứa nhiều thông tin có giá trị, có thể khai thác cho các bước phân tích và xây dựng mô hình tiếp theo. Tuy nhiên, dữ liệu cũng tồn tại một số vấn đề kỹ thuật như giá trị thiếu, giá trị ngoại lai và sự không nhất quán giữa các biến. Những vấn đề này có thể ảnh hưởng đến độ chính xác của kết quả phân tích nếu không được xử lý phù hợp.

Do đó, việc thực hiện EDA đầu tiên đóng vai trò quan trọng trong việc phát hiện và định hướng các bước làm sạch dữ liệu ở các giai đoạn tiếp theo, nhằm nâng cao chất lượng và độ tin cậy của dữ liệu đầu vào.

3.1.1 Đặc điểm cấu trúc và quy mô tập dữ liệu

Bộ dữ liệu NYC Yellow Taxi tháng 01/2026 được thu thập và lưu trữ dưới định dạng Parquet, phù hợp cho việc xử lý dữ liệu lớn với hiệu năng cao. Kết

quả phân tích ban đầu cho thấy tập dữ liệu có quy mô lớn và cấu trúc tương đối đầy đủ.

Cụ thể, tập dữ liệu bao gồm tổng cộng 3.724.889 bản ghi, tương ứng với số lượng chuyến đi được ghi nhận trong tháng. Về cấu trúc, dữ liệu gồm 20 trường thông tin, bao phủ các đặc trưng quan trọng của mỗi chuyến đi. Ngoài các trường cơ bản theo danh mục chuẩn, bộ dữ liệu còn chứa một số biến bổ sung như Airport_fee và cbd_congestion_fee, góp phần cung cấp thêm thông tin chi tiết phục vụ cho phân tích.

Bên cạnh đó, quá trình kiểm tra dữ liệu trùng lặp cho thấy tập dữ liệu có mức độ toàn vẹn cao, với 0% bản ghi trùng lặp, tức toàn bộ 3.724.889 dòng đều là duy nhất. Điều này đảm bảo tính tin cậy của dữ liệu trong các bước phân tích và xử lý tiếp theo.

Bảng 3.1: Danh mục thuộc tính dữ liệu NYC Taxi

Tên cột	**Ý nghĩa**	**Đơn vị**
VendorID	Mã nhà cung cấp dịch vụ (1: CMT, 2: VeriFone)	ID (1 hoặc 2)
tpep_pickup_datetime	Thời điểm khách bắt đầu lên xe	Thời gian
tpep_dropoff_datetime	Thời điểm khách kết thúc chuyến đi	Thời gian
passenger_count	Số lượng hành khách trên xe	Người
trip_distance	Quãng đường di chuyển của chuyến đi	Dặm (Miles)
RatecodeID	Mã biểu giá áp dụng cuối cùng	ID (1-6)
PULocationID	Khu vực đón khách (TLC Taxi Zone)	ID (1-265)
DOLocationID	Khu vực trả khách (TLC Taxi Zone)	ID (1-265)
payment_type	Phương thức thanh toán (Tiền mặt/Thẻ/...)	Mã (1-6)
fare_amount	Giá cước tính theo thời gian và khoảng cách	USD ($)
extra	Các khoản phụ phí giờ cao điểm/ban đêm	USD ($)
mta_tax	Thuế MTA (Metropolitan Transportation Authority)	USD ($)
tip_amount	Tiền Tip (chỉ ghi nhận khi trả bằng thẻ)	USD ($)
tolls_amount	Tổng phí cầu đường	USD ($)
improvement_surcharge	Phí cải thiện cơ sở hạ tầng giao thông	USD ($)
total_amount	Tổng số tiền hóa đơn khách phải trả	USD ($)
congestion_surcharge	Phí ùn tắc giao thông (tại Manhattan)	USD ($)
Airport_fee	Phí dịch vụ đón/trả tại sân bay	USD ($)

Bảng trên trình bày chi tiết các thuộc tính chính trong bộ dữ liệu NYC Yellow Taxi, bao gồm tên cột, ý nghĩa và đơn vị đo lường tương ứng. Các biến trong tập dữ liệu phản ánh đầy đủ thông tin của một chuyến đi taxi, từ thời gian, vị trí đón/trả khách, đến các yếu tố liên quan đến chi phí và phương thức thanh toán.

Cụ thể, nhóm biến thời gian (tpep_pickup_datetime, tpep_dropoff_datetime) cho phép xác định khoảng thời gian thực hiện chuyến đi. Nhóm biến không

gian (PULocationID, DOLocationID) thể hiện khu vực đón và trả khách theo hệ thống phân vùng của TLC. Ngoài ra, các biến như trip_distance, passenger_count cung cấp thông tin về đặc điểm hành trình.

Đặc biệt, nhóm biến liên quan đến chi phí (fare_amount, extra, tip_amount, tolls_amount, total_amount,...) cho phép phân tích chi tiết cấu trúc giá cước và hành vi chi tiêu của khách hàng. Một số khoản phí bổ sung như congestion_surcharge và Airport_fee phản ánh các chính sách quản lý giao thông đô thị và dịch vụ đặc thù tại sân bay.

Nhìn chung, hệ thống thuộc tính của bộ dữ liệu được thiết kế đầy đủ và có tính nhất quán cao, tạo điều kiện thuận lợi cho việc phân tích, trực quan hóa và xây dựng các mô hình dự báo trong các bước tiếp theo.

3.1.2 Kiểm tra lược đồ dữ liệu

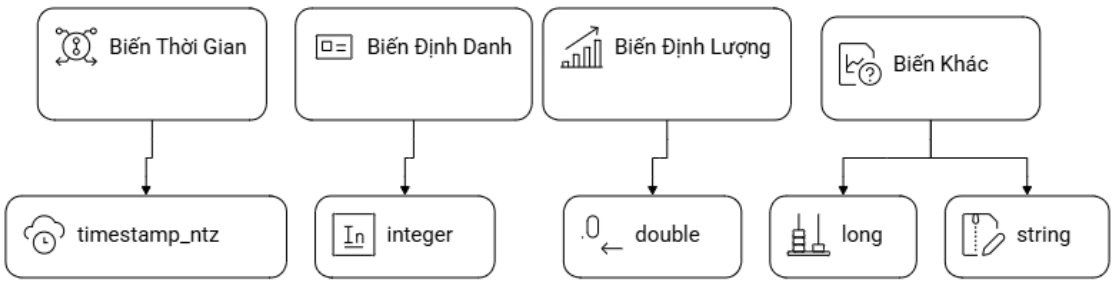
Bộ dữ liệu được tổ chức dưới dạng cấu trúc phân cấp với các kiểu dữ liệu được lựa chọn phù hợp nhằm tối ưu hóa cho việc lưu trữ và xử lý trên hệ thống dữ liệu lớn. Cách tổ chức này giúp đảm bảo hiệu năng trong quá trình truy vấn và phân tích dữ liệu.

Các biến thời gian như tpep_pickup_datetime và tpep_dropoff_datetime được lưu dưới dạng timestamp_ntz, cho phép thực hiện hiệu quả các phép toán liên quan đến thời gian, đặc biệt là tính toán thời lượng chuyến đi và phân tích theo khung giờ.

Đối với các biến định danh như VendorID, PULocationID và DOLocationID, dữ liệu được biểu diễn dưới dạng số nguyên . Việc sử dụng kiểu dữ liệu này giúp tối ưu hóa việc lưu trữ cũng như hỗ trợ hiệu quả trong các phép nối và truy vấn dữ liệu.

Các biến định lượng như trip_distance, fare_amount, total_amount cùng các khoản chi phí khác được lưu dưới dạng số thực, đảm bảo độ chính xác cần thiết cho các phép tính và phân tích định lượng. Ngoài ra, các biến như

passenger_count, RatecodeID và payment_type sử dụng kiểu long, trong khi store_and_fwd_flag được lưu dưới dạng chuỗi.



Hình 3.1: Các kiểu dữ liệu trong data

Đáng chú ý, toàn bộ các trường dữ liệu đều cho phép giá trị null (nullable = true), cho thấy khả năng tồn tại dữ liệu thiếu trong tập dữ liệu. Đây là một yếu tố quan trọng cần được xem xét và xử lý trong các bước tiền xử lý và làm sạch dữ liệu tiếp theo.

3.1.3 Thống kê mô tả và nhận diện giá trị bất thường

Để có thể thấy rõ sự biến động giữa các giá trị của các biến định định lượng, chúng ta sử dụng hàm `describe()` để có thể thầy được sự phản ánh sự tồn tại của nhiều điểm bất thường cần được xem xét kỹ lưỡng trong quá trình phân tích.

Bảng 3.2: Thống kê mô tả các thuộc tính chính

Thống kê	**Passenger**	**Distance**	**Fare**	**Tip**	**Total**
Count	2,636,831	3.724.889	3.724.889	3.724.889	3.724.889
Mean	1.26	6.46	20,80	2,61	29,18
Stddev	0.67	648.89	18,93	3,92	22,59
Min	0	0.0	-2.555,2	-88,88	-2.560,2
Max	9	269,097.48	2.555,2	766,0	2.560,2

Đối với biến trip_distance, giá trị trung bình đạt khoảng 6,45 miles, phù hợp với đặc điểm các chuyến đi trong đô thị. Tuy nhiên, giá trị cực đại lên tới 269.097,48 miles là hoàn toàn phi thực tế về mặt vật lý, cho thấy sự tồn tại của các giá trị ngoại lai hoặc lỗi ghi nhận dữ liệu. Đồng thời, độ lệch chuẩn rất lớn (648,89) cũng phản ánh mức độ phân tán cao của biến này.

Tương tự, biến fare_amount cũng xuất hiện các giá trị bất thường, với mức nhỏ nhất là -2.555,2 USD. Giá trị âm trong chi phí thường không hợp lý trong bối cảnh giao dịch thông thường, và có thể xuất phát từ các trường hợp hoàn tiền, lỗi hệ thống hoặc sai sót trong quá trình ghi nhận dữ liệu. Điều này cho thấy cần có bước xử lý dữ liệu để loại bỏ hoặc điều chỉnh các giá trị không hợp lệ.

Đối với biến passenger_count, số lượng hành khách trung bình khoảng 1,25 người mỗi chuyến, phản ánh đặc điểm phổ biến của dịch vụ taxi đô thị. Tuy nhiên, dữ liệu ghi nhận các trường hợp bất thường như 0 hành khách hoặc lên đến 9 hành khách trong một chuyến đi. Những giá trị này có thể do lỗi nhập liệu hoặc các trường hợp đặc biệt, và cần được kiểm tra thêm để đảm bảo tính hợp lý.

Nhìn chung, kết quả thống kê mô tả cho thấy mặc dù dữ liệu có giá trị phân tích cao, nhưng vẫn tồn tại nhiều điểm bất thường và ngoại lai. Do đó, việc xử lý dữ liệu là cần thiết nhằm đảm bảo độ chính xác và độ tin cậy cho các bước phân tích tiếp theo.

3.1.4 Phân tích sự thiếu hụt và trùng lặp dữ liệu

Bên cạnh các vấn đề liên quan đến giá trị ngoại lai và sai lệch dữ liệu, một khía cạnh quan trọng khác cần được xem xét trong quá trình phân tích khám phá dữ liệu là tình trạng giá trị khuyết thiếu và trùng lập. Việc xác định mức độ và đặc điểm của dữ liệu thiếu đóng vai trò then chốt trong việc đảm bảo tính chính xác và độ tin cậy của các phân tích tiếp theo.

Kết quả phân tích dữ liệu cho thấy sự tồn tại của vấn đề nghiêm trọng liên quan đến giá trị khuyết thiếu trong một số biến quan trọng của tập dữ liệu. Cụ thể, có 1.088.058 bản ghi, chiếm khoảng 29% tổng số dòng, chứa giá trị NULL tại các cột như passenger_count, RatecodeID, store_and_fwd_flag, congestion_surcharge và Airport_fee. Đây đều là các biến có vai trò quan trọng trong việc mô tả đặc điểm chuyến đi và cấu trúc chi phí, do đó mức độ thiếu dữ liệu lớn có thể ảnh hưởng đáng kể đến kết quả phân tích. Đặc biết bộ dữ liệu không có bất kỳ dòng nào bị trùng với nhau điều đó thể hiện mức độ đáng tin cậy của bộ dữ liệu.

Đáng chú ý, số lượng giá trị NULL này trùng khớp hoàn toàn với số lượng bản ghi có payment_type = 0. Điều này cho thấy có mối liên hệ chặt chẽ giữa phương thức thanh toán và khả năng thu thập dữ liệu. Cụ thể, các giao dịch có payment_type = 0 nhiều khả năng là các bản ghi không xác định hoặc không hợp lệ về phương thức thanh toán, dẫn đến việc thiếu thông tin ở các trường liên quan.

Hiện tượng này gợi ý rằng việc thiếu dữ liệu không xảy ra ngẫu nhiên mà có tính hệ thống. Do đó, trong quá trình tiền xử lý, cần xem xét kỹ lưỡng các bản ghi có payment_type = 0 để đưa ra phương án xử lý phù hợp, chẳng hạn như loại bỏ, thay thế hoặc phân tích riêng biệt, nhằm tránh gây sai lệch cho các kết quả phân tích và mô hình hóa sau này.

Bảng 3.3: Thống kê số lượng giá trị thiếu (Null) trong tập dữ liệu

Tên cột (Attribute)	**Số lượng Null**	**Tỷ lệ (%)**
passenger_count	1,088,058	$\approx 29.2\%$
RatecodeID	1,088,058	$\approx 29.2\%$
store_and_fwd_flag	1,088,058	$\approx 29.2\%$
congestion_surcharge	1,088,058	$\approx 29.2\%$
Airport_fee	1,088,058	$\approx 29.2\%$
Các cột còn lại	0	0%

Nhìn chung, vấn đề giá trị khuyết thiếu trong tập dữ liệu không chỉ ảnh hưởng đến tính đầy đủ mà còn phản ánh các bất thường trong quá trình thu thập dữ liệu, đòi hỏi các bước xử lý cẩn trọng ở giai đoạn tiếp theo.

3.2. Chiến lược làm sạch và xử lý dữ liệu nhiễu

Sau khi thực hiện phân tích khám phá dữ liệu, có thể nhận thấy tập dữ liệu tồn tại nhiều vấn đề về chất lượng như giá trị ngoại lai, dữ liệu không hợp lệ và giá trị khuyết thiếu. Đây là giai đoạn trọng tâm về mặt kỹ thuật, nhằm xác định và loại bỏ các dữ liệu không có giá trị phân tích, đồng thời chuẩn hóa dữ liệu để đảm bảo tính nhất quán và độ tin cậy.

Trên cơ sở đó, các chiến lược làm sạch dữ liệu sẽ được đề xuất và áp dụng một cách có hệ thống, bao gồm việc xử lý giá trị thiếu, loại bỏ hoặc điều chỉnh các giá trị bất thường, cũng như chuẩn hóa các biến dữ liệu. Những bước này đóng vai trò quan trọng trong việc nâng cao chất lượng dữ liệu đầu vào, tạo nền tảng vững chắc cho các giai đoạn phân tích và xây dựng mô hình tiếp theo.

3.2.1 Khử trùng lặp và loại bỏ giá trị thiếu

Trong quá trình làm sạch dữ liệu, việc xử lý các bản ghi trùng lặp và giá trị khuyết thiếu đóng vai trò quan trọng nhằm đảm bảo tính nhất quán và độ tin cậy của tập dữ liệu. Mặc dù kết quả phân tích ban đầu cho thấy không tồn tại các dòng trùng lặp hoàn toàn, quy trình kiểm tra và khử trùng lặp vẫn được thực hiện bằng hàm `dropDuplicates()` trên các cột định danh và các thuộc tính cốt lõi nhằm đảm bảo không có sự trùng lặp tiềm ẩn trong dữ liệu.

Bên cạnh đó, các giá trị khuyết thiếu được xử lý thông qua hàm dropna(), tập trung vào các cột quan trọng như passenger_count,trip_distance,... Việc loại bỏ các bản ghi chứa giá trị `NULL` ở các trường này giúp đảm bảo rằng dữ liệu đầu vào cho các bước phân tích tiếp theo là đầy đủ và đáng tin cậy.

Sau khi áp dụng các bước xử lý trên, số lượng bản ghi trong tập dữ liệu giảm xuống còn 2.636.831 dòng, phản ánh việc loại bỏ một lượng đáng kể các dữ liệu không hợp lệ hoặc không đầy đủ. Mặc dù làm giảm kích thước dữ liệu, bước này giúp nâng cao chất lượng tổng thể của tập dữ liệu, từ đó cải thiện độ chính xác và hiệu quả của các mô hình phân tích trong các giai đoạn tiếp theo.

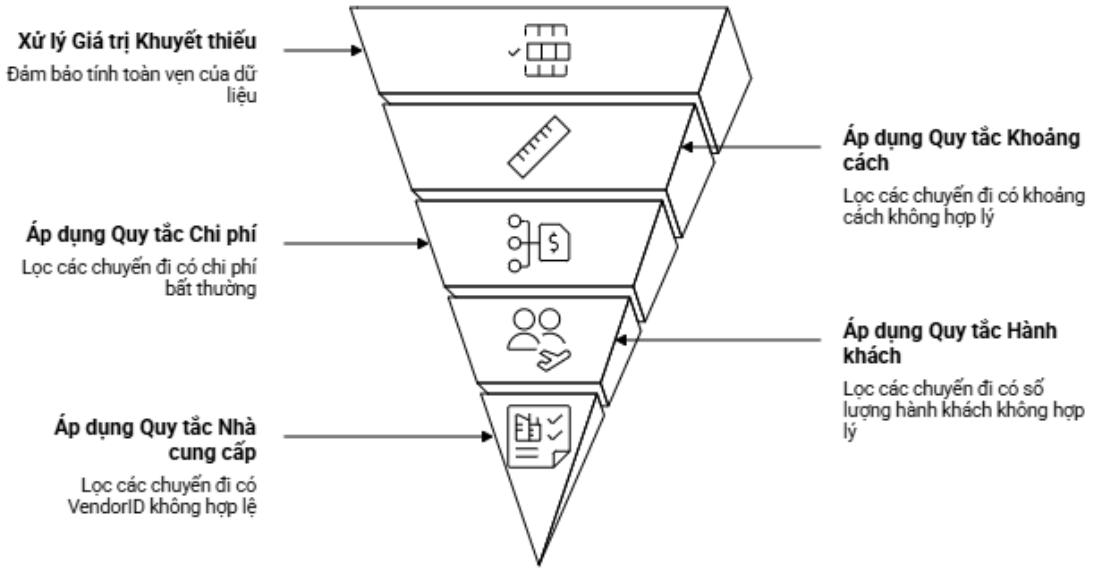
3.2.2 Áp dụng quy tắc nghiệp vụ để lọc dữ liệu

Sau khi xử lý giá trị khuyết thiếu và đảm bảo tính toàn vẹn cơ bản của dữ liệu, bước tiếp theo là áp dụng các quy tắc nghiệp vụ nhằm loại bỏ các bản ghi không phù hợp với thực tế hoạt động của dịch vụ taxi tại New York. Các quy tắc này được xây dựng dựa trên hiểu biết về đặc điểm vận hành và các ràng buộc thực tế của ngành.

Cụ thể, đối với biến trip_distance, chỉ giữ lại các chuyến đi có khoảng cách lớn hơn 0 và không vượt quá 200 miles, nhằm loại bỏ các giá trị bằng 0

hoặc quá lớn, không hợp lý về mặt thực tế. Đối với chi phí, biến fare_amount được giới hạn trong khoảng từ 2,5 USD đến 500 USD, đảm bảo loại bỏ các giá trị bất thường như âm hoặc quá cao. Đồng thời, biến total_amount cũng được ràng buộc lớn hơn 0 và không vượt quá 1000 USD nhằm phản ánh đúng tổng chi phí hợp lệ của một chuyến đi.

Bên cạnh đó, số lượng hành khách được giới hạn trong khoảng từ 1 đến 6 người, phù hợp với sức chứa thực tế của xe taxi tiêu chuẩn. Các giá trị ngoài khoảng này được xem là không hợp lệ và bị loại bỏ. Ngoài ra, biến tip_amount được yêu cầu không âm, và VendorID chỉ chấp nhận các giá trị hợp lệ là 1 hoặc 2, tương ứng với các nhà cung cấp dịch vụ chính thức.



Hình 3.2: Quy trình lọc dữ liệu theo nghiệp vụ

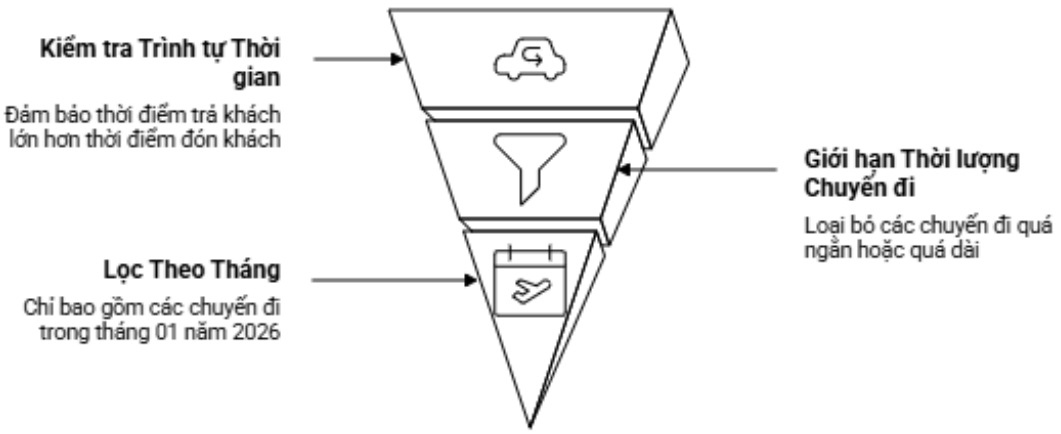
Sau khi áp dụng các quy tắc lọc theo nghiệp vụ, số lượng bản ghi trong tập dữ liệu còn lại 2.507.799 dòng. Kết quả này cho thấy một phần dữ liệu đã được loại bỏ nhằm đảm bảo tính hợp lý và độ tin cậy, từ đó nâng cao chất lượng dữ liệu phục vụ cho các bước phân tích và xây dựng mô hình tiếp theo.

3.2.3 Chuẩn hóa thời gian và không gian

Bên cạnh việc áp dụng các quy tắc nghiệp vụ, dữ liệu cũng được chuẩn hóa theo yếu tố thời gian nhằm đảm bảo tính hợp lý và nhất quán của các chuyến đi. Cụ thể, điều kiện đầu tiên được áp dụng là thời điểm trả khách phải lớn hơn thời điểm đón khách, nhằm loại bỏ các bản ghi sai lệch về trình tự thời gian.

Ngoài ra, thời lượng chuyến đi được giới hạn trong khoảng từ 60 giây đến 21.600 giây (tương đương từ 1 phút đến 6 giờ). Điều kiện này giúp loại bỏ các chuyến đi có thời gian quá ngắn (có thể do lỗi ghi nhận) hoặc quá dài, không phù hợp với thực tế vận hành của dịch vụ taxi trong đô thị.

Bên cạnh đó, để đảm bảo tính nhất quán về phạm vi nghiên cứu, dữ liệu được lọc chỉ bao gồm các chuyến đi diễn ra trong tháng 01 năm 2026, dựa trên trường tpep_pickup_datetime. Điều này giúp đồng nhất dữ liệu theo thời gian và phục vụ cho mục tiêu phân tích cụ thể của bài toán.



Hình 3.3: Quy trình lọc theo thời gian là không gian

Sau khi áp dụng các điều kiện lọc liên quan đến thời gian, số lượng bản ghi trong tập dữ liệu còn lại 2.497.196 dòng. Bước xử lý này góp phần loại bỏ các dữ liệu không hợp lệ về mặt thời gian, từ đó nâng cao chất lượng và

độ tin cậy của tập dữ liệu cho các bước phân tích tiếp theo.

3.3. Kiểm soát giá trị ngoại lệ

Sau khi áp dụng các quy tắc lọc cơ bản, tập dữ liệu vẫn có thể tồn tại các giá trị ngoại lệ– là những điểm dữ liệu có giá trị quá lớn hoặc quá nhỏ so với phần còn lại. Những giá trị này có thể không hoàn toàn sai, nhưng lại gây ảnh hưởng đáng kể đến các chỉ số thống kê như trung bình và độ lệch chuẩn, từ đó làm sai lệch kết quả phân tích và mô hình hóa. Vì vậy cần phải kiểm soát hay loại bỏ các giá trị này.

Để giải quyết vấn đề này, các kỹ thuật phát hiện ngoại lệ được áp dụng nhằm xác định và loại bỏ các điểm dữ liệu quá dị. Một trong những phương pháp phổ biến là sử dụng khoảng tứ phân vị, trong đó các giá trị nằm ngoài khoảng

$$[Q_1 - m \times \text{IQR}, Q_3 + m \times \text{IQR}]$$

Trong đó, m là hệ số điều chỉnh (thường nằm trong khoảng từ 1.5 đến 3.0) nhằm kiểm soát mức độ nghiêm ngặt khi loại bỏ ngoại lệ.sẽ được xem là ngoại lệ. Phương pháp này đặc biệt hiệu quả đối với các biến định lượng như trip_distance,total_amount,... vốn thường có phân phối lệch phải trong dữ liệu thực tế.

Bảng 3.4: So sánh hiệu quả loại bỏ ngoại lai theo hệ số m (phương pháp IQR)

Hệ số m	**Số dòng còn lại**	**Tỷ lệ giữ lại (%)**	**Tỷ lệ loại bỏ (%)**
1.5	2,036,336	81.54%	18.46%
2.0	2,124,258	85.07%	14.93%
2.5	2,171,329	86.95%	13.05%
3.0	**2,216,753**	**88.77%**	**11.23%**

Kết quả cho thấy khi $k = 3$, tập dữ liệu vẫn giữ lại khoảng 88,77% số bản

ghi, đồng thời loại bỏ được các giá trị cực đoan gây nhiễu. Do đó, giá trị $k = 3$ được lựa chọn là ngưỡng phù hợp, đảm bảo cân bằng giữa việc loại bỏ ngoại lệ và duy trì chất lượng dữ liệu cho phân tích.

Sau khi áp dụng phương pháp IQR với hệ số đã chọn, tập dữ liệu được tinh lọc, giảm thiểu ảnh hưởng của các giá trị bất thường và trở nên ổn định hơn cho các bước phân tích và mô hình hóa tiếp theo.

3.4. Kỹ thuật đặc trưng và làm giàu dữ liệu

Sau khi hoàn tất các bước làm sạch và chuẩn hóa dữ liệu, giai đoạn tiếp theo tập trung vào việc xây dựng và làm giàu các đặc trưng. Đây là bước quan trọng nhằm khai thác tối đa thông tin tiềm ẩn từ dữ liệu thô, đồng thời tạo ra các biến mới có ý nghĩa hơn phục vụ cho các phân tích chuyên sâu.

Việc xây dựng các đặc trưng mới không chỉ giúp làm rõ hơn bản chất của dữ liệu mà còn góp phần nâng cao hiệu quả của các phương pháp phân tích và mô hình hóa. Các đặc trưng này sẽ đóng vai trò nền tảng cho các phân tích chuyên sâu được trình bày trong Chương 4.

3.4.1 Chuyển đổi đặc trưng thời gian

Từ biến thời gian gốc tpep_pickup_datetime, các đặc trưng liên quan đến thời gian được trích xuất nhằm phục vụ cho việc phân tích theo chu kỳ và xu hướng. Cụ thể, cột pickup_hour được tạo ra để xác định giờ đón khách trong ngày, giúp phân tích lưu lượng theo khung giờ. Bên cạnh đó, cột pickup_dayofweek thể hiện thứ trong tuần, hỗ trợ phân tích sự khác biệt giữa ngày thường và cuối tuần. Ngoài ra, cột pickup_week được xây dựng để xác định tuần trong năm, phục vụ cho việc phân tích xu hướng theo thời gian dài hơn.

Ta xem xét một ví dụ cụ thể như sau: một chuyến đi có thông tin ban

đầu thời điểm đón khách là 08:30 sáng ngày 15/01/2026, thời điểm trả khách là 08:50 cùng ngày, quãng đường di chuyển là 5 miles, giá cước là 20 USD và tiền tip là 3 USD. Từ đó ta có thể xây dựng các đặc trừng thời gian như sau: pickup_hour = 8 (giờ đón khách), pickup_dayofweek = 5 (tương ứng với ngày trong tuần, ví dụ Thứ Sáu) và pickup_week = 3 (tuần thứ 3 trong năm)

3.4.2 Tính toán chỉ số hiệu suất chuyến đi

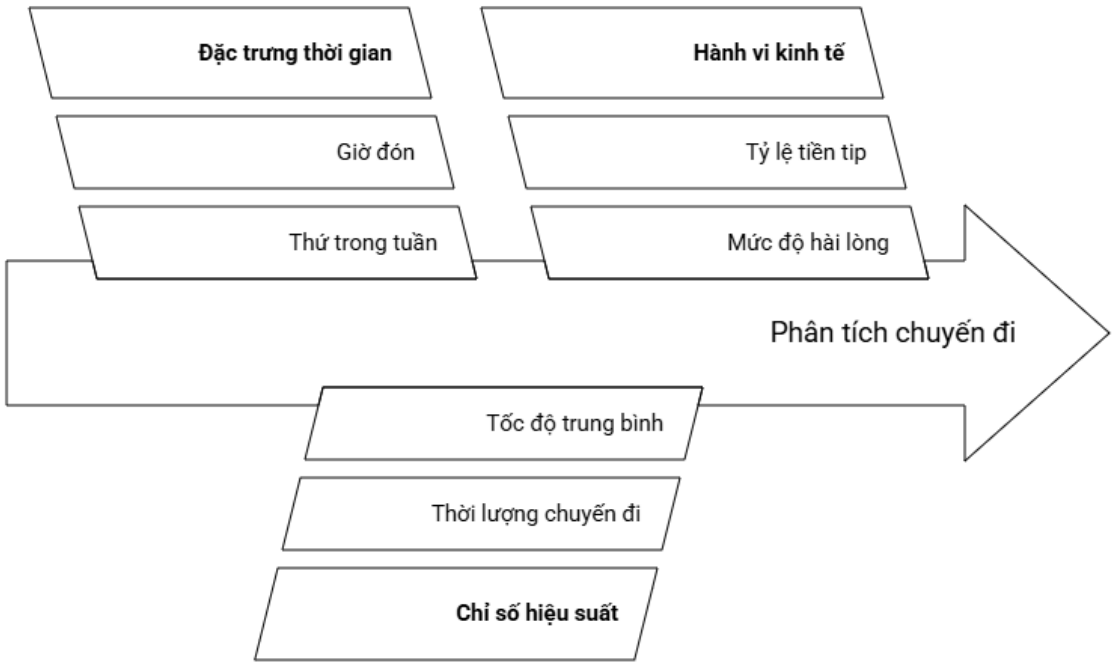
Tiếp sau khi xây dựng đặc trưng về thười gian, để đánh giá hiệu suất của mỗi chuyến đi, các chỉ số mới được xây dựng từ dữ liệu sẵn có. Cụ thể, cột trip_duration_min được tính toán dựa trên chênh lệch giữa thời điểm trả và đón khách, sau đó chuyển đổi sang đơn vị phút. Từ đó, tốc độ trung bình của chuyến đi (speed_mph) được xác định bằng cách lấy quãng đường (trip_distance) chia cho thời gian di chuyển (quy đổi sang giờ). Các chỉ số này giúp phản ánh hiệu quả vận hành và có thể được sử dụng để phát hiện các bất thường trong dữ liệu. Áp dụng vào ví dụ trên, ta có trip_duration_min = 20 phút (từ 08:30 đến 08:50) và speed_mph = 15 mph (được tính từ 5 miles trong 20 phút). Các chỉ số này giúp phản ánh hiệu quả vận hành và có thể được sử dụng để phát hiện các bất thường trong dữ liệu.

3.4.3 Phân tích hành vi kinh tế

Nhằm đánh giá hành vi chi tiêu và mức độ hài lòng của khách hàng, cột tip_percentage được xây dựng bằng cách tính tỷ lệ phần trăm giữa tiền tip và giá cước. Chỉ số này cho phép phân tích xu hướng tip của khách hàng theo từng điều kiện khác nhau, từ đó cung cấp thông tin hữu ích cho việc đánh giá chất lượng dịch vụ.

Trong ví dụ đã nêu, tỷ lệ tiền tip được tính là tip= 15% (tương ứng với 3 USD tiền tip trên 20 USD giá cước), phản ánh mức độ hài lòng tương đối

cao của khách hàng đối với chuyến đi.



Hình 3.4: Quy trình làm giàu dữ liệu

3.5. Đánh giá chất lượng dữ liệu sau tiền xử lý

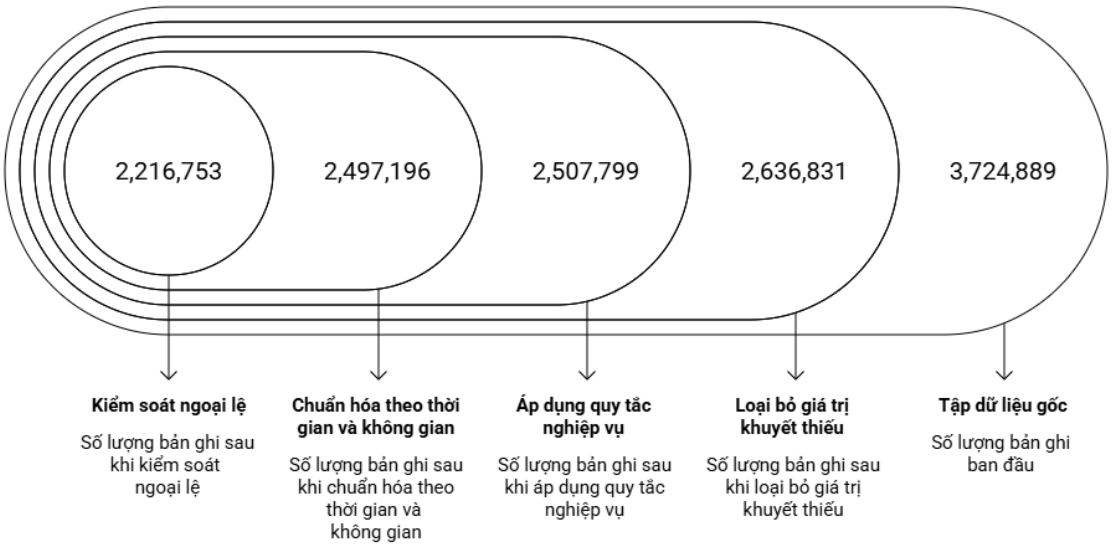
Sau khi hoàn tất các bước làm sạch và biến đổi dữ liệu, việc đánh giá lại chất lượng tập dữ liệu là cần thiết nhằm xác định mức độ cải thiện cũng như đảm bảo dữ liệu đã sẵn sàng cho các bước phân tích chuyên sâu. Phần này tập trung vào việc so sánh sự thay đổi về quy mô dữ liệu và kiểm chứng lại phân phối của các biến quan trọng sau khi tiền xử lý.

3.5.1 So sánh biến động dữ liệu

Để đánh giá mức độ ảnh hưởng của quá trình làm sạch, tiến hành so sánh số lượng bản ghi trước và sau khi xử lý dữ liệu. Ban đầu, tập dữ liệu gốc bao gồm 3.724.889 dòng. Sau khi thực hiện các bước xử lý như loại bỏ giá trị khuyết thiếu, áp dụng quy tắc nghiệp vụ và kiểm soát ngoại lệ, số lượng bản

ghi giảm xuống còn 2.216.753 dòng.

Kết quả này cho thấy một tỷ lệ đáng kể dữ liệu không hợp lệ đã được loại bỏ. Mặc dù kích thước dữ liệu giảm, nhưng chất lượng tổng thể của tập dữ liệu được cải thiện rõ rệt, giúp giảm nhiễu và tăng độ tin cậy cho các phân tích tiếp theo. Việc loại bỏ dữ liệu rác là cần thiết nhằm đảm bảo các kết quả phân tích phản ánh đúng thực tế.



Hình 3.5: Số lượng dòng dữ liệu trước và sau khi sử lý

3.5.2 Kiểm chứng phân phối sau làm sạch

Để kiểm chứng hiệu quả của quá trình làm sạch dữ liệu, các chỉ số thống kê mô tả được tính toán lại trên tập dữ liệu sau tiền xử lý. Bảng 3.5 thể hiện phân phối của các biến chính sau khi đã loại bỏ các giá trị bất thường, qua đó cho thấy dữ liệu đã trở nên hợp lý hơn, không còn xuất hiện các giá trị vô lý (như khoảng cách quá lớn hay chi phí âm), đồng thời các giá trị tập trung trong những khoảng phù hợp với thực tế vận hành.

Bảng 3.5: Thống kê mô tả các thuộc tính chính sau khi làm sạch

Thống kê	**Passenger**	**Distance**	**Fare**	**Tip**	**Total**
Count	2,216,753	2,216,753	2,216,753	2,216,753	2,216,753
Mean	1.25	2.06	14.23	2.84	22.34
Stddev	0.66	1.78	7.81	2.17	9.07
Min	1	0.01	2.5	0.0	4.0
Max	6	10.12	47.8	50.0	59.67

Sau quá trình tiền xử lý, phân phối của các biến quan trọng đã có sự cải thiện đáng kể. Cụ thể, các giá trị bất thường như khoảng cách âm hoặc quá lớn đã được loại bỏ, giúp phân phối của biến trip_distance trở nên hợp lý hơn và tập trung trong khoảng giá trị thực tế. Tương tự, các biến liên quan đến chi phí như fare_amount và total_amount không còn xuất hiện các giá trị âm hoặc cực đoan, dẫn đến phân phối ổn định và dễ phân tích hơn.

Bên cạnh đó, các biến như passenger_count cũng được chuẩn hóa về phạm vi hợp lệ, loại bỏ các giá trị không thực tế như 0 hoặc quá lớn. Nhìn chung, các biểu đồ phân phối sau làm sạch cho thấy dữ liệu đã được chuẩn hóa tốt hơn, giảm thiểu sự ảnh hưởng của các giá trị ngoại lai và phản ánh đúng đặc điểm thực tế của hoạt động taxi.

Chương IV

Tổng hợp, phân tích và trực quan hóa

Trong chương này, nhóm tiến hành thực hiện các phép tổng hợp dữ liệu trên tập dữ liệu đã được làm sạch và chuẩn hóa ở Chương 3. Mục tiêu chính là khai thác các thông tin tiềm ẩn, từ đó rút ra các quy luật và xu hướng quan trọng liên quan đến hành vi di chuyển của hành khách, doanh thu dịch vụ và hiệu quả vận hành của hệ thống taxi tại New York trong tháng 01 năm 2026.

Thông qua việc áp dụng các kỹ thuật phân tích dữ liệu kết hợp với trực quan hóa, các kết quả thu được sẽ giúp làm rõ đặc điểm phân bố theo thời gian, không gian và các yếu tố kinh tế. Đây cũng là cơ sở để đưa ra các nhận định và đề xuất mang tính thực tiễn trong việc tối ưu hóa hoạt động vận hành và nâng cao chất lượng dịch vụ taxi.

4.1. Tổng hợp và phân tích theo thời gian

Thông qua script `03_aggregation_time.py` [11], dữ liệu được tổng hợp và phân tích đa chiều theo thời gian. Việc bóc tách các đặc trưng như giờ trong ngày, ngày trong tuần và tuần trong năm giúp nhận diện rõ rệt các xu hướng biến động, từ đó làm nổi bật các khung giờ cao điểm cũng như sự khác

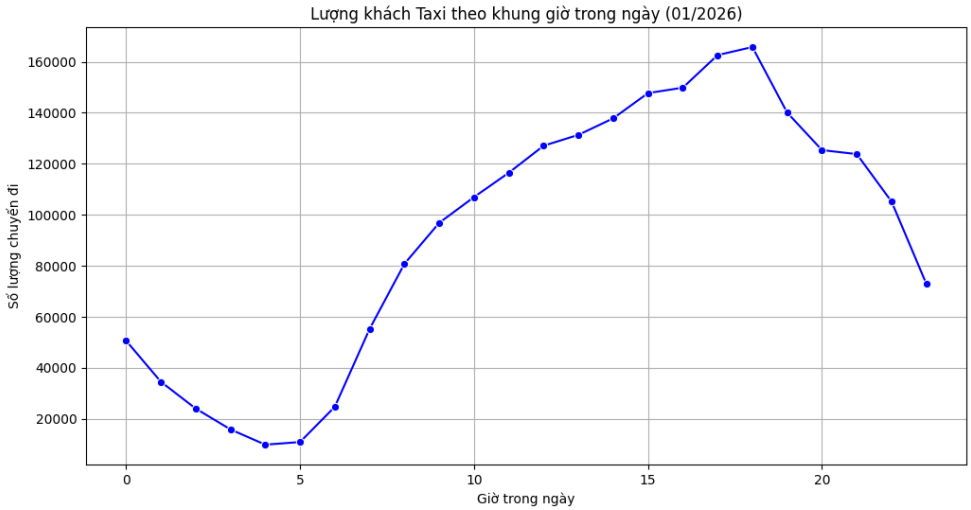
biệt trong hành vi sử dụng dịch vụ của hành khách.

4.1.1 Phân tích theo giờ trong ngày

Để hiểu rõ hơn về sự biến động của nhu cầu di chuyển trong ngày, dữ liệu được tiến hành phân tích theo từng khung giờ thông qua biến pickup_hour. Việc phân tích theo giờ cho phép nhận diện các thời điểm cao điểm và thấp điểm, đồng thời đánh giá mối quan hệ giữa lưu lượng chuyến đi, doanh thu và điều kiện giao thông trong từng thời điểm cụ thể.

Bảng 4.1: Thống kê hoạt động taxi NYC theo khung giờ

Giờ	Tổng chuyến	Tổng khách	Km TB	Giá TB	Doanh thu	% Tip	Phút TB	Vận tốc
0	50,699	68,155	2.53	14,58	1.179.958,54	22,68	11.74	12.58
1	34,593	46,722	2.43	14,08	782.044,52	22,62	11.23	12.62
2	24,082	32,555	2.41	13,92	539.453,34	22,66	10.95	12.74
3	15,904	21,350	2.47	13,90	354.026,77	22,12	10.69	13.37
4	9,920	12,751	2.78	14,87	227.367,83	20,59	11.45	14.47
5	10,936	12,228	3.14	15,81	250.127,60	17,94	12.60	15.78
6	24,749	26,951	2.73	14,67	517.378,64	18,50	13.02	13.39
7	55,275	62,080	2.32	14,12	1.142.401,16	20,12	13.43	11.13
8	80,787	91,890	2.10	14,19	1.698.061,31	20,97	13.95	9.52
9	96,854	111,421	2.03	14,28	2.050.616,95	20,95	13.93	9.22
10	106,955	127,299	2.00	14,39	2.286.977,98	20,98	14.12	8.96
11	116,500	141,257	1.95	14,47	2.512.452,54	21,00	14.37	8.50
12	127,075	155,688	1.92	14,33	2.718.235,99	20,96	14.20	8.40
13	131,348	162,934	1.91	14,32	2.814.960,62	21,07	14.18	8.31
14	137,818	171,495	1.92	14,40	2.971.785,80	21,15	14.36	8.21
15	147,718	186,690	1.91	14,41	3.193.942,75	21,23	14.51	8.11
16	149,842	189,799	1.91	14,27	3.501.558,69	23,49	14.43	8.21
17	162,607	204,039	1.87	14,17	3.836.016,09	24,23	14.28	8.12
18	165,774	208,705	1.87	13,78	3.862.878,47	24,73	13.36	8.51
19	140,054	178,499	1.98	13,63	3.244.285,88	24,85	12.59	9.36
20	125,380	162,539	2.15	13,91	2.836.484,14	23,94	12.37	10.22
21	123,804	163,429	2.28	14,26	2.855.179,72	23,92	12.48	10.72
22	105,179	140,760	2.35	14,48	2.451.163,32	23,63	12.47	11.09
23	72,900	96,745	2.49	14,59	1.704.757,53	22,99	12.07	12.03



Hình 4.1: Biểu đồ thể hiện lượng khách theo từng khung giờ trong một ngày

Dựa trên kết quả tổng hợp theo biến pickup_hour, dữ liệu cho thấy sự biến động rõ rệt về nhu cầu sử dụng dịch vụ taxi theo từng khung giờ trong ngày. Số lượng chuyến đi ở mức thấp từ 0h đến 5h, sau đó bắt đầu tăng mạnh từ khoảng 6h–7h sáng, phản ánh nhu cầu di chuyển vào giờ đi làm. Lượng chuyến đi tiếp tục tăng trong suốt buổi trưa và đạt đỉnh vào khoảng 17h–18h, với hơn 160.000 chuyến mỗi giờ, tương ứng với khung giờ tan làm.

Bên cạnh đó, tổng doanh thu cũng có xu hướng biến động tương tự với số lượng chuyến đi, cho thấy mối quan hệ chặt chẽ giữa nhu cầu di chuyển và doanh thu của hệ thống taxi. Các khung giờ cao điểm không chỉ ghi nhận số chuyến đi lớn mà còn đóng góp phần lớn vào tổng doanh thu trong ngày.

Một điểm đáng chú ý là tốc độ trung bình có xu hướng tỷ lệ nghịch với số lượng chuyến đi. Cụ thể, trong các khung giờ cao điểm (từ 8h đến 18h), tốc độ trung bình giảm xuống mức thấp nhất, dao động khoảng 8–9 mph, phản ánh tình trạng ùn tắc giao thông trong đô thị. Ngược lại, vào các khung giờ ít phương tiện thì tốc độ trung bình có thể đạt trên 12–15 mph, cho thấy điều kiện lưu thông thuận lợi hơn.

Ngoài ra, thời lượng chuyến đi cũng có xu hướng tăng nhẹ trong giờ cao

điểm, do ảnh hưởng của tình trạng kẹt xe. Trong khi đó, khoảng cách trung bình lại giảm nhẹ vào ban ngày, cho thấy phần lớn các chuyến đi trong giờ cao điểm là các hành trình ngắn trong nội đô.

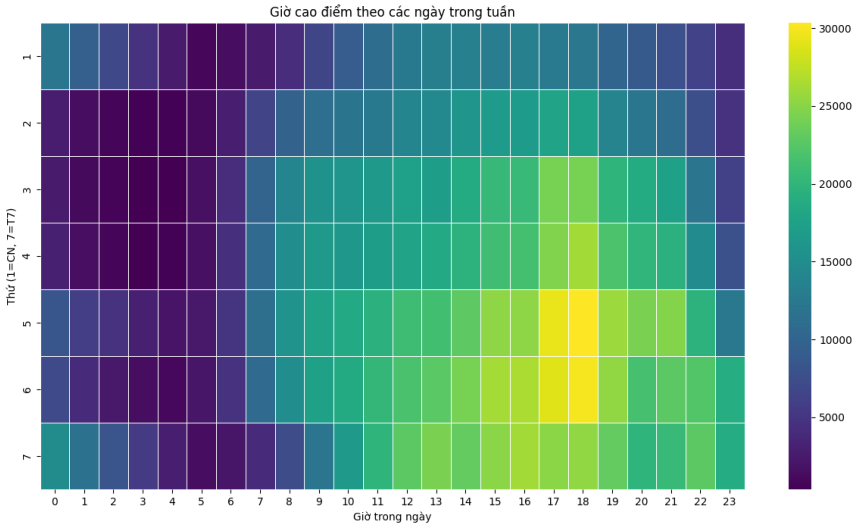
Nhìn chung, phân tích theo giờ cho thấy sự khác biệt rõ rệt giữa các khung thời gian trong ngày, đồng thời làm nổi bật mối quan hệ giữa nhu cầu di chuyển, doanh thu và điều kiện giao thông. Đây là cơ sở quan trọng để tối ưu hóa phân bổ phương tiện và nâng cao hiệu quả vận hành của hệ thống taxi.

4.1.2 Phân tích theo giờ trong tuần

Để làm rõ sự khác biệt trong hành vi sử dụng dịch vụ taxi, dữ liệu được phân tích theo từng ngày trong tuần dựa trên biến pickup_dayofweek, đồng thời kết hợp với biểu đồ nhiệt thể hiện số lượng chuyến đi theo từng khung giờ trong ngày.

Bảng 4.2: Thống kê hoạt động taxi NYC theo các ngày trong tuần

Thứ	**Mã**	**Tổng chuyến**	**Km TB**	**Doanh thu ($)**	**Giá TB**	**% Tip**
Sunday	1	198,154	2.18	4.179.016,47	13,50	22,25
Monday	2	223,662	2.11	4.837.393,38	13,54	22,87
Tuesday	3	299,429	2.05	6.860.197,05	14,60	22,69
Wednesday	4	320,931	2.06	7.408.220,22	14,72	22,68
Thursday	5	396,228	2.08	9.143.870,16	14,72	22,50
Friday	6	394,899	2.02	8.891.102,02	14,28	22,39
Saturday	7	383,450	2.02	8.212.316,88	13,76	22,18



Hình 4.2: Biểu đồ tương quan giữa giờ và ngày

Kết quả thống kê cho thấy các ngày trong tuần (đặc biệt từ thứ ba đến thứ sáu) có lưu lượng chuyến đi cao và ổn định, đóng vai trò là nguồn tạo sản lượng chính cho hệ thống. Điều này phản ánh nhu cầu di chuyển mang tính thường xuyên, chủ yếu phục vụ công việc và sinh hoạt hàng ngày.

Biểu đồ heatmap cung cấp một góc nhìn trực quan hơn về hành vi này. Có thể nhận thấy vào các ngày trong tuần, lưu lượng chuyến đi tập trung mạnh vào hai khung giờ cao điểm: buổi sáng (7h–9h) và đặc biệt là buổi chiều (16h–18h). Trong đó, khung giờ tan tầm thể hiện cường độ hoạt động cao nhất, với mật độ chuyến đi lớn và liên tục trong nhiều ngày, cho thấy đây là "điểm nóng" về nhu cầu di chuyển trong đô thị.

Ngược lại, vào cuối tuần thứ bảy và chủ nhật, tổng số chuyến đi có xu hướng giảm nhẹ và phân bố đều hơn trong ngày, không còn tập trung rõ rệt vào giờ cao điểm. Tuy nhiên, dữ liệu cho thấy giá trị trung bình mỗi chuyến đi lại cao hơn, do khoảng cách di chuyển dài hơn, phản ánh nhu cầu đi lại phục vụ mục đích giải trí, mua sắm hoặc du lịch.

Từ góc độ doanh nghiệp, có thể thấy ngày thường tối ưu về sản lượng, cần

tập trung đảm bảo khả năng đáp ứng và phân bổ xe hiệu quả trong giờ cao điểm.Còn cuối tuần tối ưu về giá trị, phù hợp để khai thác các chuyến đi dài và tăng doanh thu trên mỗi chuyến.

Ngoài ra, heatmap cũng cho thấy sự chênh lệch rõ rệt về cường độ hoạt động giữa các khung giờ, từ đó gợi ý doanh nghiệp có thể áp dụng các chiến lược linh hoạt như điều phối tài xế theo thời gian thực hoặc áp dụng giá linh hoạt vào các khung giờ cao điểm nhằm tối ưu hóa doanh thu.

4.1.3 Phân tích theo giờ trong tháng

Để đánh giá xu hướng biến động theo thời gian, dữ liệu được tổng hợp theo từng ngày trong tháng 01/2026 thông qua biến pickup_date. Các chỉ số chính bao gồm tổng số chuyến đi, tổng doanh thu và tổng tiền tip.

Bảng 4.3: Thống kê hoạt động taxi NYC chi tiết theo từng ngày trong tháng 01/2026

Ngày	Tổng chuyến	Tổng khách	Km TB	Doanh thu ($)	Tiền Tip ($)	% Tip	Phút TB
2026-01-01	54,420	80,650	2.28	1.226.546,10	149.825,65	21.83	12.04
2026-01-02	61,679	87,750	2.14	1.381.966,13	166.130,74	21.58	12.97
2026-01-03	65,784	95,615	2.13	1.434.978,49	177.488,34	21.28	12.73
2026-01-04	52,395	71,758	2.29	1.124.937,02	136.293,10	21.19	11.83
2026-01-05	61,591	74,788	2.21	1.348.972,53	162.095,14	21.94	12.79
2026-01-06	71,395	85,351	2.13	1.573.712,59	194.560,31	22.38	13.13
2026-01-07	75,677	89,837	2.12	1.696.552,34	213.956,18	22.51	13.51
2026-01-08	79,885	95,846	2.11	1.815.717,96	229.750,49	22.40	13.99
2026-01-09	80,269	100,573	2.09	1.789.721,66	225.771,11	22.67	13.36
2026-01-10	85,505	115,064	1.99	1.827.317,57	237.061,15	22.39	12.64
2026-01-11	66,464	86,663	2.17	1.408.303,06	180.352,59	22.39	11.66
2026-01-12	72,669	86,366	2.08	1.602.190,03	202.860,54	22.89	13.08
2026-01-13	80,926	95,351	2.06	1.819.723,81	235.126,85	23.05	13.65
2026-01-14	85,921	100,978	2.09	1.926.737,72	250.562,87	23.27	13.30
2026-01-15	91,579	108,251	2.05	2.050.906,67	266.151,81	23.40	13.48
2026-01-16	82,331	102,472	2.03	1.816.989,60	230.624,87	22.81	13.31
2026-01-17	74,594	102,425	2.08	1.588.483,15	205.641,79	22.37	12.16
2026-01-18	62,943	86,081	2.15	1.305.587,33	166.288,32	22.51	11.10
2026-01-19	56,737	71,446	2.10	1.201.595,04	153.148,93	23.13	11.07
2026-01-20	81,455	95,832	2.01	1.828.099,88	234.205,67	23.02	13.79
2026-01-21	84,302	98,692	2.03	1.911.672,42	247.741,98	22.93	13.95
2026-01-22	88,725	105,005	2.06	2.032.935,78	263.355,30	22.83	14.23
2026-01-23	89,260	110,314	1.98	1.973.213,36	250.955,07	22.83	13.40
2026-01-24	79,641	104,128	1.95	1.654.065,16	214.851,79	22.70	11.91
2026-01-25	16,352	21,638	2.06	340.189,06	45.431,24	24.12	10.98
2026-01-26	32,665	40,307	2.01	684.635,78	88.100,87	24.12	10.77
2026-01-27	65,653	77,199	1.97	1.638.660,77	211.818,63	22.18	17.11
2026-01-28	75,031	87,434	1.99	1.873.257,74	238.972,87	21.88	17.62
2026-01-29	81,619	95,732	1.96	2.017.763,65	256.774,71	21.70	17.44
2026-01-30	81,360	99,566	1.91	1.929.211,27	243.405,77	21.81	16.07
2026-01-31	77,926	102,869	1.98	1.707.472,51	220.566,76	21.99	13.49

Kết quả cho thấy doanh thu và số lượng chuyến đi có xu hướng biến động tương đối ổn định trong phần lớn thời gian của tháng, dao động trong khoảng từ 54.000 đến 90.000 chuyến/ngày, tương ứng với mức doanh thu từ 0.34 đến 2.0 triệu USD/ngày. Điều này phản ánh nhu cầu di chuyển duy trì ở mức cao

và ổn định trong điều kiện hoạt động bình thường.

Tuy nhiên, một điểm bất thường rõ rệt được ghi nhận vào ngày 25 và 26/01, khi số lượng chuyến đi giảm mạnh xuống chỉ còn khoảng 16.000 – 32.000 chuyến/ngày, kéo theo doanh thu giảm sâu xuống mức dưới 700.000 USD. Đây là mức sụt giảm đáng kể so với trung bình toàn tháng, cho thấy sự gián đoạn trong hoạt động vận tải.

Từ góc độ doanh nghiệp, những biến động bất thường này có thể liên quan đến các yếu tố ngoại sinh như điều kiện thời tiết khắc nghiệt, sự kiện đặc biệt hoặc gián đoạn hệ thống tại New York. Việc phát hiện sớm các "điểm gãy" trong chuỗi thời gian là rất quan trọng, giúp doanh nghiệp chủ động điều chỉnh chiến lược vận hành, phân bổ tài nguyên hoặc triển khai các phương án dự phòng.

Ngoài ra, dữ liệu cũng cho thấy sau giai đoạn sụt giảm, hệ thống nhanh chóng phục hồi về mức hoạt động bình thường từ ngày 27 trở đi, phản ánh khả năng thích ứng và phục hồi tốt của hệ thống vận hành taxi.

4.2. Tổng hợp theo nhà cung cấp, phương thức thanh toán và khu vực

Dựa trên kết quả tổng hợp từ script `04_aggregation_vendor.py`[11], dữ liệu được phân tích theo từng nhà cung cấp dịch vụ nhằm đánh giá hiệu quả kinh doanh và xác định các khu vực hoạt động trọng điểm. Việc so sánh các chỉ số như số lượng chuyến đi, doanh thu, quãng đường trung bình và tỷ lệ tiền tip giữa các nhà cung cấp cho phép làm rõ sự khác biệt trong hiệu suất vận hành cũng như chiến lược khai thác thị trường.

Từ góc độ doanh nghiệp, phân tích này giúp nhận diện các "điểm nóng" tức là những phân khúc hoặc khu vực mang lại doanh thu cao hoặc có nhu cầu di chuyển lớn. Qua đó, doanh nghiệp có thể tối ưu hóa việc phân bổ tài

nguyên, nâng cao hiệu quả khai thác và xây dựng các chiến lược cạnh tranh phù hợp giữa các nhà cung cấp dịch vụ.

4.2.1 So sánh hiệu suất giữa các nhà cung cấp

Để đánh giá hiệu quả hoạt động và mức độ cạnh tranh trong hệ thống taxi, dữ liệu được tổng hợp và phân tích theo từng nhà cung cấp dịch vụ. Việc so sánh các chỉ số quan trọng như số lượng chuyến đi, doanh thu, giá cước trung bình và tỷ lệ tiền tip cho phép làm rõ sự khác biệt trong chiến lược vận hành cũng như chất lượng dịch vụ giữa các nhà cung cấp.

Bảng 4.4: So sánh hiệu quả hoạt động giữa các nhà cung cấp dịch vụ

Nhà cung cấp	Tổng chuyến	Tổng khách	Km TB	Doanh thu ($)	Giá TB	% Tip	Vận tốc
Creative Mobile (1)	472,526	529,197	2.38	10.615.320,34	15,21	21.01%	9.11
VeriFone (2)	1,744,227	2,246,784	1.98	38.916.795,84	13,97	22.89%	9.50

Dựa trên kết quả tổng hợp theo VendorID, có thể nhận thấy sự khác biệt rõ rệt về hiệu suất hoạt động giữa hai nhà cung cấp chính là Creative Mobile và VeriFone.

Xét về quy mô hoạt động, VeriFone chiếm ưu thế tuyệt đối với khoảng 1,74 triệu chuyến đi, tương đương gần 80% thị phần, đồng thời tạo ra tổng doanh thu lên tới hơn 38,9 triệu USD. Điều này cho thấy Vendor 2 đang giữ vai trò chủ đạo trong hệ thống, với khả năng khai thác thị trường và phân bổ phương tiện hiệu quả hơn.

Trong khi đó, Creative Mobile chỉ chiếm khoảng 19% thị phần với hơn 472 nghìn chuyến đi. Tuy nhiên, xét về chất lượng chuyến đi, Vendor 1 lại thể hiện một số điểm đáng chú ý. Cụ thể, giá cước trung bình cao hơn (15,21 USD so với 13,97 USD), cùng với doanh thu trung bình trên mỗi chuyến nhỉnh hơn, cho thấy các chuyến đi của Vendor 1 có xu hướng dài hơn hoặc có giá trị cao hơn.

Đáng chú ý, chỉ số tỷ lệ tiền tip trung bình của Vendor 2 cao hơn (22.89% so với 21.01%), cho thấy mức độ hài lòng của khách hàng đối với dịch vụ của VeriFone có thể tốt hơn. Ngoài ra, Vendor 2 cũng có thời gian chuyến đi ngắn hơn và tốc độ di chuyển cao hơn, phản ánh hiệu quả vận hành tốt hơn trong điều kiện giao thông đô thị.

Từ góc độ doanh nghiệp, VeriFone dẫn đầu về quy mô và hiệu quả vận hành, trong khi Creative Mobile tập trung vào các chuyến đi có giá trị cao hơn.

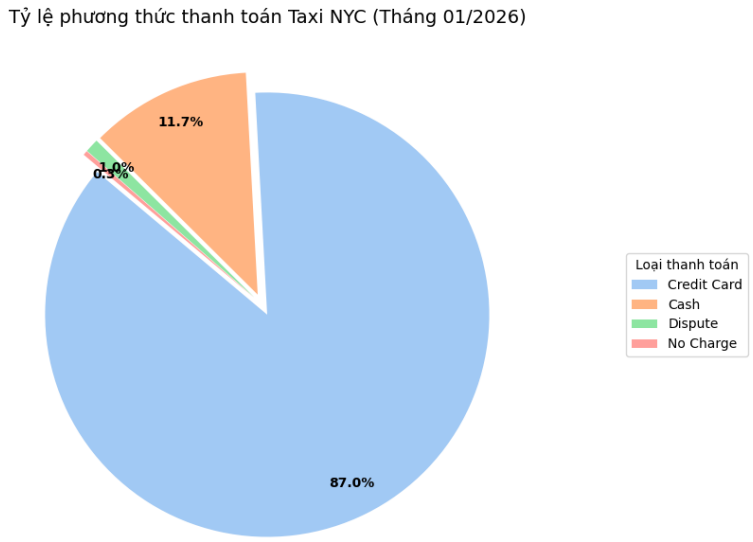
Điều này gợi ý rằng hai nhà cung cấp đang theo đuổi các chiến lược khác nhau: một bên tối ưu hóa về sản lượng và tốc độ phục vụ, trong khi bên còn lại có xu hướng khai thác các chuyến đi có giá trị cao hơn. Đây là cơ sở quan trọng để đánh giá vị thế cạnh tranh và định hướng chiến lược phát triển trong tương lai.

4.2.2 Cơ cấu phương thức thanh toán

Để hiểu rõ hành vi thanh toán của khách hàng, dữ liệu được tổng hợp theo biến payment_type và trực quan hóa thông qua biểu đồ tròn. Kết quả cho thấy sự phân bổ rất rõ rệt giữa các phương thức thanh toán trong hệ thống taxi.

Bảng 4.5: Thống kê hoạt động theo phương thức thanh toán

Phương thức	Tổng chuyến	Doanh thu ($)	Giá TB	Tip TB	% Tip
Credit Card	1,927,818	43.859.138,71	14,21	3,27	25.86%
Cash	259,441	5.085.902,69	14,41	0,00	0.00%
Dispute	22,136	449.097,44	14,81	0,00	0.00%
No Charge	7,358	137.977,34	13,49	0,00	0.01%



Hình 4.3: Biểu đồ tỷ lệ sử dụng các phương thức thanh toán

Cụ thể, thanh toán bằng thẻ tín dụng chiếm ưu thế tuyệt đối, với khoảng 87% tổng số chuyến đi, trong khi thanh toán bằng tiền mặt chỉ chiếm khoảng 11.7%. Các phương thức khác như Dispute và No Charge chiếm tỷ trọng không đáng kể. Điều này phản ánh xu hướng thanh toán không tiền mặt đang chiếm ưu thế trong môi trường đô thị hiện đại như New York.

Từ góc độ doanh thu, nhóm khách hàng sử dụng thẻ tín dụng cũng đóng góp phần lớn tổng doanh thu của hệ thống. Đáng chú ý, dữ liệu cho thấy khách hàng thanh toán bằng thẻ có xu hướng để lại tiền tip cao hơn đáng kể, với avg_tip_pct đạt khoảng 25.86%, trong khi nhóm thanh toán bằng tiền mặt gần như không ghi nhận tiền tip trong dữ liệu.

Điều này có thể được lý giải bởi đặc thù hệ thống ghi nhận: tiền tip thường được nhập trực tiếp khi thanh toán bằng thẻ, trong khi với tiền mặt, tip có thể không được ghi nhận đầy đủ. Tuy nhiên, từ góc độ doanh nghiệp, đây vẫn là một tín hiệu quan trọng cho thấy hành vi chi tiêu của khách hàng có sự khác biệt rõ rệt theo phương thức thanh toán.

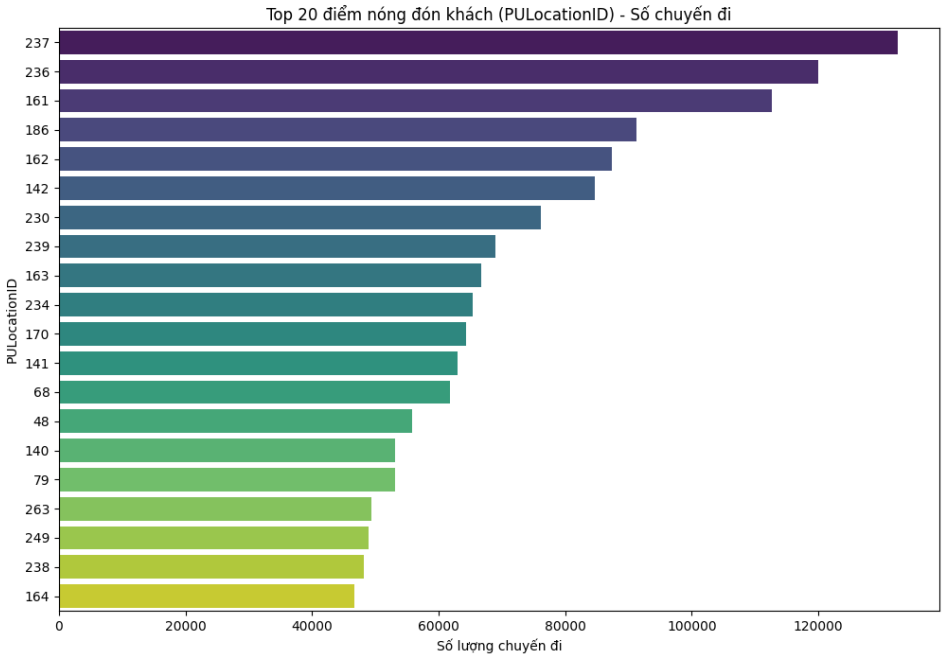
Từ các phân tích gợi ý rằng doanh nghiệp nên tiếp tục khuyến khích thanh toán không tiền mặt, đồng thời có thể tích hợp các cơ chế gợi ý tip trong quá trình thanh toán điện tử nhằm tối đa hóa doanh thu.

4.2.3 Phân tích địa điểm và tuyến đường phổ biến

Để làm rõ phân bố không gian của nhu cầu di chuyển, dữ liệu được tổng hợp theo mã khu vực và trực quan hóa thông qua biểu đồ Top 20 điểm đón khách có lưu lượng cao nhất. Kết quả cho thấy sự tập trung rõ rệt của các chuyến đi tại một số khu vực trọng điểm.

Bảng 4.6: Thống kê Top 20 khu vực đón khách có lưu lượng cao nhất

PULocationID	Tổng chuyến	Doanh thu ($)	Km TB	Giá TB
237	132,534	2.601.095,72	1.50	11,83
236	120,061	2.409.473,77	1.62	12,41
161	112,679	2.549.610,82	1.74	13,85
186	91,321	2.138.270,96	1.90	14,80
162	87,433	1.968.066,85	1.79	13,77
142	84,688	1.754.286,49	1.78	12,66
230	76,217	1.720.563,36	1.83	13,95
239	69,005	1.380.800,81	1.71	12,31
163	66,791	1.454.606,55	1.72	13,19
234	65,325	1.433.533,86	1.76	13,28
170	64,376	1.430.388,42	1.80	13,72
141	62,953	1.236.199,78	1.61	11,99
68	61,780	1.463.050,19	2.03	14,83
48	55,885	1.194.645,31	1.87	13,04
140	53,182	1.165.417,45	1.98	14,08
79	53,157	1.187.165,12	2.05	13,75
263	49,360	965.080,97	1.74	12,03
249	48,903	1.092.662,53	1.96	13,65
238	48,219	964.511,54	1.80	12,68
164	46,675	1.023.274,83	1.75	13,34



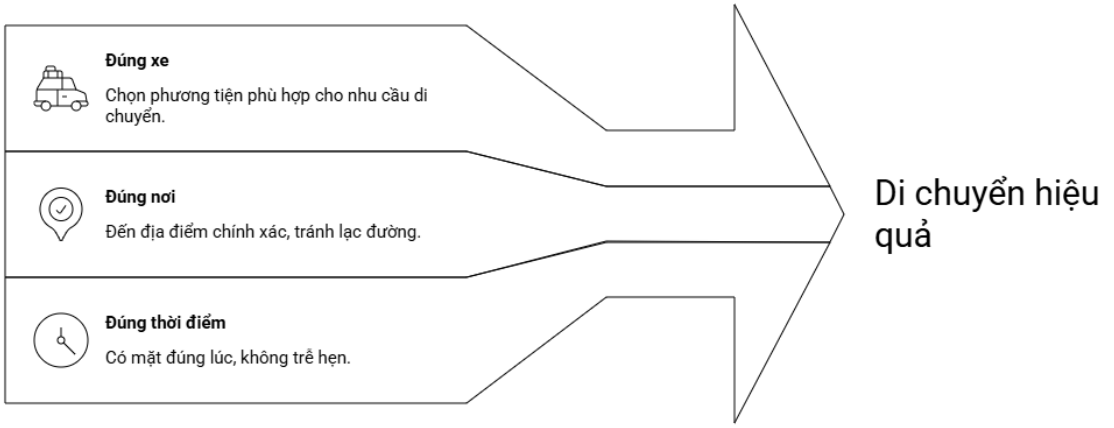
Hình 4.4: Biểu đồ Top 20 điểm nóng đón khách

Cụ thể, như thể hiện trong biểu đồ, các khu vực có mã LocationID như 237, 236, 161 đứng đầu về số lượng chuyến đi, với quy mô lên đến hơn 100.000 chuyến trong tháng. Các khu vực này chủ yếu thuộc trung tâm Manhattan – nơi tập trung dày đặc các hoạt động kinh tế, thương mại và du lịch. Sự chênh lệch rõ rệt giữa nhóm dẫn đầu và các khu vực còn lại cho thấy nhu cầu di chuyển không phân bố đồng đều mà tập trung mạnh vào các điểm nóng đô thị.

Bên cạnh đó, phân tích các cặp tuyến đường cho thấy phần lớn các chuyến đi phổ biến là các tuyến ngắn trong nội đô, với quãng đường trung bình chỉ khoảng 1.5 – 2 miles. Điều này phản ánh đặc trưng sử dụng taxi tại New York là phục vụ các nhu cầu di chuyển nhanh, linh hoạt trong khu vực trung tâm thay vì các hành trình dài.

Từ góc độ kinh doanh, có thể thấy nhu cầu di chuyển tập trung mạnh tại một số khu vực nhất định. Vì vậy cần ưu tiên phân bổ tài xế tại các điểm

này. Đặc biệt phần lớn chuyến đi là quãng ngắn thế nên tối ưu hóa vòng quay xe sẽ quan trọng hơn giá trị từng chuyến. Cuối cùng sự chênh lệch giữa các khu vực gợi ý cần có chiến lược điều phối xe thông minh để tránh tình trạng thiếu xe cục bộ.



Hình 4.5: Đúng xe – đúng nơi – đúng thời điểm

Chương V

Kết luận và hướng phát triển

5.1. Kết luận

Trong bài tiểu luận này, nhóm đã xây dựng một quy trình xử lý và phân tích dữ liệu hoàn chỉnh cho bộ dữ liệu Taxi NYC tháng 01/2026, bắt đầu từ dữ liệu thô cho đến các kết quả phân tích có giá trị. Quy trình được triển khai theo mô hình pipeline gồm các bước: khám phá dữ liệu, làm sạch dữ liệu, xây dựng đặc trưng và tổng hợp dữ liệu.

Thông qua quá trình phân tích, nhiều đặc điểm quan trọng của hệ thống taxi đã được làm rõ. Về mặt thời gian, nhu cầu di chuyển tập trung mạnh vào các khung giờ cao điểm trong ngày, đặc biệt là buổi sáng và chiều tối của các ngày làm việc. Về mặt hành vi người dùng, phương thức thanh toán bằng thẻ tín dụng chiếm ưu thế tuyệt đối và có mối liên hệ rõ rệt với mức tiền tip, phản ánh xu hướng thanh toán không tiền mặt trong đô thị hiện đại.

Ở góc độ không gian, dữ liệu cho thấy các khu vực trung tâm như Manhattan và các điểm giao thông trọng yếu đóng vai trò là các "điểm nóng" về nhu cầu di chuyển. Đồng thời, phần lớn các chuyến đi là các hành trình ngắn trong nội đô, cho thấy taxi chủ yếu phục vụ nhu cầu di chuyển nhanh và linh hoạt.

Ngoài ra, việc tổ chức dữ liệu theo cấu trúc phân tầng (raw → cleaned → aggregated) và lưu trữ theo từng nhóm chức năng đã giúp đảm bảo tính nhất

quán, dễ tái sử dụng và hỗ trợ hiệu quả cho các bước phân tích. Điều này không chỉ có ý nghĩa về mặt kỹ thuật mà còn phù hợp với các hệ thống xử lý dữ liệu thực tế trong doanh nghiệp.

Tổng thể, bài toán không chỉ dừng lại ở việc phân tích dữ liệu mà còn thể hiện cách tiếp cận có hệ thống trong xử lý dữ liệu lớn, từ đó cung cấp các insight có giá trị phục vụ cho việc tối ưu hóa vận hành và ra quyết định.

5.2. Hướng phát triển

Mặc dù đã đạt được các kết quả nhất định, đề tài vẫn còn nhiều tiềm năng để mở rộng và phát triển trong tương lai.

Thứ nhất, có thể xây dựng các mô hình dự báo nhằm dự đoán nhu cầu di chuyển theo thời gian và không gian, từ đó hỗ trợ việc phân bổ tài nguyên (xe, tài xế) một cách hiệu quả hơn. Các mô hình như hồi quy, Random Forest hoặc các phương pháp học sâu có thể được áp dụng.

Thứ hai, có thể tích hợp thêm các nguồn dữ liệu bên ngoài như thời tiết, sự kiện hoặc dữ liệu giao thông để nâng cao khả năng giải thích và dự báo. Những yếu tố này có ảnh hưởng đáng kể đến hành vi di chuyển của người dân.

Thứ ba, hệ thống có thể được phát triển thành một dashboard trực quan (sử dụng Power BI hoặc các công cụ BI khác) nhằm hỗ trợ việc theo dõi và phân tích dữ liệu theo thời gian thực. Điều này đặc biệt hữu ích trong môi trường doanh nghiệp.

Cuối cùng, có thể mở rộng phạm vi nghiên cứu sang nhiều tháng hoặc nhiều năm để phân tích xu hướng dài hạn, từ đó đưa ra các chiến lược vận hành mang tính bền vững hơn.

Tài liệu tham khảo

[1] Doug Laney, *3D Data Management: Controlling Data Volume, Velocity, and Variety*. META Group Research Note, 2001.

[2] Amir Gandomi and Murtaza Haider, "Beyond the hype: Big data concepts, methods, and analytics," *International Journal of Information Management*, vol. 35, no. 2, pp. 137–144, 2015.

[3] Yu Zheng, Licia Capra, Ouri Wolfson, and Hai Yang, "Urban Computing: Concepts, Methodologies, and Applications," *ACM Transactions on Intelligent Systems and Technology*, vol. 5, no. 3, article 38, 2014.

[4] Jeffrey Dean and Sanjay Ghemawat, "MapReduce: Simplified Data Processing on Large Clusters," *Communications of the ACM*, vol. 51, no. 1, pp. 107–113, 2008.

[5] Konstantin Shvachko, Hairong Kuang, Sanjay Radia, and Robert Chansler, "The Hadoop Distributed File System," in *Proceedings of the 2010 IEEE 26th Symposium on Mass Storage Systems and Technologies (MSST)*, pp. 1–10, 2010.

[6] Matei Zaharia, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, Josh Rosen, Shivaram Venkataraman, Michael J. Franklin, Ali Ghodsi, Joseph Gonzalez, Scott Shenker, and Ion Stoica, "Apache Spark: A Unified Engine for Big Data

Processing," *Communications of the ACM*, vol. 59, no. 11, pp. 56–65, 2016.

[7] Apache Software Foundation, *Apache Parquet Documentation*. Technical documentation, Apache Software Foundation.

[8] Dirk Merkel, "Docker: Lightweight Linux Containers for Consistent Development and Deployment," *Linux Journal*, no. 239, 2014.

[9] Thomas Kluyver, Benjamin Ragan-Kelley, Fernando Pérez, Brian Granger, Matthias Bussonnier, Jonathan Frederic, Kyle Kelley, Jessica Hamrick, Jason Grout, Sylvain Corlay, Paul Ivanov, Damián Avila, Safia Abdalla, and Carol Willing, "Jupyter Notebooks – a publishing format for reproducible computational workflows," in *Positioning and Power in Academic Publishing: Players, Agents and Agendas*, IOS Press, pp. 87–90, 2016.

[10] New York City Taxi and Limousine Commission, *Trip Record Data*. Official open data documentation, 2026.

[11] Dhai02, "Big-Data-NYC," GitHub repository, 2026. [Online]. Available: `https://github.com/dhai02/Big-Data-NYC`.